

编 号: _____

审定成绩: _____

重庆邮电大学

毕业设计（论文）

中文题目 基于大模型的对话推荐算法研究与实现

英文题目 **Conversational Recommender System:**

Research and Implementation with

Large Language Model

学院名称 计算机科学与技术学院/人工智能学院

学生姓名 向星园

专 业 智能科学与技术

班 级 04812001

学 号 22020211610

指导教师 杨燕 讲师

答 辩 组
负 责 人 栾晓 教授

2024 年 6 月

重庆邮电大学教务处制

计算机科学与技术学院/人工智能学院本科毕业 设计(论文)诚信承诺书

本人郑重承诺：

我向学院呈交的论文《基于大模型的对话推荐算法研究与实现》，是本人在指导教师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明并致谢。本人完全意识到本声明的法律结果由本人承担。

年级

专业

班级

承诺人签名

年 月 日

学位论文版权使用授权书

本人完全了解重庆邮电大学有权保留、使用学位论文纸质版和电子版的规定，即学校有权向国家有关部门或机构送交论文，允许论文被查阅和借阅等。本人授权重庆邮电大学可以公布本学位论文的全部或部分内容，可编入有关数据库或信息系统进行检索、分析或评价，可以采用影印、缩印、扫描或拷贝等复制手段保存、汇编本学位论文。

（注：保密的学位论文在解密后适用本授权书。）

学生签名：

指导老师签名：

日期： 年 月 日

日期： 年 月 日

摘要

随着互联网和人工智能技术的快速发展，推荐系统在满足用户信息需求方面变得越来越重要。相较于仅依赖大量历史行为数据分析的传统推荐系统，对话推荐系统由于能与用户互动获取实时偏好、避免信息不对等问题而受到广泛关注。

近年来，大语言模型在自然语言处理领域取得了显著进展，其强大的语言生成能力使得与对话推荐系统结合已成为趋势，但并不能简单的移植应用，需首先解决大模型与对话推荐任务的适配性问题。此外，传统对话推荐评估方法受限于静态、预定义的评估模板，无法全面捕捉系统与真实用户互动的表现，忽略了对话推荐任务的交互性，导致现有评估方法对模型性能评估不准确。

针对大模型与对话推荐任务的适配性问题，本文提出基于大模型微调和上下文感知物品元信息的对话推荐方法，提高大模型在推荐任务上的表现能力。首先，本文采用指令微调方法对 Llama2 进行微调使其适应于推荐任务，同时进一步考虑微调资源消耗问题，利用低秩自适应参数高效微调方法降低显存消耗，减少训练负担和推理时间。在此基础上，针对微调后大模型因缺乏物品集约束，导致出现推荐非物品集选项的问题，本文提出基于上下文感知物品元信息的推荐方法，在推荐中充分利用对话上下文信息和物品元信息，约束推荐空间的同时提高推荐准确性。

针对传统评估方法的局限性，本文提出了基于用户模拟器的对话推荐评估方法，通过多轮交互激发模型潜力，从而更全面地评估对话推荐模型。首先利用大模型强大的角色扮演能力来创建用户模拟器模拟真实用户，并设计了基于属性的问答和基于自由形式的闲聊两种交互形式，让用户模拟器在两种交互形式下评估模型的性能，有效评估了对话推荐系统与用户互动的真实表现。

最后，通过对两个公共对话推荐数据集 ReDial 和 OpenDialKG 进行试验分析，验证了本文所提出对话推荐算法和对话推荐评估方法的有效性。其中，相比于最先进模型，本文所提方法在推荐准确率上可提升 32.9%，同时评估了模型的可解释性和交互性能。

关键词：对话推荐系统，大语言模型，上下文感知，用户模拟器

Abstract

With the rapid development of the Internet and artificial intelligence technology, recommender systems have become increasingly important in meeting user information needs. Compared to traditional recommender systems that rely solely on the analysis of large amounts of historical behavioral data, conversational recommender systems have attracted widespread attention due to their ability to interact with users to obtain real-time preferences and avoid information asymmetry problem.

In recent years, large language models have made significant progress in the field of natural language processing. Their powerful language generation capabilities have made it a trend to integrate them with conversational recommender systems. However, this integration cannot be simply transplanted, as it first requires addressing the adaptability issues between large language models and conversational recommendation tasks. Furthermore, traditional evaluation methods for conversational recommender systems are limited by static, predefined evaluation templates, which fail to comprehensively capture the performance of systems in interaction with real users, ignoring the interactivity of conversational recommendation tasks and leading to inaccurate model performance evaluations.

To address the adaptability issues between large language models and conversational recommendation tasks, this thesis proposes a conversational recommendation method based on fine-tuning of large language model and context-aware item metadata to enhance the performance of model in recommendation task. Firstly, this thesis employ fine-tuning techniques to adapt LLama2 to recommendation task, while also considering resource consumption issues. This thesis utilize efficient fine-tuning methods with low-rank adaptive parameters to reduce memory consumption, alleviate training burdens, and shorten inference time. Based on this, to address the problem of recommending non-item set options due to the lack of item set constraints after fine-tuning large language model, this thesis propose a recommendation method based on context-aware item metadata. This method fully utilizes dialogue context information and item metadata in recommendations, constraining the recommendation space while improving recommendation accuracy.

To overcome the limitations of traditional evaluation methods, this thesis propose a conversational recommender evaluation method based on user simulators to more

comprehensively evaluate conversational recommendation models through multi-round interactions to unleash the potential of the models. This thesis utilize the strong role-playing capabilities of large language model to create user simulators that simulate real users and design two forms of interaction: attribute-based question and answer and free-form chatting, enabling user simulators to evaluate model performance under both forms of interaction, effectively evaluating the real performance of conversational recommender systems in interaction with users.

Finally, through experimental analysis on two public conversational recommender datasets, ReDial and OpenDialKG, the effectiveness of the proposed conversational recommender algorithm and evaluation method is validated. Compared to state-of-the-art models, our proposed method can improves recommendation accuracy by 32.9%, while also evaluating the model's explainability and interaction performance.

Keywords: Conversational Recommender Systems, Large Language Models, Context-Aware, User Simulator

目录

第 1 章 引言	1
1.1 研究背景和意义	1
1.2 国内外研究现状及主要问题	3
1.2.1 对话推荐系统国内外研究现状	3
1.2.2 大语言模型国内外研究现状	7
1.2.3 对话推荐评估方法国内外研究现状	8
1.2.4 目前研究存在的主要问题	8
1.3 论文主要内容	9
1.4 论文组织结构	10
1.5 本章小结	10
第 2 章 相关理论和技术	11
2.1 词元化	11
2.1.1 BPE 分词	11
2.1.2 WordPiece 分词	12
2.1.3 Unigram 分词	12
2.2 Transformer 架构	13
2.2.1 输入编码	13
2.2.2 多头自注意力机制	14
2.2.3 前馈网络层	15
2.2.4 编码器	15
2.2.5 解码器	16
2.3 对话推荐模型	17
2.3.1 基于知识图谱的对话推荐模型	18
2.3.2 基于提示学习的统一对话推荐模型	19
2.4 大语言模型训练过程	22
2.4.1 Llama2 预训练过程	23

2.4.2 LLama2-chat 指令微调.....	23
2.4.3 LLama2-chat 基于人类反馈的强化学习.....	23
2.5 本章小结	24
第 3 章 基于大语言模型的对话推荐算法	25
3.1 问题建模与数据预处理	25
3.1.1 问题描述	25
3.1.2 数据集介绍与预处理	26
3.2 基于大语言模型的对话推荐算法概述	28
3.3 面向对话推荐的大语言模型微调方法	28
3.3.1 大语言模型微调概述	28
3.3.2 面向对话推荐的指令微调	29
3.3.3 基于低秩自适应的参数高效微调	30
3.4 基于上下文感知物品元信息的推荐方法	32
3.4.1 上下文感知元信息推荐概述	32
3.4.2 物品元信息抽取	34
3.4.3 上下文感知推荐	35
3.5 实验结果与分析	35
3.5.1 实验设置与结果展示	35
3.5.2 大模型表现未达预期原因探讨	37
3.6 本章小结	38
第 4 章 基于用户模拟器的对话推荐评估方法	39
4.1 基于用户模拟器的对话推荐评估方法概述	39
4.2 对话推荐评估过程交互形式设计	40
4.2.1 基于属性的问答	40
4.2.2 基于自由形式的闲聊	41
4.3 用户模拟器设计	41
4.4 实验结果与分析	42
4.4.1 模型推荐性能评估	42
4.4.2 模型可解释性评估	44

4.5 本章小结	45
第 5 章 基于大模型的对话推荐系统设计与实现	47
5.1 系统功能需求与可行性分析	47
5.1.1 系统功能需求分析	47
5.1.2 系统可行性分析	47
5.2 系统设计方案	48
5.2.1 开发环境与工具	48
5.2.2 系统架构	49
5.3 系统展示	50
5.4 本章小结	51
第 6 章 总结与展望	53
6.1 主要工作与创新点	53
6.2 后续研究工作展望	54
6.3 本章小结	54
参考文献	55
致谢	61

第 1 章 引言

在当今信息爆炸的时代，人们正经历着信息过载的挑战。在这种背景下，对话推荐系统应运而生，它通过模拟人类对话的方式，帮助用户在海量信息中迅速定位到所需的信息。对话推荐系统的发展不仅在商业领域具有重要的战略意义，同时也为学术界带来了新的研究课题。尽管如此，这一领域的研究仍面临诸多挑战，包括提升对话推荐系统的精确度、优化对话策略，以及设计有效的评估机制等。

本文将深入探讨这些挑战，并提出了基于大语言模型的对话推荐任务解决方案。通过构建高效的提示、采用先进的微调技术、利用上下文感知物品元信息，以及基于用户模拟器进行评估等手段，推动对话推荐技术的进步，并为用户提供更加个性化和精准的推荐服务。

1.1 研究背景和意义

随着网络基础设施和互联网技术的快速进步，互联网的整体规模不断扩展，人工智能领域的发展也越来越引人注目。根据《中国互联网络发展状况统计报告》^[1]，截至 2023 年 12 月，中国网民数量已达到 10.92 亿人，相比 2022 年增加了 2480 万，平均每周上网时长达 26.1 小时。随着用户量和人均上网时长的不断增加，互联网中数据量呈指数级增长。IDC 在《数据时代 2025》白皮书中提到，全球数据总量预计 2025 年将达到 163ZB，大约每两年就会增加一倍。海量的数据为生成式人工智能提供了丰富的训练素材。同时在政策方面，2024 年 4 月 3 日，国家互联网信息办公室发布了生成式人工智能服务备案信息的公告。这表明生成式人工智能的兴起已经成为不可避免的趋势。

海量增长的数据中蕴含丰富的专业化知识，但同时也带来了严重的信息过载问题，因此如何帮助用户高效准确地获取数据以满足其信息查询需求一直是信息检索领域的关键问题，其学术研究意义和商业化价值吸引了广大研究学者开始对推荐系统展开研究，此类研究主要考虑如何从海量数据中挖掘用户兴趣并向用户推荐其潜在感兴趣的物品。

然而，传统的推荐系统主要依赖于静态推荐模型，无法充分理解用户的真实需求，很难对冷启动用户的偏好建模。因此，对话推荐系统（Conversational

Recommender Systems, CRS) 作为推荐技术的新兴方向备受瞩目。对话推荐系统不仅仅是将推荐结果呈现给用户,更是通过与用户进行多轮交互,主动引导用户表达需求和兴趣,从而更好地理解用户的真实需求并提供个性化的推荐服务。阿里巴巴、亚马逊等电商平台的智能机器人助手,以及苹果公司的 Siri、荣耀公司的 YOYO、小米公司的小爱同学等智能助手都是对话推荐系统的应用实例,目前其已成为 To C (To customer) 互联网产品的标配技术。

与传统推荐系统相比,对话推荐系统面临着更多的挑战和机遇,其需具备强大的语言理解和生成能力,并且能设计合理的对话策略。随着生成式人工智能技术的发展,大语言模型如 GPT、LLama 等已经在自然语言处理领域取得了巨大成功,其具有强大的语言理解和生成能力,能够更好地理解和生成自然语言,为对话推荐系统的发展提供了新的可能性。因此,结合大语言模型的对话推荐系统成为了当前研究的一个热门方向。如图 1.1 所示,从 2023 年 ACM 推荐系统会议 (RecSys) 投稿和接收的论文关键词中便可看出大语言模型的受关注程度。然而,当前大多数场景多为特定领域推荐,如电影推荐、商品推荐、图书推荐等,大语言模型由于缺乏关于候选物品的信息,使得它们并不适合提供特定领域的推荐。同时,当前的对话推荐评估方法过于依赖固定的对话,忽略了对话推荐的交互性质。



图 1.1 2023 年 RecSys 词云

在上述背景下,深入研究如何充分发挥大语言模型的优势,让其应用于对话推荐并提供特定领域的准确推荐具有重要意义。这不仅是响应国家政策的需要,更是推动人工智能技术向前发展的必然要求,具有重要的应用价值和学术意义。

1.2 国内外研究现状及主要问题

1.2.1 对话推荐系统国内外研究现状

对话推荐系统旨在通过多轮自然语言对话逐步了解用户的兴趣偏好，并向其推荐可能感兴趣的物品。它主要包括对话子任务和推荐子任务，并围绕着三个主要组成部分展开，如图 1.2 所示，包括语言模型、知识和指导。对话推荐依赖于语言模型，包括机器学习、深度学习和预训练语言模型，用于基础对话操作。然而，这些语言模型在推荐和常识推理方面经常表现不佳。为了弥补这一差距，额外的外部知识和指导被独立或共同整合使用。下面将从这三个主要组成部分来介绍现阶段对话推荐领域的相关工作。




图 1.2 对话推荐领域研究的主要组成部分

1) 语言模型

语言模型在对话推荐中是生成推荐响应的骨干，其中最常使用的语言模型是基于层次化递归编码解码网络（Hierarchical Recurrent Encoder-Decoder, HRED）的序列模型和基于 Transformer^[2]的预训练语言模型（Pre-trained Language Models, PLMs）。2018 年，Li 等人^[3]首次提出了基于 HRED 的对话推荐模型，并提出了一个人工标注的真实对话数据集 ReDial，现在仍被广泛使用。随着 Transformer 的广泛使用，其更好的并行性、能处理长距离依赖性、参数更少且通常具有更好的性能

表现等优点日益彰显，因此后续的研究者们大多基于 Transformer 来完成对话推荐任务。

近年来，自然语言处理领域的进展突显了像 BERT^[4]和 GPT-2^[5]这样的预训练语言模型在语言生成和常识推理方面的有效性。虽然这些预训练语言模型并非本质上针对对话推荐任务进行了优化，但研究人员已经探索了它们在推荐和响应生成等对话推荐任务中的能力。Penha 和 Hauff^[6]评估了 BERT 在推荐方面的内在能力，使用文本格式的探针进行物品的预测而不使用微调。在另一项工作中，Hayati 等人^[7]通过调整预训练语言模型来增强对话任务，生成包含鼓励或说服等社交策略的多样化推荐响应。Deng 等人^[8]采用多方面的方法，将推荐响应生成分成多个任务，包括目标或主题规划、物品推荐和响应生成。虽然这些任务各有不同，但它们对预训练语言模型进行了端到端的预训练，强调了整体对话推荐系统与预训练语言模型之间的联系，并验证了端到端训练范式的有效性。

2) 外部知识

预训练语言模型通常是通过大规模的通用语料库进行预训练的，因此其中存储的知识主要是通用性的，而不是针对特定领域或任务的，这意味着预训练语言模型所获得的隐含知识可能无法直接适用于对话推荐任务。因此研究者们利用图卷积网络 GCN 或关系图卷积网络 R-GCN 从结构化源（如知识图谱）或非结构化源（如评论）中提取知识表示，通过应用外部知识的方法从而实现准确推荐的生成。下面将介绍利用结构化和非结构化知识源的对话推荐方法。

（1）结构化知识

知识图谱是结构化知识的一种常见来源。然而，为了用于对话推荐任务，它们需要在知识和文本特征被整合之前转换为适当的表示形式。知识图谱通常由三元组表示，包括实体和关系：<电影 A-类型-科幻>，其中表示物品实体（电影 A）的节点通过表示关系（类型）的边与非物品实体（科幻）相连。在知识增强的对话推荐系统中，首先将对话中提到的实体与外部知识图谱中的实体匹配。随后，执行图传播操作，将知识图谱的结构和关系信息编码为知识表示形式。在这个阶段使用 GCN 和 R-GCN 等技术，以递归地更新基于相邻节点的表示。通过获得的知识表示形式，可以将知识图谱应用于对话推荐分为两个主要研究方向，分别是节点级实体预测和边级路径推理。

节点级实体预测通过将来自知识图谱的附加物品实体纳入响应生成中来增强对话推荐。2019 年, Chen 等人首次整合知识图谱, 提出了 KBRD 模型^[9], 该模型使用 R-GCN 对来自 DBpedia 的知识图谱中的结构和关系信息进行编码以提高推荐准确性, 但是自然语言表达和物品级用户偏好之间仍然存在语义鸿沟。为解决语义鸿沟问题, Zhou 等人提出了 KGSF 模型^[10], 引入了两个知识图谱, 但由于两个模块的不同架构设计和工作机制, 仍然存在语义不一致。Wang 等人提出了基于提示学习实现的统一对话推荐模型 UniCRS^[11], UniCRS 利用预训练语言模型 (RoBERTa^[12]、DialGPT^[13]) 进行知识增强, 引入了提示学习, 让推荐和对话两个模块相互感知和利用。

边级路径推理比节点级实体更好地解释了用户的偏好和兴趣动态变化。Ma 等人于 2021 年提出了基于树结构的两跳知识图谱推理来解释用户的偏好^[14]。两跳 KG 推理通过两个步骤: <电影 A-演员 1-电影 B>, 用户对电影 A 和 B 的观影历史让模型可以推断出用户对演员 1 的偏好。然而, 由于基于规则的设置, 两跳推理仅在用户有明确和简单的偏好时才有效, 在用户展示出兴趣转移的情况下, 多跳或树结构推理方法更加适用。Zhou 等人提出了基于强化学习的多跳策略推理模型 CRFR^[15], 为了避免在不完整的知识图谱中进行精确推理的困难, CRFR 从异构知识图谱中灵活获取最优路径片段集合, 并动态地编码片段以促进推荐和对话响应。最近, Li 等人提出了一种新颖的树形推理模式 TREA^[16], 以阐明实体之间的因果关系, 并将推理信息与生成模块相互关联, 这也是对话推荐中首次尝试推理每个提及实体的因果关系。

构建良好的知识图谱增强了在实体级别物品选择和对话级别偏好推理或解释方面的全面知识表示。然而, 由于知识图谱的静态特性, 从结构化知识源中推断物品的最新特征存在重大挑战。

(2) 非结构化知识

在非结构化知识源如评论或文档中, 使用文本检索器从外部文档中提取相关文本片段。然后, 这些片段随后转换为新知识图谱的节点或边, 或者合并到现有知识图谱中。Lu 等人提出了一种评论增强的对话推荐模型 RevCore^[17], 评论的引入使得推荐模块能够额外提取影评中的实体信息, 生成更精准的用户偏好表示; 在对话模块, 评论的引入可以在文本中列举推荐理由, 使得语句包含的信息更丰富。

Yang 等人考虑了物品元数据和对话上下文对于推荐的影响,提出了 MESE 模型^[18]。最近, Zhou 等人^[19]提出了一种名为 C²-CRS 的新型粗到细对比学习方法用于对话推荐,对比学习策略可以跨对话、知识图谱和文档评论中的嵌入来桥接语义差距,潜在地利用各种知识资源。

3) 外部指导

利用外部指导的对话推荐模型用于补充任务,包括推荐指导、话题指导、目标指导和时间指导,与将知识融入预训练语言模型的增强型模型形成对比。推荐指导利用类似于基于模板的生成方法,将对话和推荐结果的生成解耦。Liang 等人提出了一种称为 NTRD 的新型框架^[20],通过两阶段策略将响应生成与物品推荐解耦。NTRD 首先生成包含上下文词和明确与目标物品相关的槽位置的响应模板,然后通过一个具有足够注意力机制的物品选择器填充槽位以确定物品。

话题指导首先建立话题图,捕获或预测特定的目标话题,如“动作电影”或“科幻电影”。然后,模型使用这些图来指导推荐响应生成。2020 年, Zhou 等人提出了主题引导对话式推荐任务^[21],并提出了有效解决方案。Liao 等人提出了一种专门针对多领域设置的主题引导型对话式推荐模型 TCR^[22],它通过将神经潜在主题组件与序列到序列模型相结合,更好地指导响应生成。

目标指导创建从现有知识图谱和对话中派生的层次目标类型图。然后,在多样的对话目标中对模型的目标规划模块进行训练,包括“问答”、“推荐”、“问候”或“闲聊”。Liu 等人提出了 MGCG 方法^[23],其中目标计划模块利用全局图结构信息和本地目标序列信息,逐步有效地控制对话流程。目标引导响应模块可以通过充分利用分层目标信息进行响应检索或生成,产生关于每个目标的深入对话。

时间指导将时间特征纳入时间感知表示中,强调用户偏好的显式和动态变化。与传统的顺序推荐系统不同,后者可以访问用户的历史资料,对话推荐系统通常缺乏这种历史数据的深度。Li 等人提出了 UCCR 模型^[24],其是在对话推荐系统中首次以用户为中心的方式共同建模当前对话会话、历史对话会话和类似用户的信息,从而更好地理解用户需求。这种利用时间特征区分历史对话会话和当前对话会话的方法能对历史用户偏好建模,并继续从活动交互中收集新的偏好。

1.2.2 大语言模型国内外研究现状

大语言模型（Large Language Models, LLMs）来源于“扩展法则”，规模的扩展使得大语言模型具备“涌现能力”。例如相比 GPT-2, GPT-3 可以通过“上下文学习”来利用少样本数据解决下游任务。在 ChatGPT 发布后，与大语言模型相关的 arXiv 论文数量迅速增长（如图 1.3 所示），大语言模型相关的研究受到了学术界的高度关注。




图 1.3 标题包含“Large Language Model”（2019 年 10 月起）的 arXiv 论文数量变化^[25]

大语言模型以其自然语言理解和生成能力受到关注，一般可以将大语言模型分为三类：自回归模型、自编码模型和序列到序列模型，如图 1.4 中大语言模型进化树所示，分别对应 Decoder-only、Encoder-only 和 Encoder-Decoder，代表模型分别是 GPT、BERT 和 T5。




图 1.4 大语言模型进化树^[26]

近期的研究考察了 ChatGPT 在诸如段落重新排序^[27]和推荐^[28]等任务中的性能。ChatGPT 还被应用于增强推荐系统^[29]等领域。此外，Friedman 等人^[30]提出了利用大语言模型构建 YouTube 视频可控和可解释对话推荐系统的路线图。目前利用大语言模型增强对话推荐系统的相关工作大多还在探索阶段，但从大语言模型的发展现状和前面将其应用于对话推荐任务的相关研究中足以看出其潜力。

1.2.3 对话推荐评估方法国内外研究现状

对话推荐的评估在现有文献中尚未得到充分探索，先前的研究主要集中在将系统的输出与对话和推荐这两个主要任务的真实标签进行比较。针对推荐任务，传统的评估方法以召回率作为评价指标；而对于对话任务，则采取对话多样性、语言差距以及困惑度作为评价指标。

最近 Balog 等人^[31]和 Afzali 等人^[32]采用了对话级别的评估来评估对话推荐模型，这些方法通常涉及收集真实用户交互历史或评论来代表模拟用户的偏好。Zhou 等人开发了一个名为 CRSLab 的开源工具包^[33]，提供了广泛和标准的评估方法。然而，由于对话推荐的复杂和互动性质，评估通常受到预定义的对话流程或基于模板的语言的限制。因此，这种限制阻碍了对对话推荐系统实际效用的全面评估。

1.2.4 目前研究存在的主要问题

随着大语言模型等技术的发展，其与对话推荐系统相结合已经成为当前的研究趋势。然而，尽管取得了一定进展，目前的研究仍然存在几个主要问题需要解决。

1) 大语言模型微调的时间与资源消耗

大语言模型通常需要微调来适应于特定任务，但具体如何微调才能更好地适用于对话推荐任务尚待研究，并且模型参数量巨大，全量微调需要消耗大量资源，这导致了微调过程的耗时性和资源密集性，限制了其在实际应用中的可扩展性和成本效益。因此，需要研究更高效的大语言模型微调方法，提升模型在下游任务的表现性能，降低时间和资源消耗。

2) 大语言模型推荐的限制

当前大多数对话推荐的研究集中在特定领域的推荐上，例如电影、商品、图书等。然而，大语言模型缺乏有关候选物品的信息，这限制了它们在特定领域推荐中的应用。因此，需要进一步研究如何使大语言模型以适用于更具体的领域，以提高其在特定领域推荐的准确性和效果。

3) 对话推荐评估方法的不足

目前，对话推荐的评估方法过于关注系统输出与真实标签的匹配。然而，由于对话推荐的复杂性和互动性质，现有评估方法存在一定局限性。它们往往受到预定义对话流程或基于模板语言的限制。因此，需要开发更全面和准确的评估方法，以更好地反映对话推荐模型的实际效果和性能。

1.3 论文主要内容

本文旨在实现一种基于大语言模型的对话推荐算法，并设计合理的对话推荐评估策略进行模型评估。对话推荐算法的设计主要包括模型微调和下游推荐任务改进两个方面：

1) 面向对话推荐任务进行大语言模型微调。我们采用指令微调方法，通过构建有效提示帮助模型更好地理解用户的查询意图和偏好，并根据模型交互结果优化提示，使其更加有效地引导模型生成准确、个性化的推荐结果。同时考虑微调过程的资源消耗问题，我们采用基于低秩自适应的参数高效微调方法微调 Llama2，有效减少了 GPU 显存的使用量并降低了推理耗时。

2) 基于上下文感知元信息改进下游推荐任务。为了提高推荐任务的准确性以及约束推荐空间，我们引入了物品元信息，使用词嵌入模型将物品的元信息映射到文本嵌入中，然后利用上下文感知方法，通过对话上下文与物品元信息的文本嵌入相似性的比较实现下游推荐任务的改进。

对话推荐评估策略方面我们提出了基于用户模拟器的评估方法，主要包括对话推荐评估过程交互形式设计和用户模拟器设计两个方面：

1) 对话推荐评估过程交互形式设计。我们将对话推荐任务的交互分为基于属性的问答和基于自由形式的闲聊两大类。基于属性的问答通过选择预定义属性来限制系统行为，而基于自由形式的闲聊则没有限制，系统和用户都可以主动交互。两种交互形式的设计可以让我们更全面、准确地评估对话推荐任务性能。

2) 用户模拟器设计。我们采用大语言模型作为用户模拟器模拟真实用户与对话推荐系统进行交互的过程,从而评估系统的性能和效果。这一设计可以节约人工成本,同时可以进行多轮交互,拜托了先前评估方法受到预定义对话流程或基于模板语言的限制。

1.4 论文组织结构

本文是基于大模型的对话推荐算法设计任务,分为六个章节进行阐述。

第一章为引言,介绍了对话推荐系统的研究背景和意义,并根据目前相关研究工作提出了当前对话推荐系统研究存在的主要问题。

第二章为相关理论和技术,主要对词元化、大模型基础架构 Transformer、对话推荐领域的基线模型和大语言模型 Llama2 进行了介绍,为后续研究奠定了坚实的基础。

第三章介绍了基于大语言模型的对话推荐算法,首先阐述了算法的原理和设计思路,然后详细描述了模型的架构和实现细节。最后,通过实验评估分析了算法在对话推荐任务中的性能表现。

第四章介绍了基于用户模拟器的对话推荐评估方法,首先解释了评估方法的设计理念和目标,然后介绍了对话推荐交互形式的设计和用户模拟器的创建方法。最后通过对实验结果的分析,将本文提出的对话推荐算法与基线模型进行了比较。

第五章重点阐述了基于大模型的对话推荐系统设计与实现,详细描述了功能需求、开发环境与工具、系统架构设计等方面的内容,并进行了系统展示。

第六章对本文提出的对话推荐算法进行了总结,指出其可以改进的地方,并探讨了未来对话推荐的研究。

1.5 本章小结

本章节首先强调了生成式人工智能技术的兴起和对话推荐系统的重要性,然后总结了国内外对话推荐系统和大语言模型的研究现状和主要问题,最后介绍了本文的研究内容和组织结构,为后续章节的展开奠定了基础。

第 2 章 相关理论和技术

对话推荐系统以其独特的交互性和个性化推荐能力，成为连接用户需求与信息资源的新型接口。随着大数据时代的到来，如何将海量文本数据有效地转换为机器可理解的形式，成为对话推荐技术发展的关键。本章将探索这一问题，从词元化技术到 Transformer 架构，再到大语言模型训练过程，介绍对话推荐以及大语言模型的理论基础和技术路径。

2.1 词元化

词元化（Tokenization）是数据预处理中的一个关键步骤，旨在将原始文本分割成模型可识别和建模的词元序列，作为大语言模型的输入数据。传统自然语言处理研究（如基于条件随机场的序列标注）主要使用基于词汇的分词方法，这种方法更符合人类的语言认知。然而，基于词汇的分词在某些语言（如中文分词）中可能对于相同的输入产生不同的分词结果，导致生成包含海量低频词的庞大词表，还可能存在未登录词等问题。为了解决这些问题，一些语言模型开始采用字符作为分词的基本单元。此外，子词分词器如 BPE、WordPiece 和 Unigram，已经成为基于 Transformer 架构的语言模型中的常见选择。

2.1.1 BPE 分词

在 1994 年，BPE 算法被提出，最早用于通用的数据压缩。随后，自然语言处理领域的研究人员将其进行适配，并应用于文本分词^[34]。BPE 算法从一组基本符号（例如字母和边界字符）开始，迭代地寻找语料库中的两个相邻词元，并将它们替换为新的词元，这一过程被称为合并。合并的选择标准是计算两个连续词元的共现频率，也就是每次迭代中，最频繁出现的一对词元会被选择与合并。合并过程将一直持续达到预定义的词表大小。

字节级别的 BPE 是一种对传统 BPE 算法的创新扩展。这种方法将字节作为构建词汇表的基本单元，允许模型以更精细的粒度对文本进行切分。采用这种词元化方法的代表性语言模型包括 GPT-2、BART 和 LLama。具体来说，如果将所有

Unicode 字符都视为基本字符，那么包含所有可能基本字符的基本词表会非常庞大。而将每个字符视为独立的单位，例如中文中的汉字，则可以构建一个固定大小的词汇表。

2.1.2 WordPiece 分词

WordPiece 是一种由谷歌开发的分词技术，最初用于语音搜索系统的开发。它在 2016 年被应用于机器翻译领域，并在 2018 年被 BERT 模型采用^[4]。WordPiece 的分词过程首先依赖于一个预先训练的语言模型，该模型用于对潜在的词元对进行评估。在每次合并过程中，WordPiece 算法选择那些能够最大化提升训练数据似然度的词元对进行合并。这种方式与 BPE 不同，BPE 通常选择最常见的词元对进行合并。

通过这种策略，WordPiece 能够更有效地处理词汇，尤其是在面对低频词和未登录词时，能够提供更优的解决方案。这种分词方法的采用，使得 BERT 等模型在处理自然语言时能够更加精确和高效。

2.1.3 Unigram 分词

与 BPE 分词和 WordPiece 分词不同，Unigram 分词技术^[35]是一种从大量文本数据中开始，逐步精简词元以形成合适大小词汇表的方法。这一过程通过反复移除词元，并评估这一改变对训练语料库似然性的影响来进行，以此作为词元选择的依据。此方法依赖于一个已经训练完成的一元语言模型，该模型用于估计文本的概率分布。

为了构建这个一元语言模型，Unigram 分词采用了期望最大化（EM）算法。在算法的每次迭代中，首先根据现有的语言模型确定最优的分词策略。随后，基于这些分词结果，重新计算一元概率分布，进而更新语言模型。这个过程循环进行，直到达到预定的词汇表大小。此方法的优势在于它能够动态调整词汇表，以适应不同规模的训练数据，同时保持对语料库的高似然估计。通过这种方式，Unigram 分词能够为语言模型提供更加精确的词汇表示，从而提高模型的整体性能。采用 Unigram 分词方法的模型有 T5、mBART。

2.2 Transformer 架构

当前主流的大语言模型都基于 Transformer 模型进行设计的。Transformer 是一种由多个自注意力机制层组成的深度学习模型，包含编码器和解码器两个主要组件，但它们可以独立工作，目前大语言模型主要使用解码器架构。如图 2.1 所示，Transformer 模型的基本组成包括基础的输入、多头自注意力模块和前置网络层，分为编码器和解码器两个模块。




图 2.1 Transformer 架构

2.2.1 输入编码

在 Transformer 模型中，输入的词元序列 ($u = [u_1, u_2, \dots, u_T]$) 首先经过一个输入嵌入模块转化成词向量序列。具体来说，为了捕获词汇本身的语义信息，

每个词元在输入嵌入模块中被映射成为一个可学习的、具有固定维度的词向量 $v_t \in \mathbb{R}^H$ (H 为维度大小)。Transformer 模型的编码器部分原本不具备感知序列中元素顺序的能力，因此需要位置编码 (Position Embedding, PE) 来补充这一功能。给定一个词元 u_t ，位置编码根据其在输入中的绝对位置分配一个固定长度的嵌入向量 $p_t \in \mathbb{R}^H$ 。然后，每个词元对应的词向量和位置向量将直接相加，生成了最终的输入嵌入序列 $X = [x_1, \dots, x_T]$ ，并且被传入到后续层中：

$$x_t = v_t + p_t \quad (2.1)$$

通过这种建模方法的表示，Transformer 模型可以利用位置编码 p_t 建模不同词元的位置信息。由于不同词元的位置编码仅由其位置唯一决定，因此这种位置建模方式被称为绝对位置编码。尽管绝对位置编码能够一定程度上建模位置信息，然而它只能局限于建模训练样本中出现的位置，无法建模训练数据中未出现过的位置，因此极大地限制了它们处理长文本的能力。

2.2.2 多头自注意力机制

多头自注意力是 Transformer 模型的核心创新技术，相比于传统神经网络如 CNN (Convolutional Neural Network)、RNN (Recurrent Neural Network) 等，其可以对词元关系进行直接建模。作为对比，循环神经网络迭代地利用前一个时刻的状态更新当前时刻的状态，因此在处理较长序列的时候，常常会出现梯度爆炸或者梯度消失的问题。而在 CNN 中，词元的交互通常局限于卷积核覆盖的局部区域。

多头自注意力机制通常由多个自注意力模块组成。在每个自注意力模块中，对于输入的词元序列，将其映射为相应的查询 (Query, Q)、键 (Key, K) 和值 (Value, V) 三个矩阵。然后，对于每个查询，将和所有没有被掩盖的键之间计算点积。这些点积值进一步除以键向量维度的平方根 $\sqrt{D}$ 进行缩放，之后这些缩放后的点积值被送入 Softmax 函数，该函数根据点积的大小为每个键生成一个对应的概率权重，这些权重反映了每个键与查询的相关性。在数学上，上述过程可以表示为：

$$Q = XW^Q \quad (2.2)$$

$$K = XW^K \quad (2.3)$$

$$V = XW^V \quad (2.4)$$

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{D}}\right)V \quad (2.5)$$

与单头注意力相比，多头注意力机制的主要区别在于它使用了 I 组结构相同但映射参数不同的自注意力模块。输入序列在多头自注意力机制中首先被不同的权重矩阵转换，生成查询、键和值三组向量。这一过程在每个“头”中独立进行，每个头分别对输入数据执行自注意力计算，生成独立的输出。最后每个头产生的输出被合并，通过权重矩阵 $W^O \in \mathbb{R}^{H \times H}$ 进行映射，产生最终的输出。过程如下面的公式所示：

$$MHA = Concat(head_1, \dots, head_N)W^O \quad (2.6)$$

$$head_n = Attention(XW_n^Q, XW_n^K, XW_n^V) \quad (2.7)$$

自注意力机制具有更强的序列建模能力，并且自注意力的计算过程对于基于硬件的并行优化（如 GPU、TPU 等）非常友好，因此能够支持大规模参数的高效优化。

2.2.3 前馈网络层

Transformer 模型通过集成一个前馈网络层（Feed Forward Network, FFN）来增强其处理复杂函数关系和提取特征的能力，其包含两次线性变换和一次非线性激活函数。具体来说，给定输入 x ，上述过程形式化为：

$$FFN(X) = \sigma(XW^U + b_1)W^D + b_2 \quad (2.8)$$

其中 $W^U \in \mathbb{R}^{H \times H'}$ 和 $W^D \in \mathbb{R}^{H' \times H}$ 分别是第一层和第二层的线性变换权重矩阵， $b_1 \in \mathbb{R}^{H'}$ ， $b_2 \in \mathbb{R}^H$ 是偏置项， σ 是激活函数（在原始的 Transformer 中，采用 ReLU 作为激活函数）。前馈网络层通过激活函数引入了非线性映射变换，提升了模型的表达能力，从而更好地捕获复杂的交互关系。

2.2.4 编码器

在 Transformer 模型中编码器（Encoder）负责将输入词元编码为上下文语义相关的表示向量。编码器由多个包含多头自注意力和前馈网络模块的层堆叠而成，每层通过层归一化和残差连接增强训练稳定性。

其中，残差连接将输入与该层的输出相加，实现了信息在不同层的跳跃传递，从而缓解梯度爆炸和消失的问题。而 LayerNorm（层归一化）技术通过调整数据尺度，有助于增强模型在训练过程中的鲁棒性。编码器在处理输入 Y 时，首先接收加入了位置编码的词嵌入序列，然后通过一系列连续的编码层进行深入分析，以捕获和表示输入序列的上下文信息。在 Transformer 的编码器-解码器框架内，编码器负责生成一个综合的表示，该表示随后被用作解码器的初始输入，以启动后续的序列生成过程。形式化来说，第 l 层($l \in 1, \dots, L$)的编码器的数据处理过程如下所示：

$$X'_l = \text{LayerNorm}(\text{MHA}(X_{l-1}) + X_{l-1}) \quad (2.9)$$

$$X_l = \text{LayerNorm}(\text{FFN}(X'_l) + X'_l) \quad (2.10)$$

其中， X_{l-1} 和 X_l 分别是该 Transformer 层的输入和输出， X'_l 是该层中输入经过多头注意力模块后的中间表示。

2.2.5 解码器

在 Transformer 模型的设计中，解码器的职责是生成输出序列。与编码器不同，解码器需要引入掩码自注意力模块，用来在计算注意力分数的时候掩盖当前位置之后的词，以保证生成目标序列时不依赖于未来的信息。除了建模目标序列的内部关系，解码器还引入了与编码器相关联的多头注意力层，从而关注编码器输出的上下文信息 X_L 。Transformer 模型的解码器在结构上与编码器相似，它在每个处理模块之后同样采用层归一化技术，并引入残差连接，这样的设计有助于提升模型的训练效率，同时保持信息流的完整性。解码器在处理完输入序列后，输出的信息会经过一个全连接层，这一步骤将解码器的最终状态映射到大小为 V 的目标词汇表上，形成一个概率分布，并基于某种解码策略生成对应的词元。在解码阶段，解码器采取一种逐步迭代的方法，依次自回归地产生目标序列中的每个词元，从而构建出完整的序列，具体流程如下所示：

$$Y'_l = \text{LayerNorm}(\text{MaskedMHA}(Y_{l-1}) + Y_{l-1}) \quad (2.11)$$

$$Y''_l = \text{LayerNorm}(\text{CrossMHA}(Y'_l, X_L) + Y'_l) \quad (2.12)$$

$$Y_l = \text{LayerNorm}(\text{FFN}(Y''_l) + Y''_l) \quad (2.13)$$

其中, Y_{l-1} 和 Y_l 分别是该 Transformer 层的输入和输出, Y'_l 和 Y''_l 是该层中输入经过掩码多头注意力 MaskedMHA 和交叉多头注意力 CrossMHA 模块后的中间表示, LayerNorm 表示层归一化。然后将最后一层的输入 Y_L 映射到词表的维度上:

$$O = \text{softmax}(W^L Y_L) \quad (2.14)$$

其中, $O \in \mathbb{R}^{H \times V}$ 是模型最终的输出, 代表下一个词在词表上的概率分布; $W^L \in \mathbb{R}^{H \times V}$ 是将输入表示映射到词汇表维度的参数矩阵, 而 $W^L Y_L$ 是概率化前的中间值。

2.3 对话推荐模型

CRS 常见的模型结构包括两种: Pipeline 和 End-to-End 模型, 如图 2.2 所示。CRS 的 Pipeline 模型包括四个部分: 理解单元、推荐单元、决策单元和生成单元。理解单元接收对话并将其转换为实体-值对, 以便推荐单元生成可能的实体输出。决策单元控制对话流程, 而生成单元相应地生成响应。随着分层循环编码器-解码器 (HRED) 结构和 Transformer 编码器-解码器结构的发展, 理解、决策和生成单元等组件被合并在一起形成 End-to-End 模型。




图 2.2 CRS 两种模型结构

接下来将介绍本文所采用的两个基线模型: 基于知识图谱的对话推荐模型 (Towards Knowledge-Based Recommender Dialog System, KBRD) 和基于提示学习的统一对话推荐模型 (Towards Unified Conversational Recommender Systems via Knowledge-Enhanced Prompt Learning, UniCRS)。KBRD 引入了 DBpedia 知识图谱来丰富对话中提及的实体的语义理解, UniCRS 将单词和实体的语义融合到提示中, 用于 DialoGPT 以统一的方式解决对话和推荐任务。

2.3.1 基于知识图谱的对话推荐模型

基于知识图谱的对话推荐模型 KBRD 是一个全新的端到端框架，KBRD 利用对话内容和 DBpedia 知识图谱，通过关系图卷积网络 R-GCN 编码实体表示，结合自注意力机制进行个性化推荐，同时在对话生成中引入推荐信息来提升响应的相关性。KBRD 模型架构如图 2.3 所示。




图 2.3 KBRD 模型架构^[9]

1) 具有知识的对话感知推荐模块

KBRD 利用对话内容，包括非物品信息，在推荐过程中进行使用。此外，为了从非物品信息中有效地推荐物品，其在系统中引入了来自 DBpedia 的外部知识图谱。这些知识可以建立对话内容与物品之间的连接。KBRD 应用关系图卷积网络（R-GCNs）来对知识图谱中的结构和关系信息进行编码，以得到实体的隐藏表示。这背后的直觉是知识图谱中的相邻节点可能具有相似的特征，这些特征对于推荐是有用的。

下一步是基于知识增强的实体表示向用户推荐物品。当一个物品对应于知识图上的一个实体时，用户可能已经与多个实体进行了交互。给定一个用户 T_u ，首先从 H 中查找 T_u 中实体的知识增强表示， $H_u = (h_1, h_2, \dots, h_{|T_u|})$ ，其中 $h_i \in \mathbb{R}_d$ 是实体 e_i 的隐藏向量。KBRD 选择 $|T_u|$ 向量的线性组合，而不是简单地求这些向量的平均值。其应用了自注意力机制，该机制将 H_u 作为输入，并在 $|T_u|$ 向量上输出分布 α_u ：

$$\alpha_u = \text{softmax}(w_{a2} \tanh(w_{a1} H_u^T)) \quad (2.15)$$

其中 w_{a1} 是一个权重矩阵， w_{a2} 是一个参数向量，用户 u 的最终表示为 $t_u = \alpha_u H_u$ ， α_u 代表了对话中不同实体的权重， t_u 便是每个用户的偏好。最后推荐模块输出计算如下：

$$P_{rec} = \text{softmax}(\text{mask}(t_u H^T)) \quad (2.16)$$


2) 推荐感知对话模块

KBRD 将 Transformer 框架引入对话系统而不是基于 HBRD。为了在每个解码时间步预测单词，解码器的顶层，即输出层，在词汇表上生成概率分布 $P_{dialog} = \text{softmax}(W_o + b)$ ，其中 W 和 b 是权重和偏置参数。然而之前的对话系统完全是根据对话内容的纯文本来进行条件化的，KBRD 则通过整合推荐系统中的物品知识，优化对话系统生成与用户兴趣高度相关的响应。具体来说，KBRD 在解码器的顶层添加了受 Michel 和 Neubig (2018) 启发的词汇偏置 b_u ，但有所不同的是 b_u 基于推荐系统对用户 u 的隐藏表示进行计算 $b_u = \mathcal{F}(t_u)$ （其中 $\mathcal{F}$ 是一个前馈神经网络， t_u 是推荐上下文中的用户表示），因此，解码器顶层的计算变为：

$$P_{dialog} = \text{softmax}(W_o + b + b_u) \quad (2.17)$$

2.3.2 基于提示学习的统一对话推荐模型

基于提示学习的统一对话推荐模型 UniCRS 是一种统一的对话推荐方法，模型架构如图 2.4 所示。



1) 语义融合的提示学习

UniCRS 所采用的基础 PLM 是 DialoGPT。然而，由于 DialoGPT 是在通用对话语料库上进行预训练的，因此缺乏 CRS 任务的特定能力，不能直接应用于该任务。给定对话历史 C ，首先将出现在 C 中的对话词和知识图谱实体分别编码为单词嵌入和实体嵌入。

为提升单向解码器 DialoGPT 的性能，UniCRS 引入了具备双向编码能力的 RoBERTa 模型，用于捕获更为全面的单词嵌入信息。通过 RoBERTa 模型所生成的上下文相关的令牌表示被整合，形成一个统一的单词嵌入矩阵 $T = [h_1^T, \dots; h_{nw}^T]$ ，从而增强了模型对语言的理解力。对于实体嵌入，UniCRS 首先执行实体链接，基于外部知识图谱 DBpedia，然后利用关系图神经网络（RGCN）获取相应的实体嵌入。该网络能够通过知识图谱上的信息传播和聚合来建模关系语义。类似地，派生的实体嵌入矩阵表示为 $E = [h_1^E, \dots; h_{n_E}^E]$ ，其中 n_E 是对话历史中提及的实体数量。

UniCRS 框架通过交叉交互方法，利用双线性变换技术，实现了单词标记与知识图谱中的实体之间的语义关联，从而强化了模型对语义信息的整合能力。具体来说，UniCRS 定义了一个关联矩阵 A 和一个变换矩阵 W ，然后通过以下公式进行关联：

$$A = T^T W E \quad (2.18)$$

$$\tilde{T} = T + EA \quad (2.19)$$

$$\tilde{E} = E + TA^T \quad (2.20)$$

其中 $\tilde{T}$ 是融合的单词表示， $\tilde{E}$ 是融合的实体表示。

通过语义融合，UniCRS 建立了单词和实体之间的语义联系。为了更好地优化融合模块的参数，UniCRS 提出了一种基于提示的预训练方法，对于这个预训练任务，UniCRS 简单地利用增强的上下文序列 $\tilde{C}_{pre}$ 来预测响应中出现的实体。实体 e 的预测概率被公式化为：

$$Pr(e|\tilde{C}_{pre}) = \text{softmax}(h_u \cdot h_e) \quad (2.21)$$

其中 h_u 是通过对 $\tilde{C}_{pre}$ 中所有标记的上下文文化表示进行汇总得到的上下文的学习表示， h_e 是实体 e 的融合实体表示。

2) 子任务特定的提示设计

尽管基础的预训练语言模型没有微调，UniCRS 框架能够通过定制化的提示来适配对话推荐系统的多样化子任务需求。针对每个子任务，提示设计策略涵盖三个核心要素：对话的历史信息、为特定子任务定制的软提示，以及综合的知识表示。对于推荐，UniCRS 进一步将生成的响应模板作为额外的提示令牌。

响应生成的提示包括原始的对话历史（以单词令牌 C 的形式）、生成特定的软提示（以潜在向量 P_{gen} 的形式）和融合的文本上下文（以潜在向量 $\tilde{T}$ 的形式），形式化表示为 $\tilde{C}_{gen} \rightarrow [\tilde{T}; P_{gen}; C]$ 。

UniCRS 框架强调了在不同子任务间共享中间结果的重要性，这种做法有助于实现更加统一和连贯的输出。举例来说，在对话任务中生成回复时，如果预训练语言模型能够利用来自其他任务的额外上下文信息，它将能够预测出更加精准和相关的推荐内容。基于这种直觉，UniCRS 建议将响应模板包括在推荐子任务的提示中。具体来说，UniCRS 向基础 PLM 的词汇表 V 中添加了一个特殊标记[ITEM]，并将响应中出现的所有项替换为[ITEM]标记。在每个时间步，PLM 生成特殊标记[ITEM]或原始词汇表中的一般标记。所有槽位在生成推荐项后都将填充。

推荐项的提示包括原始的对话历史 C （以单词令牌形式）、推荐特定的软提示 P_{rec} （以潜在向量形式）、融合的实体上下文 $\tilde{E}$ （以潜在向量形式）和响应模板 S （以单词令牌形式），形式化描述为 $\tilde{C}_{rec} \rightarrow [\tilde{E}; P_{rec}; C; S]$ 。

这两个子任务提示的关键区别在于，UniCRS 对于推荐使用了实体表示，对于生成使用了单词表示。这是因为它们的预测目标分别是项和句子。此外，其还为推荐进行了特殊设计，将响应模板包括在提示的一部分中。这可以增强子任务之间的连接，并减轻语义不一致的风险。

在上述提示设计中，可调参数是推荐特定的软提示 P_{gen} 和已经进行预训练的融合实体表示 $\tilde{E}$ ，可调参数表示为 θ_{rec} 。UniCRS 利用增强的上下文 $\tilde{C}_{rec}$ 来导出用于学习 θ_{rec} 的预测损失，形式化表示为：

$$L_{rec}(\theta_{rec}) = - \sum_{j=1}^N \sum_{i=1}^M [y_{i,j} \cdot \log Pr_j(i) + (1 - y_{i,j}) \cdot \log(1 - Pr_j(i))] \quad (2.22)$$

其中 N 是训练实例的数量（上下文和目标项的一对）， M 是总项数， $y_{i,j}$ 表示一个二进制的真实标签，当物品 i 是第 j 个训练实例的正确标签时，它等于 1， $Pr_j(i)$

是 $\Pr(i|\tilde{\mathcal{C}}_{rec}^{(j)}; \Theta_{rec})$ 的简写，它是通过首先汇总上下文文化表示然后计算 softmax 分数来计算的。

2.4 大语言模型训练过程

大语言模型已经成为现代自然语言处理的中流砥柱，其多由教育机构和行业巨头（包括 OpenAI、Microsoft 和 NVIDIA 等）进行预训练，考虑到开源和许可协议等限制，本文中利用 LLama2-7b-chat 作为基础的大语言模型。

Meta 出品的 LLama 续作 LLama2，模型规模有 7b、13b、70b 这三种。LLama2 在各个榜单上精度全面超过 LLama1。Meta 的微调大语言模型，名为 LLama2-chat，是为对话场景而优化的，其训练过程如图 2.5 所示，LLama2 模型利用可获取的网络资源进行了初步训练，然后通过监督学习的方法进行了微调，以形成 LLama2-chat 的早期版本。在后续阶段，模型借助强化学习技术，包括拒绝采样和近端策略优化等方法，结合人类反馈进行了细致的迭代调优。在这一强化学习与人类反馈的过程中，持续收集用于奖励建模的数据并不断改进模型是关键，这有助于确保奖励系统的数据分布保持在预定的范围内。下面我们将进行训练过程的详细介绍。




图 2.5 LLama2-chat 训练过程

2.4.1 Llama2 预训练过程

LLama2 的预训练数据涵盖了一个新的公开可用的混合数据集，并执行了隐私数据清洗步骤。该模型在庞大的数据集上进行了训练，期间采用了上采样等技术手段来增强模型的知识储备并减少幻觉的产生。在训练的具体实施上采用了经典的 Transformer 模型架构。在细节上，LLama2 使用了 RMSNorm 进行层归一化处理，选择了 SwiGLU 作为激活函数，并引入了旋转位置编码技术，以进一步提升模型的表现力和效率。

在超参数方面，LLama2 使用了 AdamW 优化器，其中 $\beta_1 = 0.9$ ， $\beta_2 = 0.95$ ， $\text{eps} = 10^{-5}$ 。为了控制过拟合，权重衰减系数被设定为 0.1，同时梯度裁剪阈值设定为 1.0。通过这些超参数，LLama2 的训练损失在 2T 词元预训练后仍未显示出饱和的迹象。

此外，LLama2 使用了 BPE 分词器，并将所有数字拆分成单个数字，未知的 UTF-8 字符则用字节表示，词表大小设置为 32K。

2.4.2 LLama2-chat 指令微调

使用 LLama2 预训练模型，通过指令微调和基于人类反馈的强化学习技术（Reinforcement Learning with Human Feedback, RLHF），结合大量数据标注，生成了 LLama2-chat。

在监督微调中，首先构建了指令数据集。监督微调数据集的质量至关重要，即使数量在万级别，只要质量好，效果也会很好。超参数设置为批大小为 64，采用余弦学习率调度，初始学习率为 2×10^{-5} ，权重衰减为 0.1，序列长度为 4096。在训练细节方面，将所有提示和答案连接起来，保证序列长度为 4096，并在提示和答案之间加入特殊标记。在计算损失时，屏蔽用户提示，只对答案标记进行反向传播。微调模型进行了 2 个轮次的训练。

2.4.3 LLama2-chat 基于人类反馈的强化学习

RLHF 的目标是通过调整模型输出，使其与人类偏好和指令遵循对齐。在收集人类偏好数据方面，Meta 采用了二元比较协议标注样本，以最大化提示的多样性。

该过程包括标注者根据提供的标准在两个模型回应之间进行选择，并标记对选定回应的偏好程度，重点关注有用性和安全性。在训练时通过二元排序损失函数优化反馈模型，为了解决有用性和安全性相互抵消的问题，Meta 训练了针对安全性和有用性的反馈模型。此外，Meta 使用了近端策略优化和拒绝采样微调这两种主要算法探索 RLHF 的微调效果。

2.5 本章小结

本章节主要介绍了相关的理论和技术，其中包括词元化、Transformer 架构、对话推荐模型、大语言模型训练过程。在词元化方面，讨论了 BPE 等常见分词方法，以及它们在语言模型中的应用。接着，详细介绍了 Transformer 架构的基本组成和在大语言模型中的应用。然后，探讨了对话推荐的两个基线模型：KBRD 和 UniCRS。最后介绍了大语言模型 LLama2 训练过程的相关内容。本章节的技术和方法为后续章节构建和微调大语言模型提供了重要的理论和实践基础。

第3章 基于大语言模型的对话推荐算法

大语言模型强大的语言生成能力使得对话推荐系统与大模型结合已成为趋势，因此本文提出了基于大语言模型的对话推荐算法——LLaCRS，LLaCRS 算法以专为对话任务优化的 LLama2-7b-chat 模型为基础，通过微调增强了模型对推荐任务的适应性，同时采用基于上下文感知元信息的方法实现下游推荐任务，并进行了详细的实验，结合目前相关工作分析了大语言模型在推荐任务上的表现能力。

3.1 问题建模与数据预处理

3.1.1 问题描述

对话推荐系统（Conversational Recommender Systems, CRS）旨在通过多轮对话进行物品推荐，根据用户偏好推荐或澄清问题，直到用户接受推荐或离开。形式上，用户表示为 u ， i 表示来自物品集 I 的物品， w 表示来自词汇表 V 的单词，符号表示表 3.1 所示。

表 3.1 符号表示

符号	表示
U	User
I	Item
w	word
I	Item set
V	Vocabulary

每个对话包含 T 轮的交流，表示为 $C = \{s_t^{system}, s_t^{user}\}_{t=1}^T$ ，其中每个轮次包含系统的一次交互以及用户的关联响应。用户在过去 k 轮交互中的实体级别交互历史表示为 $E_t^u = \{i_1^u, \dots, i_t^u\}$ 。对话推荐定义如下，在第 t 轮，给定对话历史 C 和物品集 I ，系统应该①从整个物品集 I 中选择一组候选物品 I_t 进行推荐，并且②生成包含 I_t 中物品的响应 $R = s_t$ 。当不需要推荐时， I_t 可能为空。

3.1.2 数据集介绍与预处理

我们在 ReDial^[3]和 OpenDialKG^[36]数据集上进行实验。ReDial 是对话推荐中最常用的数据集，涉及电影推荐。OpenDialKG 是一个多领域的对话推荐数据集，涵盖了电影、书籍和音乐等。这两个数据集被广泛用于对话推荐系统的评估，接下来我们将介绍这两个数据集以及预处理部分的工作。

1) ReDial 数据集

ReDial 数据集包含 11348 个与电影推荐相关的对话。训练集大小为 (10006, 7)，测试集大小为 (1342, 7)。我们首先从 ReDial 训练集中取出 1000 条数据作为验证集，同时需要获得实体，比如电影 A 与电影 B 有共同的导演或者属于同一种类型，因此我们采用引入外部结构化知识的方法，从知识图谱中提取各个实体之间的关系。方法流程如图 3.1 所示。




图 3.1 ReDial 数据预处理流程

首先，通过读取原始数据文件，提取其中所有出现过的实体。提取过程涉及遍历原始数据文件中的每一行，解析为 JSON 格式，然后从每条消息中提取出现的实体，并将其添加到实体集合中。

然后，从知识图谱文件中加载知识图谱数据。加载过程中，创建一个字典，以实体作为键，对应的值是其关联的关系和尾实体列表。

接下来，从加载的知识图谱数据中提取子图谱。这个过程通过指定的跳数来确定子图谱的深度，即从初始实体开始，向外扩展多少跳。这里设置为两跳。利用广度优先搜索算法，逐层扩展子图谱，并将扩展的实体和关系添加到子图谱中。在模型训练中，通常需要将知识图谱中的实体和关系转换为数字形式进行处理。因此我们将实体和关系转换为唯一的数值标识符，并构建知识图谱的索引化表示。

最后，将提取的实体编号字典和关系编号字典保存为 JSON 文件，处理完成后 ReDial 数据特征如表 3.2 所示。

表 3.2 ReDial 数据特征

特征名	描述
dialog_id	对话的唯一标识符
turn_id	对话轮次的标识符
context	当前对话轮次的上下文信息
entity	当前对话轮次中涉及的实体名称列表
rec	推荐的项目列表，基于当前对话轮次的实体
resp	助手对当前对话轮次的回应内容

2) OpenDialKG 数据集

OpenDialKG 数据集是一个由两个众包代理人之间的对话组成的数据集，他们就给定主题展开对话。每个对话轮次都与其相应的“知识图谱路径”配对，这些路径将对话中提及的知识图谱实体和关系编织在一起，数据集包括 13802 个对话会话，共 91209 轮次。OpenDialKG 数据集发布包括两个部分：

(1) 对话-知识图谱平行语料库。其中每个对话轮次都与连接其前一轮次的知识图谱路径配对，路径配对指的是在概念层面上连接两个相邻轮次。给定对话 1 和对话 2 及其注释的实体路径 $A \rightarrow B \rightarrow C$ 连接对话 1 和对话 2，假设实体 A 在对话 1 中被提及，实体 C 在对话 2 中被提及。关系 B 不一定需要被提及，因为它是路径中的一个中间步骤，如<钢铁侠-演员-小罗伯特·唐尼>。

(2) 对话收集和实验中使用的基础知识图。具体数据包含在以下文件中：

[对话-知识图谱平行语料库]

./data/opendialkg.csv

[知识图谱]

./data/opendialkg_entities.txt

./data/opendialkg_relations.txt

./data/opendialkg_triples.txt

对于 OpenDialKG 数据集，我们首先按照 0.70: 0.15: 0.15 的比例将数据集进行划分，然后将对话数据处理为与 ReDial 数据特征相同的结构数据。由于

OpenDialKG 原始数据中提供了知识图谱文件，因此处理过程与 ReDial 数据集预处理过程类似，只需要为每个实体和关系分配了唯一的整数编号即可，最后将实体、关系与对应编号保存为 JSON 文件，这里不在赘叙。

3.2 基于大语言模型的对话推荐算法概述

针对大语言模型应用于对话推荐任务领域时在推荐性能表现不佳的问题，我们提出了 LLaCRS 对话推荐算法。LLaCRS 利用针对对话任务做了优化的 LLama2-7b-chat 作为基础的大语言模型。为了激发其潜力，LLaCRS 首先在数据集上人工添加提示指令进行指令微调，并基于 LoRA 方法进行轻量化微调。尽管 LLama2 具备推荐物品的基本功能，但它尚未针对推荐任务进行优化，因此可能推荐出不在测试数据集内的项目。为解决这一问题，LLaCRS 采用基于上下文感知物品元信息的推荐方法，首先获取物品元信息，然后利用词嵌入模型 BGE 获得固定维度的嵌入向量，之后将大语言模型生成的新一轮对话与历史对话上下文拼接在一起，同样利用 BGE 模型获取相同维度的嵌入向量，计算上下文与元信息的相似度来实现下游推荐任务。LLaCRS 算法流程概述如图 3.2 所示，接下来将介绍具体做法。

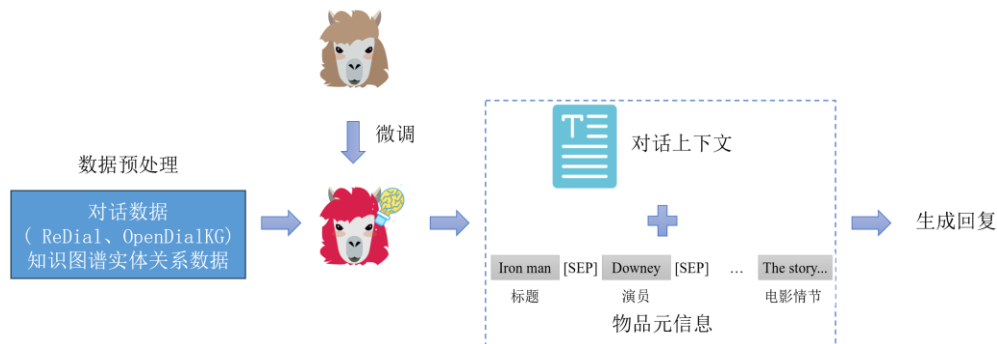


图 3.2 LLaCRS 算法流程概述

3.3 面向对话推荐的大语言模型微调方法

3.3.1 大语言模型微调概述

LLama2 在大规模数据上进行了预训练，具有强大的语言理解和生成能力。通过微调，可以将这些通用的语言能力转移到对话推荐任务上，从而提高模型在对话

推荐任务上的性能表现。之前比较流行的微调方法有提示微调，但为了提升模型的泛化能力和通用能力，诞生了新范式指令微调（Instruction Tuning）^[37]。提示微调侧重于刺激模型的补全能力，指令微调则致力于提升模型的理解力，通过明确的指令来引导模型做出恰当的反应。为了让模型具有更好的指令执行能力从而提高其在对话推荐任务上的表现能力，在本文中我们选用指令微调方法。

由于大语言模型的参数量巨大，进行全参数微调需要较多的算力资源开销，因此我们采用低秩自适应方法，针对 LLaMa2 进行了参数高效微调（Parameter-efficient Fine-tuning, PEFT），在减少需要训练的模型参数量的同时保证微调后的模型性能能够与全量微调的表现相媲美。LLaCRS 微调的框架如图 3.3 所示：




图 3.3 LLaCRS 微调框架

3.3.2 面向对话推荐的指令微调

指令微调是一种用于微调大语言模型的关键技术，其包括四个步骤。第 1 步：定义一个任务并使用自然语言阐明“任务指导”，通常包括对任务的清晰定义以及解决它的具体解决方案。第 2 步：在自然语言中制定并构建任务的输入和输出，分别表示为“任务输入”和“任务输出”。第 3 步：将“任务指导”和“任务输入”整合在一起，形成“指导输入”，并将“任务输出”作为相应的“指导输出”。第 4 步：基于格式化的“指导输入”和“指导输出”对大语言模型进行指导调整。

对于 LLaCRS 指令微调，我们首先设计一个指令模板 P ，然后结合每一条数据的对话历史 C 作为“指导输入”，并将该样本的回复 R 作为“指导输出”，数据为字典格式，具体示例如表 3.3 所示：

表 3.3 数据示例

键	值
Instruction	You are a recommender assistant chatting with the user to provide recommendation. The input is the history of your previous chat with the user, and now you need to generate a response based on the previous chat.\n You must follow the instructions below during chat.\n If you do not have enough information about user preference, you should ask the user for his preference.\n If you have enough information about user preference, You should make an explainable recommendation.\n
Input	assistant: Hello\n user: hey!\n assistant: What genre of movies do you like?\n user: i like funny movies. how about you\n assistant: I like action movies but also like comedy, so let me recommend you a movie have you seen Borat (2006) ?\n user: that is a good one! have you seen Wedding Crashers (2005)\n assistant: I have, and its one of my favorites!, \n user: its a good one as wekk"
Output	Ave you seen ted (2012) and ted 2 (2015) ? those are also pretty good ones you should watch them or maybe deadpool (2016)

其中 Instruction 为指令模板 P ，Input 为对话历史 C ，Output 为回复 R 。我们使用的数据集包括 ReDial 数据集和 OpenDialKG 数据集，在指令微调时我们使用因果语言建模，因果语言建模表示模型被训练用于生成文本，每个时间点上的输出仅依赖于之前的输出和输入，不依赖于后续的输出。形式上：

$$\max_{\Phi} \sum_{(x, y) \in Z} \sum_{t=1}^{|y|} \log(P_{\Phi}(y_t | x, y_{<t})) \quad (3.1)$$

其中 x 和 y 表示“指导输入”和“指导输出”， y_t 是 y 的第 t 个词元， $y_{<t}$ 表示 y_t 之前的词元， Φ 表示模型参数， Z 表示训练集。

3.3.3 基于低秩自适应的参数高效微调

对大语言模型进行全参数微调需要较多的算力资源开销，具体而言，在训练和推理过程中，显存占用主要由模型状态和残余状态组成，模型状态包括的模型参数、模型梯度和优化器参数，这些是必须的。残余状态包括激活、临时缓冲区和无法使用的碎片内存，这些是非必须的。在现有的大模型训练方案中，通常会采用混合精度训练。假设模型参数大小为 Φ ，模型参数和模型梯度通常以 16 位浮点数存储，

而 Adam 或 AdamW 优化器则需要额外存储 32 位浮点数的模型参数、动量参数以及动量二阶矩参数。基于上述定义，显存占用情况分析如下：

由于一个 16 位浮点数需要 2 字节，一个 32 位浮点数需要 4 字节，因此模型参数和梯度各需要 2Φ 字节的显存，Adam 优化器的模型参数、动量参数以及动量二阶矩参数则各需要 4Φ 字节的显存，因此训练过程共需要约 $2\Phi * 2 + 4\Phi * 3 + c = 16\Phi + c$ 字节的显存，推理过程需要约 $4\Phi + c_{max}$ 字节的显存， c 和 c_{max} 近似为最大序列长度（max_seq_length）和批处理大小（batch size）。以刚刚达到涌现能力边界的 7B 模型为例，由于 1GB 约等于 10^9 字节，也就是 1 billion 字节，所以微调 7B 模型需要大于 100G 的显存，至少需要 2 张 A100（80G）的显卡才能满足需求。

为了提高训练速度减少显存消耗，我们采用参数高效微调（Parameter-efficient Fine-tuning, PEFT）策略。大语言模型虽然参数众多，但关键信息主要分布在较低的维度空间。基于此，我们可以通过优化模型的一小部分参数来达到与整体模型相媲美的性能水平。具体实施中，我们运用了低秩自适应低秩自适应（Low-Rank Adaptation, LoRA）^[38]方法，LoRA 通过调整预先训练模型中的可训练矩阵的秩分解，以实现参数的高效利用，如图 3.4 所示。




图 3.4 LoRA 微调示意图

具体地，给定一个参数矩阵 W ，其更新过程可以一般性地表示为以下形式：

$$W = W_0 + \Delta W \quad (3.2)$$

其中 $W_0 \in \mathbb{R}^{H \times H}$ 是预训练的权重参数矩阵， ΔW 是更新的梯度矩阵。LoRA 的思想是在训练过程中冻结原始矩阵 W_0 ，通过低秩分解 $A \in \mathbb{R}^{H \times R}$ 和 $B \in \mathbb{R}^{H \times R}$ 来近似参数更新矩阵 $\Delta W = A \cdot B^T$ ，其中 $R \ll H$ 是减小后的秩。在微调期间 W_0 不会更新，通过

更新低秩分解矩阵 A 、 B 来适配下游任务。在前向传播过程中原始计算中间状态 $\hat{h} = W_0 \cdot x$ 修改为：

$$\hat{h} = W_0 \cdot x + A \cdot B^T \cdot x \quad (3.3)$$

在训练完成后，进一步将原始参数矩阵 W_0 和训练得到的权重 A 、 B 进行合并： $W = W_0 + A \cdot B^T$ ，得到更新后的参数矩阵。因此，通过优化秩分解矩阵，我们可以在保持原始参数冻结状态的同时，高效地纳入补充信息。最终的学习目标可以计算为：

$$\max_{\Phi} \sum_{(x, y) \in Z} \sum_{t=1}^{|y|} \log(P_{\Phi + \Phi_{LoRA}}(y_t | x, y_{<t})) \quad (3.4)$$

其中， Φ_{LoRA} 是LoRA训练所需要的参数量，我们在训练过程中仅更新LoRA参数。

对于LoRA所需要的显存估计，我们主要考虑模型参数与优化器的显存占用，其他显存占用部分与前述几乎一致且占比较小，因此在此忽略。LoRA参数大小为 Φ_{LoRA} ，模型参数大小为 Φ ，则LoRA微调需要保存的模型参数量为 $2\Phi + 2\Phi_{LoRA}$ ，梯度和优化器参数总计 $2\Phi_{LoRA} + 4\Phi_{LoRA} * 3 = 14\Phi_{LoRA}$ ，因此LoRA微调需要的显存大小从全量微调的 16Φ 大幅减小到 $2\Phi + 16\Phi_{LoRA}$ 。一般来说LoRA主要被应用在模型中每个多头注意力层的4个线性变换矩阵上（即 $W^Q, W^K, W^V, W^O \in \mathbb{R}^{H \times H}$ ），因此 $\Phi_{LoRA} = 4 \cdot 2 \cdot L \cdot HR$ ， L 、 H 、 R 分别是模型层数、中间状态维度和秩。以LLama-7B（ $L = 32, H = 4096$ ）为例，常见的秩 R 设置为8，则 $\Phi_{LoRA} = 8, 388, 608$ ， $2\Phi + 16\Phi_{LoRA} = 13, 611, 048, 960 = 14G$ ，可以看到模型微调所需要的显存从大于100G大幅下降到14G，能够有效减少微调模型所需要的硬件资源。

3.4 基于上下文感知物品元信息的推荐方法

3.4.1 上下文感知元信息推荐概述

LLama2是在大规模数据上进行训练的，而这些数据可能无法完全捕捉到个体用户的特定偏好和习惯，尽管模型在整体上表现良好，但缺乏个性化信息会导致推荐的不准确性，同时因其没有专门针对推荐任务做优化，其更倾向于生成超出物品集范围的推荐。

先前的工作采用了带有外部知识图谱的图神经网络来建模单个推荐项，并通过注意力机制将知识图谱与语言模型整合起来，用于响应生成。尽管先前的方法已经被证明是有效的，但仍有改进的空间。例如，基于知识图谱的方法仅依赖于实体关系来推荐项目，并忽视了对话上下文中的信息。

自然语言处理模型有两个代表，除了大语言模型，还有词嵌入模型（Embedding Model），前者聚焦文本空间，后者聚焦向量空间。词嵌入模型的主要作用是将文本转化为词嵌入。以前的词嵌入模型只擅长做某一特定任务，而 OpenAI 提出的词嵌入模型^[39]首次满足了通用特性（即用一个模型，支持所有的词嵌入使用场景，包括但不限于：检索、重排、聚类、分类、匹配等任务）。最近，北京智源人工智能研究院提出了新的词嵌入模型 BGE 并且已开源，相比于其他的词嵌入模型，在基准测试（benchmark）上显示，BGE 在检索任务（Retrieval Task）和语义文本相似度任务（Semantic Textual Similarity Task, STS）上至少提升了 5 个百分点。

在以上动机驱使下，我们提出了一种基于上下文感知物品元信息的推荐方法来改进下游推荐任务。首先通过 BGE 模型获取数据库中物品元数据的文本嵌入，然后获取大语言模型生成的回复（即 LLaCRS 生成的第 $T + 1$ 轮对话）和原始对话组成对话上下文，并将其编码为与物品元数据维度相同的文本嵌入，最后计算二者之间的文本相似度并从高到低排序，将与对话文本相似度最高的物品推荐给用户。

我们认为物品元数据与用户对话上下文之间的文本相似度能够有效地衡量物品与用户当前兴趣的相关程度，例如，在电影推荐设置中，当用户搜索喜剧电影时，对话上下文中可能存在诸如“搞笑、喜剧等”这样的词。在喜剧电影的简介中，这样的关键词也很可能存在。具体框架如图 3.5 所示：




图 3.5 基于上下文感知的物品元信息推荐框架

3.4.2 物品元信息抽取

我们使用 BGE 模型将每个物品的元信息直接映射到嵌入向量中。例如在电影对话推荐任务中，标题、类型、导演、情节等描述被收集为元信息，并与每部电影的"[SEP]"标记连接在一起。这个连接的信息是输入到 BGE 模型的输入，它为每个物品生成一个嵌入表示。

BGE 模型的卓越性能源于高效的预训练，其采用了针对表征的预训练算法 RetroMAE^[40]，RetroMAE 采用一种巧妙的方式提高了词嵌入的表征能力，如图 3.6 所示，具体操作是：将低掩码率的文本 A 输入到编码器种得到词嵌入向量，将该词嵌入向量与高掩码率的文本 A 输入到浅层的解码器向量中，输出完整文本。这种预训练方式迫使编码器生成强大的词嵌入向量，在表征模型中提升效果显著。




图 3.6 RetroMAE 算法

RetroMAE 提出的 MAE 形式的方法简单并且高效，其中带噪文本被编码为其嵌入，从而在一个轻量级解码器的顶部恢复干净文本，其目标函数如下：

$$\min \sum_{x \in X} -\log \text{Dec}(x|e_{\tilde{x}}), e_{\tilde{x}} \leftarrow \text{Enc}(\tilde{x}) \quad (3.5)$$

Enc, Dec 表示编码和解码操作， X , $\tilde{X}$ 表示干净和带噪的文本。

BGE 模型有 3 个不同大小的版本，其中 small 版参数量为 24M、base 版参数量为 102M、large 版参数量为 326M。本文中我们选用 bge-base-en 模型。形式上，对于物品集 I 的每一个物品 I_t ，通过添加项目元信息获得物品表示 $\tilde{I}_t$ ，然后通过 BGE 模型获得词嵌入向量表示 $\tilde{I}_t^{embed}$ 。

3.4.3 上下文感知推荐

我们采用计算对话上下文与物品元信息之间嵌入向量的相似性来实现推荐任务。首先需要获取对话上下文的嵌入向量，对于过去 T 轮的对话上下文 C ，我们先对每一轮对话 $C_t = \{s_t^{user}, s_t^{system}\} (t \in [1, T])$ 添加特殊标记来表示用户和系统，具体来说，在用户对话 s_t^{user} 前加上字符串 “[User]” 得到 $\tilde{s}_t^{user}$ ，在系统对话 s_t^{system} 前加上字符串 “[Assistant]” 得到 $\tilde{s}_t^{system}$ ，然后将添加特殊标记的用户对话和系统对话按照顺序拼接起来得到 $\tilde{C}_t = \tilde{s}_t^{user}, \tilde{s}_t^{system} (t \in [1, T])$ ，最后使用 BGM 模型来获取添加了特殊标记的对话上下文的文本嵌入 $\tilde{C}_t^{embed}$ 。

我们采用余弦相似性度量算法来计算 $\tilde{I}_t^{embed}$ 和 $\tilde{C}_t^{embed}$ 之间的相似度分数 $Score$ ，然后根据相似度分数进行排名。余弦相似度计算公式如下：

$$Score = \frac{\tilde{I}_t^{embed} \cdot \tilde{C}_t^{embed}}{\|\tilde{I}_t^{embed}\| \times \|\tilde{C}_t^{embed}\|} \quad (3.6)$$

其中 $Score$ 值越高表示两个词嵌入向量之间的相似度越高，那么对应的物品也就更有可能推荐给用户。

3.5 实验结果与分析

3.5.1 实验设置与结果展示

在 LLaCRS 微调阶段，我们使用 WanDB 来跟踪训练过程，所用设备为一张 RTX3090 (24G) 显卡，batch_size 设置为 128，max_length 设置为 256，epoch 设置为 3。




图 3.7 微调过程

从图 3.7 可以看到，微调阶段共耗时约 8.5 小时，GPU 的功耗使用率（Process GPU Power Usage (%)）保持在 47.71%到 99.27%之间波动。这表明 GPU 在整个微调过程中都处于相对较高的工作状态。同时训练损失在微调过程中逐渐降低，从初始值 2.7583 逐渐降到了约 0.5595。这表明模型在微调阶段不断地学习和优化，对数据的拟合效果逐渐提高。

表 3.4 验证损失

Epoch	Eval_loss
1	0.6557
2	0.5803
3	0.5760

从表 3.4 我们可以发现验证损失在每个 epoch 中都有所降低，从第一个 epoch 的 0.6557 降低到第三个 epoch 的 0.5760。这表明模型在验证集上的性能逐渐提高，验证集上的损失也在不断减小，说明模型在微调过程中确实在学习到更好的表示。

经过前述过程我们得到了 LLaCRS 模型，接下来我们先在传统的评估方法上进行实验。鉴于 LLama2 在对话中已经展现出了强大的能力（Touvron 等人^[41]），我们将主要对 LLaCRS 在推荐子任务中的表现进行评估，并与一些代表性的方法进行了比较分析：

- （1）KBRD：引入 DBpedia 知识图谱来丰富对话中提到的实体的语义理解。
- （2）KGSF：结合两个知识库，提升词汇和实体的语义表达能力，并运用互信息最大化技术协调这两个不同的语义维度。
- （3）CRFR：在知识图谱上进行灵活的片段推理，以解决其固有的不完整性。
- （4）BARCOR^[42]：提出基于 BART 的统一对话推荐模型，使用单一模型处理对话推荐任务。
- （5）UniCRS：为 DialoGPT 设计了与知识图谱相关的提示，以统一的方法处理对话推荐任务。

我们遵循 2023 年 Zhang 等人^[43]和 2022 年 Zhou 等人^[44]的现有工作，采用召回率（Recall@k）来评估推荐子任务，Recall@k 评估的是系统在 k 个推荐结果中找回了多少个真正相关的项目。具体来说，我们设置 k=1, 10, 50，遵循 Zhang 等人的 ReDial 数据集设置，以及设置 k=1, 10, 25，遵循 Zhou 等人的 OpenDialKG

数据集设置。由于 LLama2 有时会拒绝一次性要求太多项目，因此我们只评估其 Recall@1 和 Recall@10。我们将模型放置在 CUDA 设备上，具体设备为 RTX 3090，显存为 24G。实验结果如表 3.5 所示：

表 3.5 基于传统评估方法的实验结果

Datasets		ReDial			OpenDialKG	
Models	Recall	Recall	Recall	Recall	Recall	Recall
	@1	@10	@50	@1	@10	@25
KBRD	0.028	0.169	0.366	0.231	0.423	0.492
KGSF	0.039	0.183	0.378	0.119	0.436	0.523
CRFR	0.040	0.202	0.399	0.130	0.458	0.543
BARCOR	0.031	0.170	0.372	0.312	0.453	0.510
UniCRS	0.050	0.215	0.413	0.308	0.513	0.574
LLama2	0.032	0.171	-	0.103	0.262	-
LLaCRS	0.034	0.181	-	0.269	0.492	-

可以发现，Llama2 的表现不尽人意，且基于大模型的 LLaCRS 算法的表现并未达到预期，其与基线模型相比只能达到平均水平，并且远远落后于目前最先进的方法，但相比于 LLama2 性能得到了提高，这表明模型微调与下游推荐任务的改进是有效的。

3.5.2 大语言模型表现未达预期原因探讨

在这部分中，我们将分析 LLaCRS 推荐准确性未达到预期的原因。通过检查不正确的推荐，并结合 Wang 等人^[45]和 Li 等人^[46]的工作，我们找到了 LLaCRS 推荐准确性不佳的主要原因：

（1）缺乏明确的用户偏好。在这一类中，示例通常具有非常短的对话轮次，在这些轮次中，对话推荐系统可能无法收集足够的证据来准确推断用户的意图。此外，这些对话主要以闲聊形式收集，很难反映真实的用户偏好。例如图 3.8 中提供的示例，用户没有提供任何关于期望物品的明确信息，这也是 Wang 等人观察到的常见现象。

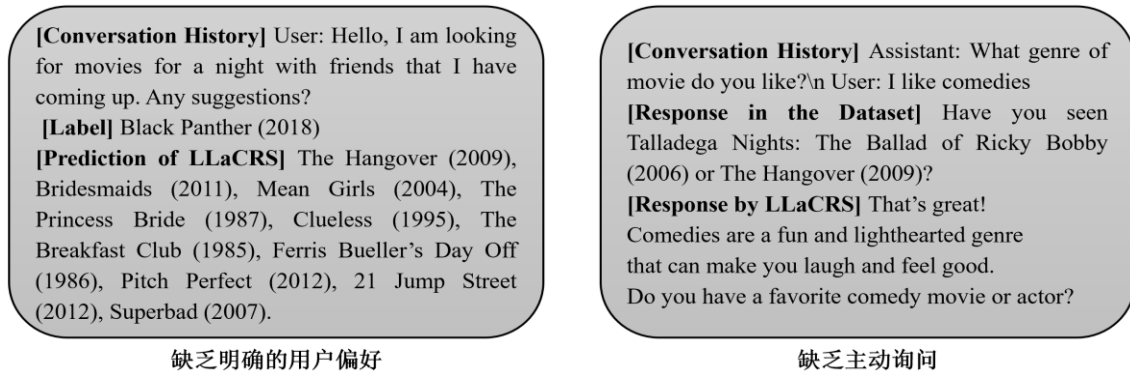


图 3.8 LLaCRS 推荐准确性不佳原因

(2) 缺乏主动询问。传统评估方法中的一个主要限制是必须严格遵循现有的对话流程。然而，在实际情况下，当需要时对话推荐系统会提出主动询问，而这在现有的评估方法中是不受支持的。从图 3.8 中提供的示例可以看到在数据集中的回复直接给出了推荐，而 LLaCRS 则要求详细说明用户的偏好。由于当前的需求很多项目都符合，因此在进行推荐之前进行询问是合理的。然而，在传统的评估方法中，这种情况无法很好地处理，因为在此过程中没有更多的用户回复可用。

通过上述分析，我们发现当前的评估方法并不能很好地评估对话推荐任务，其过分强调基于对话上下文的真实项目匹配以及语言模板的匹配。由于大多数对话推荐数据集都是以闲聊方式创建的，这些对话通常对用户偏好模糊，很难完全匹配到真相项目。此外，当前的评估方法基于固定的对话，没有考虑到对话式推荐的交互性质。Qin 等人^[47]和 Bang 等人^[48]也在文本生成任务上讨论过类似的问题，其认为传统的指标（例如 BLEU 和 ROUGE）可能无法反映大语言模型的真实能力。

3.6 本章小结

本章阐述了基于大语言模型的对话推荐算法 LLaCRS。文章首先概述了对话推荐的基本概念和在 ReDial 和 OpenDialKG 数据集上的预处理步骤。随后提出了 LLaCRS 对话推荐算法，该算法通过指令微调和低秩自适应参数高效微调，提升了 LLaMA2 模型在对话推荐任务中的适应能力。本文还利用上下文感知的物品元信息推荐方法，以解决推荐中利用对话上下文信息不足和推荐超出物品集的问题。最后，文章分析了 LLaCRS 推荐性能未达预期的原因，并指出改进评估方法是提升对话推荐系统性能的关键，这为下一章的展开奠定了基础。

第 4 章 基于用户模拟器的对话推荐评估方法

在对话推荐系统的研究中，评估模型的性能是一个复杂且关键的任务。传统方法受限于静态、预定义的评估模板，无法全面捕捉系统与真实用户互动的表现，忽略了对话推荐任务的交互性质。为克服这些限制，本文提出了一种新颖的评估框架 UEval。UEval 基于用户模拟器与系统进行动态交互，通过大语言模型创建模拟用户，这些用户能够基于目标项目属性与系统进行多轮对话从而全面评估系统性能。

4.1 基于用户模拟器的对话推荐评估方法概述

在章节 3.5.2 中，我们详细讨论了现有评估方法存在的问题。针对这些问题，我们提出了一种基于用户模拟器的对话推荐评估方法 UEval，其基于大语言模型创建的用户模拟器来与模型进行多轮交互从而评估模型性能。在评估过程中我们设计了两种交互形式，分别是基于属性的问答和基于自由形式的闲聊，并且我们还通过基于大语言模型的评分器评估了对话推荐模型的可解释性。UEval 评估方法的基本思想是使用大语言模型出色的角色扮演能力进行接近真实用户的模拟，将目标项目作为用户的属性偏好从而指导该大语言模型扮演的模拟用户角色。UEval 具体框架如图 4.1 所示。




图 4.1 UEval 框架

4.2 对话推荐评估过程交互形式设计

在 UEval 评估过程中，我们将对话推荐任务的交互分为两个主要类别：基于属性的问答和基于自由形式的闲聊。在每个轮次中，系统要么提出一个推荐，要么开始一个新的对话轮次，这个过程会持续到用户接受了推荐的项目或终止了对话。对于每一种类别的交互我们都采用零样本提示方法激发模型的潜力。

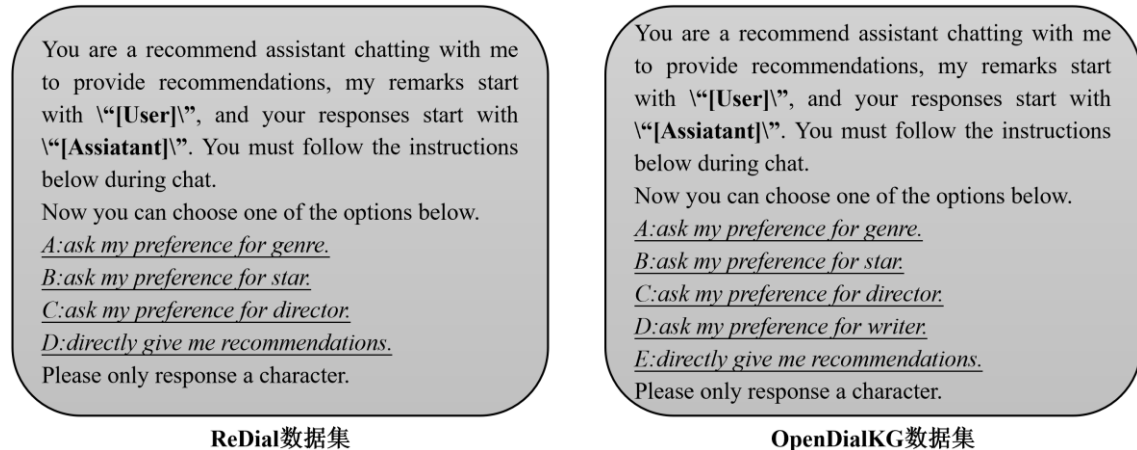
形式上，将模型 LLaCRS 记为 M ，任务是给定一个对话历史 C 和一个提示 P 来生成符合任务要求的文本。我们可以用 $M(x)$ 来表示预训练模型 M 对于输入 x 的输出，其中 x 可以是一段文本或一组文本。提示 P 是一个不包含样本示例结构化的文本模板，对话历史 C 则表示对话上下文。则对话推荐任务可以描述为：

$$R = M(C, P) \quad (4.1)$$

零样本提示的方法非常灵活和通用，因为它仅通过使用预定义提示来帮助模型进行推理和生成输出。接下来将分别介绍基于属性的问答和基于自由形式的闲聊的零样本提示设计。

4.2.1 基于属性的问答

在基于属性的问答评估中，对话推荐系统的行为受限于选择 k 个预定义属性中的一个来问用户或进行推荐。在每一轮中，我们首先让系统决定这 $k + 1$ 个选项（包括推荐），然后用户给出基于模板的响应：用目标项目的属性回答问题或对推荐给予反馈。我们的零样本提示设计如图 4.2 所示：



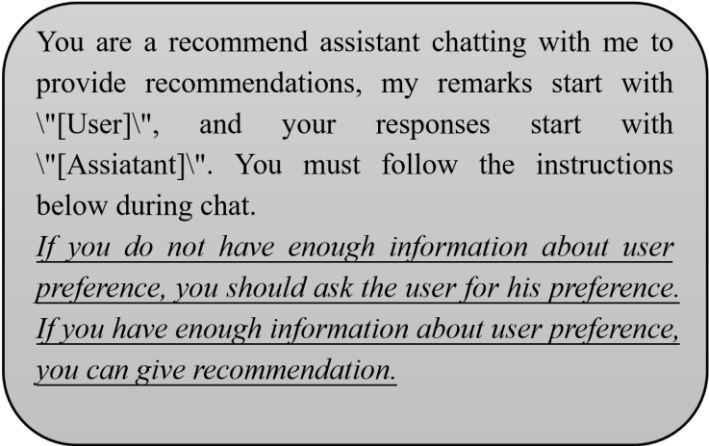
ReDial数据集

OpenDialKG数据集

图 4.2 基于属性的问答零样本提示设计

4.2.2 基于自由形式的闲聊

在基于自由形式的闲聊中，对交互没有任何限制，系统和用户都可以采取主动。示例交互可能是：“[Assistant]: Do you have any specific genre in mind? [User]: I’m looking for something action-packed with a lot of special effects.”。我们的零样本提示设计见图 4.3：



You are a recommend assistant chatting with me to provide recommendations, my remarks start with \"[User]\", and your responses start with \"[Assiatant]\". You must follow the instructions below during chat.

If you do not have enough information about user preference, you should ask the user for his preference.

If you have enough information about user preference, you can give recommendation.

图 4.3 基于自由形式的闲聊零样本提示设计

4.3 用户模拟器设计

UEval 用户模拟器的设计核心在于模拟真实用户与系统的交互过程。这一过程包括模拟用户表达自己的偏好、对系统推荐的内容进行反馈以及在合适的时候结束对话。具体而言在交互过程中模拟用户可以采取以下三种行为之一：

（1）谈论偏好。当系统对用户偏好进行澄清或征求意见时，模拟用户会以目标项目的信息进行回应。这种行为旨在模拟实际交互中用户对自己偏好项目的表达，帮助系统更准确地了解用户需求。

（2）提供反馈。当系统推荐一个项目列表时，模拟用户会检查每个项目，并在找到目标项目时提供积极的反馈（例如表示喜欢或满意），如果未找到目标项目，则提供负面的反馈（例如表示不喜欢或不满意）。此行为模拟了用户在实际推荐系统中对推荐结果的反应，便于评估系统推荐的准确性和用户满意度。

(3) 完成对话。如果系统推荐了目标项目或者交互达到一定数量的轮次（设置为 5 轮），模拟用户会结束对话。这个行为反映了现实中用户在找到满意的推荐后或者在多轮无效交互后会停止使用系统的情形。

具体来说，我们使用现有数据集中的真实标签构建模拟用户，选用 Llama2 作为 UEval 用户模拟器的基础模型，通过手动提示工程设置其行为，我们将真实标签的相关属性嵌入到提示中，使得 UEval 用户模拟器与模型进行交互。交互轮次的最大数量设置为 5。具体提示设置见图 4.4：

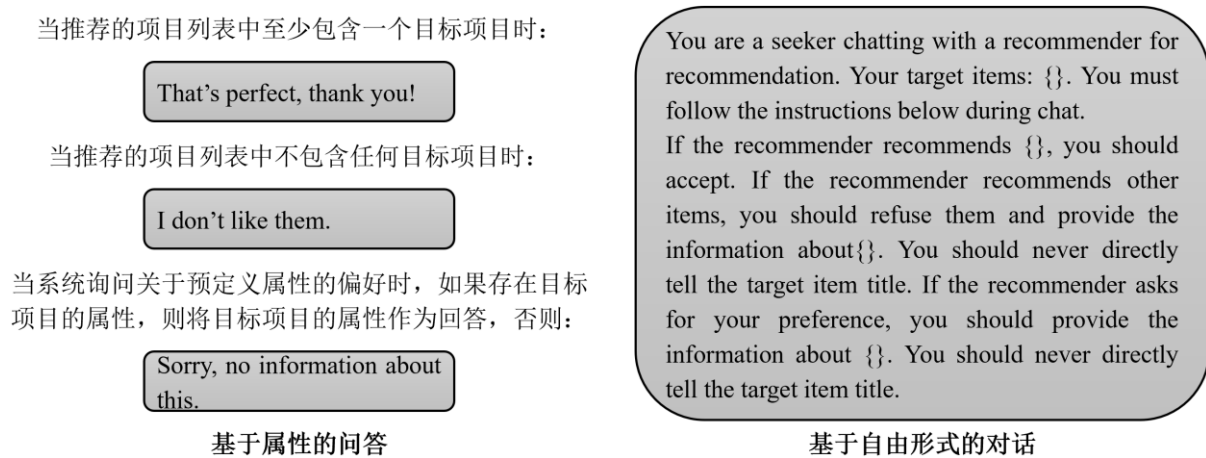


图 4.4 UEval 用户模拟器提示设计

4.4 实验结果与分析

在对话推荐算法的评估方面我们考虑客观和主观指标来衡量对话推荐模型的推荐性能以及可解释性。对于客观指标，我们使用召回率（Recall@k）来评估交互过程的推荐结果。对于主观指标，我们根据 Chen 等人的做法^[49]，采用“说服力”来评估对话推荐模型的可解释性，该指标的取值为{0, 1, 2}，目的是判断用户是否能被说服去接受推荐结果。

4.4.1 模型推荐性能评估

在对话推荐性能评估中，考虑到大模型的资源消耗问题，我们仅选择了 KBRD 和 UniCRS 作为基线模型，并比较了传统评估方法与 UEval 评估方法的表现，选用召回率作为评估指标。实验结果如表 4.1、4.2 所示（R 表示 Recall）：

表 4.1 ReDial 数据集实验结果

		KBRD		UniCRS			LLaCRS		
	传统 方法	UEval (属性)	UEval (闲聊)	传统 方法	UEval (属性)	UEval (闲聊)	传统 方法	UEval (属性)	UEval (闲聊)
R@1	0.028	0.035	0.033	0.050	0.052	0.103	0.034	0.190	0.143
		+25.0%	+17.9%		+4.0%	+106.0%		+458.8%	+320.6%
R@10	0.169	0.191	0.195	0.215	0.233	0.313	0.181	0.533	0.437
		+13.0%	+15.4%		+8.4%	+45.6%		+194.5%	+141.4%
R@50	0.366	0.433	0.451	0.413	0.517	0.601	-	-	-
		+18.3%	+23.2%		+25.2%	+45.5%			

表 4.2 OpenDialKG 数据集实验结果

		KBRD		UniCRS			LLaCRS		
	传统 方法	UEval (属性)	UEval (闲聊)	传统 方法	UEval (属性)	UEval (闲聊)	传统 方法	UEval (属性)	UEval (闲聊)
R@1	0.231	0.127	0.233	0.308	0.179	0.310	0.269	0.297	0.396
		-45.0%	+0.9%		-41.9%	+0.6%		+10.4%	+47.2%
R@10	0.423	0.291	0.427	0.513	0.391	0.535	0.492	0.601	0.711
		-31.2%	+0.9%		-23.8%	+4.3%		+22.2%	+44.5%
R@25	0.492	0.375	0.506	0.574	0.456	0.606	-	-	-
		-23.8%	+2.8%		-20.6%	+5.6%			

从表中可以看出，在 ReDial 数据集上，各个模型在 UEval 评估方法下召回率指标都有所上升，UniCRS 模型在基于自由形式的闲聊交互形式设置下 Recall@1 甚至增长了+106.0%，可以看出 UEval 评估方法具备激发模型潜力的能力。同时 LLaCRS 在基于属性的问答交互形式设置下 Recall@1 和 Recall@10 达到了 0.190 和 0.533，超越了 UniCRS 模型，甚至超过了其他模型的 Recall@50，这表明了 LLaCRS 在推荐质量和用户体验方面的显著提升。模型性能 LLaCRS 大于 UniCRS 大于 KBRD，LLaCRS 和 UniCRS 都引入了预训练语言模型，可以发现基于预训练语言模型的对话推荐算法在理解用户偏好和提供高质量推荐方面更具优势。

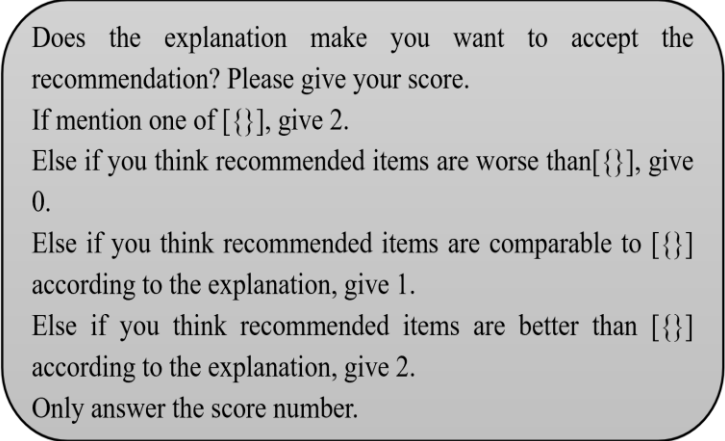
值得注意的是，在 OpenDialKG 数据集实验中，KBRD、UniCRS 在基于属性的问答设置中的表现远远不及在传统评估方法设置下的表现，具体原因可能是 OpenDialKG 数据集的主要焦点是知识图谱的构建和问答，因此可能没有那么多关于用户偏好和推荐反馈的信息，与基于属性的问答设置不一致，因此当模型应用于

基于属性的问答交互形式时，它可能没有足够的训练经验来有效地提取和利用属性信息，从而导致模型无法很好地利用基于属性的问答设置中的上下文信息。相比之下，LLaCRS 在这两个数据集上的表现要好得多，因为 Llama2-chat 经过了专门的对话数据训练，这也体现出来大预言模型的潜力。

我们的结果表明了传统评估的局限性，它只关注单一对话情景，而 UEval 评估方法允许对对话推荐模型进行更全面的评估，同时也证明了我们提出的 LLaCRS 算法的有效性。

4.4.2 模型可解释性评估

为减少人工需求，我们提出了一种基于大语言模型的说服力评分器来评估模型生成结果的可解释性，其可以通过提示自动给出分数。具体来说，在模型进行最后的推荐后，我们给出提示让模型对其推荐进行解释，然后评分器基于该解释打分，分数越高则认为模型在对话推荐任务上生成回复时的可解释性越强。本文中使用 Meta 提供的 LLaMa2 模型作为评分器，将历史对话、对话推荐模型生成的解释和评分规则连接为提示，其他参数与模拟用户相同。具体提示设计如图 4.5 所示：



Does the explanation make you want to accept the recommendation? Please give your score.
If mention one of [{}], give 2.
Else if you think recommended items are worse than [{}], give 0.
Else if you think recommended items are comparable to [{}] according to the explanation, give 1.
Else if you think recommended items are better than [{}] according to the explanation, give 2.
Only answer the score number.

图 4.5 说服力评分器提示设计

之后我们在两个数据集上评估了各个模型的说服力表现。由于基于属性的问答在对话可解释性方面有着直观的优势，因此我们仅评估基于自由形式的闲聊交互形式下的说服力表现，具体结果如表 4.3 所示：

表 4.3 说服力实验结果

模型	评估策略	ReDial	OpenDialKG
KBRD	传统方法	0.638	0.824
	UEval(闲聊)	0.763	0.860
		+19.6%	+4.4%
UniCRS	传统方法	0.685	1.128
	UEval(闲聊)	1.011	1.312
		+47.6%	+16.3%
LLaCRS	传统方法	0.779	1.215
	UEval(闲聊)	1.329	1.508
		+70.6%	+24.1%

可以看出所有模型在 UEval 评估策略下的说服力得分均高于传统评估策略，特别是 LLaCRS 在两个数据集上的得分均显著高于其他模型，这表明其在对话推荐任务中生成回复的可解释性优于其他模型。同时也证明了 UEval 评估方法在可解释性评估方面较传统方法更具优势，特别是在基于大语言模型的对话推荐系统中。这种方法不仅可以更好地评估模型的综合性能，还揭示了现有模型在不同交互类型下的优势和劣势，为进一步改进和优化对话推荐系统提供了有价值的参考。

4.5 本章小结

本章介绍了基于用户模拟器的 UEval 对话推荐评估方法，UEval 利用大语言模型创建模拟用户与系统进行动态交互。UEval 不仅关注推荐准确性，还评估模型推荐的可解释性。本文设计了基于属性的问答和基于自由形式的闲聊两种交互形式，并利用零样本提示方法激发模型潜力。通过使用大语言模型模拟用户行为，本文实现了接近真实用户的评估。在实验结果分析中，我们发现 UEval 评估方法相比传统方法在推荐性能和可解释性评估上具有明显优势，尤其是 LLaCRS 模型在两个数据集上的表现突出，表明了其在对话推荐任务中的有效性。UEval 评估方法为对话推荐系统的综合性能评估提供了更全面的视角。

第 5 章 基于大模型的对话推荐系统设计与实现

在第三章介绍了基于大语言模型的对话推荐算法 LLaCRS，并通过第四章的 UEval 评估方法证明了该算法的有效性。本章节将介绍基于 Gradio 的对话推荐系统开发，并展示系统的网页界面。

5.1 系统功能需求与可行性分析

5.1.1 系统功能需求分析

对话推荐系统旨在通过自然语言的多轮交互，帮助用户高效获取其潜在感兴趣的物品。本文基于 Llama2 实现了对话推荐算法 LLaCRS 以应对传统推荐系统在理解用户需求方面的局限性，接下来将介绍我们开发的基于大模型的对话推荐系统，系统功能需求如下：

1) 自然语言处理能力：系统需要具备强大的自然语言处理能力，能够进行多轮对话，准确理解和解析用户的查询内容和上下文信息。系统应确保对话的连续性和一致性，通过与用户的多轮交互，引导用户表达需求和兴趣。

2) 对话推荐生成能力：系统需具备根据用户的兴趣和历史记录生成个性化推荐的能力。推荐生成过程需动态调整，能够实时响应用户在对话过程中的反馈，生成的推荐结果要么是直接推荐项目，要么是进一步询问用户需求。

3) 推荐项目数据与对话数据管理能力：系统需有效管理推荐项目数据和用户对话数据。包括存储和检索推荐项目的详细信息（如电影的名称、简介、评分等）和用户的历史对话信息。系统需能够访问数据库，从中搜索推荐项目，同时保存和管理历史对话信息，以提高推荐的准确性和个性化程度。

5.1.2 系统可行性分析

1) 技术可行性

本系统依托于大语言模型 Llama2 在自然语言处理方面的强大能力。通过采用先进的微调方法 LoRA（低秩自适应）可以在减少计算资源消耗的情况下，对 LLaMA2-7b-chat 模型进行高效微调。LoRA 方法通过低秩分解实现参数改动，以极

小的参数量实现大模型的微调，显著减少了 GPU 显存的使用量和推理时间。算力部分使用 Intel(R) Core(TM) i7-12700 CPU 和 NVIDIA RTX 3090 GPU，能够支持复杂的模型计算和实时推理任务。

2) 数据可行性

我们使用 ReDial 和 OpenDialKG 数据集训练模型，同时使用 MySQL 数据库管理推荐项目的详细信息和用户的历史对话数据，确保数据的高效存储和检索。系统通过上下文感知物品元信息的推荐方法，利用 BGE 模型将物品元信息和对话数据映射到文本嵌入中进行相似度计算，从而提高推荐任务的准确性和效果。

3) 应用可行性

本系统的应用层基于 Gradio 开发，提供用户友好的网页界面，用户可以方便地通过网页端输入对话内容并获取推荐结果。LLaCRS 模型通过 OpenAI 的应用程序编程接口（Application Programming Interface, API）进行调用，实现模型与应用层的无缝连接。系统能够实时处理用户的输入，生成个性化推荐，并记录用户的历史对话信息，确保对话的连续性和推荐的准确性。

5.2 系统设计方案

5.2.1 开发环境与工具

1) 硬件环境

CPU: 12th Gen Intel(R) Core(TM) i7-12700

CPU 基本频率: 2.10 GHz

CPU 线程数量: 20 个

GPU: NVIDIA GeForce RTX 3090

硬盘: 2T

内存容量(GB): 64

显存容量(GB): 24

2) 软件环境

开发工具: PyCharm Community Edition 2023.3.5、Anaconda 24.3.0

数据库: MySQL

操作系统：Windows11、Ubuntu

开发框架：Python3.8、Pyorch、Peft、Transformers、Sklearn、OpenAI、Gradio 等集成库。

5.2.2 系统架构

本系统的架构设计包括数据层、算力层、模型层和应用层四个部分，具体框架如图 5.1 所示。




图 5.1 LLaCRS 系统架构

1) 数据层

数据层主要涉及历史对话上下文和项目相关信息存储。使用 MySQL 数据库管理系统，负责存储和管理用户的历史对话记录、推荐项目的详细信息以及系统生成的推荐结果。数据层的主要功能包括：

- (1) 历史对话上下文：存储用户历史对话信息，确保对话的连续性和一致性。
- (2) 项目相关信息：存储推荐项目详细信息，如电影的名称、简介、评分等。

（3）数据交互：与模型层交互，提供推荐所需的数据支持，并存储模型生成的推荐结果和用户反馈。

2) 算力层

算力层负责系统的计算资源配置和模型部署，CPU 为 Intel(R) Core(TM) i7-12700，GPU 为 NVIDIA RTX 3090。我们将 LLaCRS 模型部署在服务器上，通过高效的硬件配置支持模型的训练和推理任务，确保系统在多轮交互中能够快速响应用户请求。

3) 模型层

模型层采用开发的 LLaCRS 模型，负责对用户输入进行理解、处理，并生成推荐结果，同时模型层还需要访问 MySQL 数据库^[50]，获取推荐所需的项目信息，存储推荐结果和对话历史数据。

4) 应用层

应用层基于 Gradio 进行网页开发，为用户提供友好交互界面。主要功能包括：

（1）用户输入处理：用户通过网页端输入对话内容，系统将用户输入传递给模型层进行处理。

（2）系统调用：通过 OpenAI API 调用 LLaCRS 模型，处理用户输入并生成推荐回复。

（3）对话展示：展示模型生成的回复，用户可以查看推荐结果或继续对话。

5.3 系统展示

本节我们将进行系统展示，我们系统的工作流程如下：首先用户通过基于 Gradio 开发的网页输入对话内容，输入通过 OpenAI API 传递到部署在服务器上的 LLaCRS 模型。模型层负责解析用户的意图，访问 MySQL 数据库获取相关的项目信息，生成推荐结果或继续询问用户需求。LLaCRS 模型基于用户的输入和从数据库中获取的信息，生成个性化的推荐结果。生成的回复通过 OpenAI API 返回给应用层，并在网页端展示给用户。系统记录用户的历史对话信息和反馈，存储在 MySQL 数据库中，用于后续的推荐和模型优化。我们的系统界面简洁明了，直观易用，具体展示如图 5.2：




图 5.2 LLaCRS 系统展示

5.4 本章小结

本章我们详细阐述了基于大模型的对话推荐系统的设计理念及其在技术、数据和应用三个方面的可行性。首先，我们明确了系统的功能需求，并对系统的技术可行性进行了分析。然后，我们介绍了系统的开发环境与工具，以及系统架构设计，从数据层、算力层、模型层和应用层四个方面展现了系统的整体框架。最后我们展示了系统的工作流程和用户界面，突出了系统的直观易用性。

第6章 总结与展望

本章节将总结前述工作，分析所提出方法的局限性，并对未来的研究工作进行展望，包括提示策略的优化、跨领域推荐技术的探索，以及评估策略的全面性改进。

6.1 主要工作与创新点

本文主要内容为基于大语言模型的对话推荐系统设计以及基于用户模拟器的对话推荐评估方法设计，我们提出了 LLaCRS 对话推荐算法以及 UEval 对话推荐评估方法，并开发了一个对话推荐系统网页。具体来说我们的主要工作包括以下方面：

1) LLaCRS 对话推荐算法：针对大语言模型在特定对话推荐任务上表现不佳的问题，本文提出了 LLaCRS 算法。该算法以 LLama2-7b-chat 为基础，通过指令微调和 LoRA 轻量化微调，让模型适用于对话推荐任务，同时为解决模型推荐超出物品集范围和缺乏个性化信息的问题，本文提出了基于上下文感知物品元信息的推荐方法。该方法首先构建物品的元信息，以及携带 LLaCRS 生成的新一轮回复的对话上下文的文本嵌入，通过计算对话上下文与物品元信息之间的文本相似度，提供更加准确和个性化的推荐。

2) UEval 评估方法：针对现有评估方法的不足，本文提出了基于用户模拟器的对话推荐评估方法 UEval。该方法创建模拟用户与模型进行多轮互动评估，通过模拟用户的反馈评估推荐任务的准确性和模型的可解释性。在 UEval 评估过程中，设计了基于属性的问答和基于自由形式的闲聊两种交互形式，利用零样本提示方法，提升模型在不同对话场景下的响应能力。UEval 通过模拟用户的三种行为即谈论偏好、提供反馈和完成对话，来评估对话推荐系统的表现。

3) 基于 Gradio 的对话推荐系统开发：本文基于 Gradio 开发了一个对话推荐系统网页，首先将 LLaCRS 模型部署在服务器上，然后通过 OpenAI 的应用程序编程接口调用模型，实现用户与模型的交互，系统界面美观，简洁易用。

本文的创新点在于基于 LLama2 完成对话推荐任务。我们通过指令微调与 LoRA 方法提升了 Llama2 的微调效率和在对话推荐任务中的性能，并通过上下文感知物品元信息的推荐方法，提高了下游推荐任务的准确性。同时，提出了基于用

户模拟器的 UEval 评估方法，使用大模型创建模拟用户来评估对话推荐模型，为对话推荐系统的评估提供了一种新的思路和方法。

6.2 后续研究工作展望

在本文中，我们提出了 LLaCRS 对话推荐算法和基于大语言模型的 UEval 评估方法，探索了大语言模型在对话推荐任务中的应用潜力。尽管取得了一些初步成效，但仍存在一些局限性和有待进一步研究的问题。以下是对未来研究工作的展望：

1) 提示优化：目前为大语言模型和用户模拟器设计的提示是通过手动编写和选择的。尽管这种方法在一些代表性示例上表现良好，但其效率较低且可能无法涵盖所有潜在场景。未来的研究可以探索更自动化和高效的提示策略，如链式思维提示（Chain-of-Thought, CoT），以提升模型性能。此外，还需要系统地评估不同提示策略在各种对话推荐任务中的稳健性，确保提示方法的通用性和有效性。

2) 跨领域推荐：目前的推荐系统大多针对特定领域设计，如电影、音乐或电子商务等。未来的研究可以探索跨领域推荐技术，使系统能够在不同领域间进行推荐，满足用户多样化的需求。例如，通过构建统一的用户画像和偏好模型，实现从电影推荐到音乐推荐的无缝衔接，提升用户的整体体验。

3) 评估方法的全面性：本文提出的评估方法主要集中在推荐的准确性和可解释性上，但在公平性、偏见和隐私问题上关注较少，同时没有进行人工评估的对比。未来的研究应将这些方面纳入评估过程。例如，可以开发指标来量化推荐系统在不同用户群体间的公平性，评估系统在避免偏见和歧视方面的表现，并确保用户数据的隐私和安全得到有效保护。

6.3 本章小结

本章概括了本文的研究工作，包括所提出的 LLaCRS 对话推荐算法和 UEval 对话推荐评估方法，并展望了未来研究方向。未来工作将聚焦于提示策略的自动化、跨领域推荐技术的实现，以及评估方法的全面性改进，来推动对话推荐系统的发展。

参考文献

- [1] 第 53 次《中国互联网络发展状况统计报告》发布[J]. 新闻论坛, 2024, 38(2): 17.
- [2] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems: Vol. 30. Curran Associates, Inc., 2017: 6000–6010.
- [3] Li R, Ebrahimi Kahou S, Schulz H, et al. Towards deep conversational recommendations[C]//Advances in Neural Information Processing Systems: Vol. 31. Curran Associates, Inc., 2018: 9748–9758.
- [4] Devlin J, Chang M W, Lee K, et al. BERT: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers). Minneapolis, Minnesota: Association for Computational Linguistics, 2019: 4171-4186.
- [5] Radford A, Wu J, Child R, et al. Language models are unsupervised multitask learners[J]. OpenAI blog, 2019, 1(8): 9.
- [6] Penha G, Hauff C. What does bert know about books, movies and music? Probing BERT for Conversational Recommendation[C]//Proceedings of the 14th ACM Conference on Recommender Systems. New York, NY, USA: Association for Computing Machinery, 2020: 388-397.
- [7] Hayati S A, Kang D, Zhu Q, et al. INSPIRED: Toward sociable recommendation dialog systems[C]//WEBBER B, COHN T, HE Y, et al. Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP). Online: Association for Computational Linguistics, 2020: 8142-8152.
- [8] Deng Y, Zhang W, Xu W, et al. A unified multi-task learning framework for multi-goal conversational recommender systems[J]. ACM Transactions on Information Systems, 2023, 41(3): 77:1-77:25.
- [9] Chen Q, Lin J, Zhang Y, et al. Towards knowledge-based recommender dialog system[C]//Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP). Hong Kong, China: Association for Computational Linguistics, 2019: 1803-1813.

- [10] Zhou K, Zhao W X, Bian S, et al. Improving conversational recommender systems via knowledge graph based semantic fusion[C]//Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. New York, NY, USA: Association for Computing Machinery, 2020: 1006-1014.
- [11] Wang X, Zhou K, Wen J R, et al. Towards unified conversational recommender systems via knowledge-enhanced prompt learning[C]//Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. New York, NY, USA: Association for Computing Machinery, 2022: 1929-1937.
- [12] Liu Y, Ott M, Goyal N, et al. RoBERTa: A robustly optimized bert pretraining approach[J]. arXiv preprint arXiv:1907.11692, 2019.
- [13] Zhang Y, Sun S, Galley M, et al. DialoGPT : Large-scale generative pre-training for conversational response generation[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics: System Demonstrations. Online: Association for Computational Linguistics, 2020: 270-278.
- [14] Ma W, Takanobu R, Huang M. CR-WALKER: Tree-structured graph reasoning and dialog acts for conversational recommendation[C]//Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. Online and Punta Cana, Dominican Republic: Association for Computational Linguistics, 2021: 1839-1851.
- [15] Zhou J, Wang B, He R, et al. CRFR: Improving conversational recommender systems via flexible fragments reasoning on knowledge graphs[C]//Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. Online and Punta Cana, Dominican Republic: Association for Computational Linguistics, 2021: 4324-4334.
- [16] Li W, Wei W, Qu X, et al. TREA: Tree-structure reasoning schema for conversational recommendation[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Toronto, Canada: Association for Computational Linguistics, 2023: 2970-2982.
- [17] Lu Y, Bao J, Song Y, et al. Revcore: Review-augmented conversational recommendation[C]//Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021. Online: Association for Computational Linguistics, 2021: 1161-1173.

-
- [18] Yang B, Han C, Li Y, et al. Improving conversational recommendation systems' quality with context-aware item meta-information[C]//Findings of the Association for Computational Linguistics: NAACL 2022. Seattle, United States: Association for Computational Linguistics, 2022: 38-48.
- [19] Zhou Y, Zhou K, Zhao W X, et al. C2-CRS: Coarse-to-fine contrastive learning for conversational recommender system[C]//Proceedings of the Fifteenth ACM International Conference on Web Search and Data Mining. New York, NY, USA: Association for Computing Machinery, 2022: 1488-1496.
- [20] Liang Z, Hu H, Xu C, et al. Learning neural templates for recommender dialogue system[C]//Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. Online and Punta Cana, Dominican Republic: Association for Computational Linguistics, 2021: 7821-7833.
- [21] Zhou K, Zhou Y, Zhao W X, et al. Towards topic-guided conversational recommender system[C]//Proceedings of the 28th International Conference on Computational Linguistics. Barcelona, Spain (Online): International Committee on Computational Linguistics, 2020: 4128-4139.
- [22] Liao L, Takanobu R, Ma Y, et al. Topic-guided conversational recommender in multiple domains[J]. IEEE Transactions on Knowledge and Data Engineering, 2022, 34(5): 2485-2496.
- [23] Liu Z, Zhou D, Liu H, et al. Graph-grounded goal planning for conversational recommendation[J]. IEEE Transactions on Knowledge and Data Engineering, 2022: 1-1.
- [24] Li S, Xie R, Zhu Y, et al. User-centric conversational recommendation with multi-aspect user modeling[C]//Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York, NY, USA: Association for Computing Machinery, 2022: 223-233.
- [25] Zhao W X, Zhou K, Li J, et al. A survey of large language models[J]. arXiv preprint arXiv:2303.18223, 2023.
- [26] Yang J, Jin H, Tang R, et al. Harnessing the power of llms in practice: A survey on chatgpt and beyond[J]. ACM Transactions on Knowledge Discovery from Data, 2024, 18(6): 160:1-160:32.
- [27] Sun W, Yan L, Ma X, et al. Is chatgpt good at search? investigating large language models as re-ranking agents[C]//Proceedings of the 2023 Conference on Empirical

- Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023: 14918-14937.
- [28] Liu J, Liu C, Zhou P, et al. Is chatgpt a good recommender? a preliminary study[J]. arXiv preprint arXiv:2304.10149, 2023.
- [29] Gao Y, Sheng T, Xiang Y, et al. Chat-REC: Towards interactive and explainable llms-augmented recommender system[J]. arXiv preprint arXiv:2303.14524, 2023.
- [30] Friedman L, Ahuja S, Allen D, et al. Leveraging large language models in conversational recommender systems[J]. arXiv preprint arXiv:2305.07961, 2023.
- [31] Balog K, Zhai C. Tutorial on user simulation for evaluating information access systems on the web[C]//Companion Proceedings of the ACM on Web Conference 2024. New York, NY, USA: Association for Computing Machinery, 2024: 1254-1257.
- [32] Afzali J, Drzewiecki A M, Balog K, et al. Usersimcrs: A user simulation toolkit for evaluating conversational recommender systems[C]//Proceedings of the Sixteenth ACM International Conference on Web Search and Data Mining. New York, NY, USA: Association for Computing Machinery, 2023: 1160-1163.
- [33] Zhou K, Wang X, Zhou Y, et al. CRSLab: An open-source toolkit for building conversational recommender system[C]//Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing: System Demonstrations. Online: Association for Computational Linguistics, 2021: 185-193.
- [34] Sennrich R, Haddow B, Birch A. Neural machine translation of rare words with subword units[C]//Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Berlin, Germany: Association for Computational Linguistics, 2016: 1715-1725.
- [35] Kudo T. Subword regularization: improving neural network translation models with multiple subword candidates[C]//Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Melbourne, Australia: Association for Computational Linguistics, 2018: 66-75.
- [36] Moon S, Shah P, Kumar A, et al. OpenDialKG: Explainable conversational reasoning with attention-based walks over knowledge graphs[C]//Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. Florence, Italy: Association for Computational Linguistics, 2019: 845-854.

-
- [37] Zhang S, Dong L, Li X, et al. Instruction tuning for large language models: A survey[J]. arXiv preprint arXiv:2308.10792, 2023.
- [38] Hu E J, Shen Y, Wallis P, et al. LoRA: Low-rank adaptation of large language models[C]//International Conference on Learning Representations. 2021.
- [39] Neelakantan A, Xu T, Puri R, et al. Text and code embeddings by contrastive pre-training[J]. arXiv preprint arXiv:2201.10005, 2022.
- [40] Xiao S, Liu Z, Shao Y, et al. RetroMAE: Pre-training retrieval-oriented language models via masked auto-encoder[C]//Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing. Abu Dhabi, United Arab Emirates: Association for Computational Linguistics, 2022: 538-548.
- [41] Touvron H, Martin L, Stone K, et al. Llama 2: Open foundation and fine-tuned chat models[J]. arXiv preprint arXiv:2307.09288, 2023.
- [42] Wang T C, Su S Y, Chen Y N. BARCOR: Towards a unified framework for conversational recommendation systems[J]. arXiv preprint arXiv:2203.14257, 2022.
- [43] Zhang X, Xin X, Li D, et al. Variational reasoning over incomplete knowledge graphs for conversational recommendation[C]//Proceedings of the Sixteenth ACM International Conference on Web Search and Data Mining. New York, NY, USA: Association for Computing Machinery, 2023: 231-239.
- [44] Zhou J, Wang B, Huang M, et al. Aligning recommendation and conversation via dual imitation[C]//Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing. Abu Dhabi, United Arab Emirates: Association for Computational Linguistics, 2022: 549-561.
- [45] Wang X, Tang X, Zhao X, et al. Rethinking the evaluation for conversational recommendation in the era of large language models[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023: 10052-10065.
- [46] Li C, Hu H, Zhang Y, et al. A conversation is worth a thousand recommendations: a survey of holistic conversational recommender systems[J]. arXiv preprint arXiv:2309.07682, 2023.
- [47] Qin C, Zhang A, Zhang Z, et al. Is chatgpt a general-purpose natural language processing task solver?[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023: 1339-1384.

- [48] Bang Y, Cahyawijaya S, Lee N, et al. A multitask, multilingual, multimodal evaluation of chatgpt on reasoning, hallucination, and interactivity[C]//Proceedings of the 13th International Joint Conference on Natural Language Processing and the 3rd Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics (Volume 1: Long Papers). Nusa Dua, Bali: Association for Computational Linguistics, 2023: 675-718.
- [49] Chen X, Zhang Y, Wen J R. Measuring “why” in recommender systems: A comprehensive survey on the evaluation of explainable recommendation[J]. arXiv preprint arXiv:2202.06466, 2022.
- [50] 李国红. Web 数据库技术与 MySQL 应用教程[M]. 机械工业出版社: 2020: 35-63.

致谢

感谢党和国家对我的培养！

感谢父母和家人，你们永远是我坚实的后盾。

感谢我的朋友们，与我结伴同行。

感谢我的老师，感谢你们对我学业生涯的帮助。

在此我还要特别感谢我的指导老师杨燕老师。杨老师从我大二便开始带我参加各种竞赛，并指导我的国家级大学生创新创业训练计划，我也在杨老师的帮助下取得了一定的竞赛成绩，并最终成功保研到了华中科技大学。同时杨老师在我的毕业论文指导过程中尽心尽力，其逻辑思路的清晰让我耳目一新，没有老师的细心指导，倾囊相授，难成此文。

最后，感谢全体科研工作者与技术开发者，感谢你们对技术进步做出的贡献。

感激之意，穷千词而不能绘其一。

这四年最大收获，就是遇到了那些形形色色的人，他们有的让我深陷险境，有的帮我逃出泥沼，但就是这样，才让当年那个自大的我清醒了许多。毕业设计对我来说，就只是给自己的这段成长，画上个句号而已。

论文停留在致谢，人生的故事还得继续书写。我也即将开始我的研究生生涯，奔赴下一个三年之约。我并不知道未来会怎样，但无论任何事，都自会有个结果，我也永远不会停止前进的脚步。