

审定成绩:

重庆邮电大学 毕业设计（论文）

中文题目 基于 NLP 的情感分析系统的设计与实现

英文题目 Design and Implementation of NLP-based
Sentiment Analysis System

学院名称 计算机科学与技术学院/人工智能学院

学生姓名 周兴龙

专 业 数据科学与大数据技术

班 级 04082004 班

学 号 2020211522

指导教师 杨燕 讲师

答 辩 组
负 责 人 栾晓 教授

2024 年 6 月

重庆邮电大学教务处制

计算机科学与技术/人工智能学院本科毕业设计(论文)

诚信承诺书

本人郑重承诺：

我向学院呈交的论文《基于 NLP 的情感分析系统的设计与实现》，是本人在指导教师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明并致谢。本人完全意识到本声明的法律结果由本人承担。

年级 2020

专业 数据科学与大数据技术

班级 04082004

承诺人签名

年 月 日

学位论文版权使用授权书

本人完全了解重庆邮电大学有权保留、使用学位论文纸质版和电子版的规定，即学校有权向国家有关部门或机构送交论文，允许论文被查阅和借阅等。本人授权重庆邮电大学可以公布本学位论文的全部或部分内容，可编入有关数据库或信息系统进行检索、分析或评价，可以采用影印、缩印、扫描或拷贝等复制手段保存、汇编本学位论文。

（注：保密的学位论文在解密后适用本授权书。）

学生签名：

指导老师签名：

日期： 年 月 日

日期： 年 月 日

摘要

随着移动互联网的发展，网络文本数据呈现出爆炸性增长，使得传统的情感分析方法已无法满足对文本情感信息的高效精准处理的需求。为了适应互联网时代文本数据量的激增和情感分析需求的深化，本文设计并实现了一个基于自然语言处理（Natural Language Processing, NLP）的细粒度情感分析系统。利用前沿技术，构建了“BERT 预训练+”的语言模型，并依托 CCF BDCI 竞赛提供的数据集来实现这一系统。针对细粒度的情感分析任务，基于 BERT 预训练模型，构建了一种结合多任务学习理念的情感分析算法，旨在通过这种先进的技术手段，提高情感分析的准确性和效率。本文的主要工作如下：

1、上下文建模与情感分析模型搭建：考虑到剧本数据中角色情感容易受到上下文影响的特点，首先进行了上下文建模以捕捉剧本中细致的情感变化，随后构建了三种情感分析模型方案：BERT+MMOE、BERT+多头注意力机制、BERT+AT-LSTM。

2、面向模型效果提升的综合训练策略构建：探讨了不同的模型训练技巧以提高模型的泛化性和鲁棒性，包括对抗训练（Fast Gradient Method, FGM）、随机权重平均(Stochastic Weight Averaging, SWA)和学习率预热等。通过这些方法，有效提升了模型在处理剧本数据方面的性能，并利用模型融合策略进一步提高了情感分析的准确性。

3、情感分析系统的设计与实现：设计并实现了一个基于 NLP 的情感分析系统，该系统能够提供数据统计分析、角色情感识别等功能，并通过可视化技术展示剧本数据的情感分布和角色重要性。

本文的数据集来源于 CCF BDCI 的剧本角色情感识别赛题，赛题任务是对数据角色标签的六种情感分别进行情感极性分类，情感极性分别为无（0）、弱（1）、中（2）、强（3）。赛题采用的评价指标是均方根误差（RMSE），本文最终实现的模型融合方案分数为 0.7126。

关键词：情感分析，自然语言处理，预训练模型，模型融合，训练策略

Abstract

With the development of mobile Internet, network text data shows explosive growth, which makes the traditional sentiment analysis methods can no longer meet the demand for efficient and accurate processing of text sentiment information. In order to adapt to the surge in the amount of text data and the deepening of the demand for sentiment analysis in the Internet era, this thesis designs and implements a fine-grained sentiment analysis system based on Natural Language Processing (NLP). Utilizing cutting-edge technologies, we constructed a “BERT pre-training+” language model, and relied on the dataset provided by CCF BDCI competition to realize this system. For the fine-grained sentiment analysis task, a sentiment analysis algorithm combining the concept of multi-task learning is constructed based on the BERT pre-training model, aiming to improve the accuracy and efficiency of sentiment analysis by means of this advanced technology. The main work of this thesis is as follows:

1. Context modeling and sentiment analysis model construction: considering the characteristics of the script data that the characters' emotions are easily affected by the context, firstly, context modeling is carried out to capture the detailed emotional changes in the script, and then three sentiment analysis model schemes are constructed: BERT+MMOE, BERT+Multiple Heads Attention Mechanism, and BERT+AT-LSTM.

2. Construction of comprehensive training strategies oriented to model effect enhancement: Different model training techniques are explored to improve the generalization and robustness of the model, including Adversarial Training (Fast Gradient Method, FGM), Stochastic Weight Averaging (SWA), and Learning Rate Warm-up, etc. The modeling techniques used in this study are as follows: BERT+MMOE, BERT+Multiple Heads Attention Mechanism, BERT+ATLSTM, and BERT+LSTM. Through these methods, the performance of the model in handling scripted data is effectively improved, and the accuracy of the sentiment analysis is further improved by utilizing the model fusion strategy.

3. Design and implementation of the sentiment analysis system: an NLP-based sentiment analysis system is designed and implemented, which can provide functions such as statistical analysis of data, character sentiment recognition, and display the

sentiment distribution and character importance of the script data through visualization techniques.

The dataset of this thesis comes from CCF BDCI's Script Character Sentiment Recognition Contest, the task of which is to classify the six emotions labeled by the data characters with the sentiment polarity of None (0), Weak (1), Medium (2), and Strong (3), respectively. The evaluation metric used for the contest question is the root mean square error (RMSE), and the final score of the model fusion scheme implemented in This thesis is 0.7126.

Keywords: Sentiment Analysis, Natural Language Processing, Pre-trained Models, Model Fusion, Training Strategies

目录

第 1 章 引言	1
1.1 研究背景和意义	1
1.2 主要问题和研究现状	2
1.2.1 主要问题	2
1.2.2 研究现状	3
1.3 主要内容	7
1.4 本文的组织结构	8
第 2 章 相关理论与技术	9
2.1 情感分析概述	9
2.2 文本预处理	10
2.3 文本向量化	10
2.3.1 离散式表示	11
2.3.2 分布式表示	13
2.4 深度学习相关技术理论	16
2.4.1 激活函数	17
2.4.2 注意力机制	20
2.4.3 Transformer 语言模型	22
2.4.4 BERT 预训练模型的介绍	24
2.5 本章小结	26
第 3 章 基于 Bert+预训练模型的多情感分析方法	27
3.1 问题描述	27
3.1.1 数据集描述	27
3.2.2 任务描述	27
3.2.3 评价指标	28
3.2 数据预处理	28
3.2.1 数据分析	28

3.2.2 数据清洗	30
3.2.3 文本拼接	30
3.3 模型搭建	31
3.3.1 上下文建模	31
3.3.2 BERT+MMOE.....	32
3.3.3 BERT+AT-LSTM	34
3.3.4 BERT+多头注意力机制	35
3.4 模型训练	37
3.4.1 损失函数的设置	37
3.4.2 训练策略	38
3.5 实验结果与分析	42
3.5.1 模型基本参数调节	43
3.5.2 基础模型调优结果	44
3.5.3 模型训练技巧提升	44
3.5.4 模型融合	46
3.5.5 实验总结	46
3.6 本章小结	47
第 4 章 基于 NLP 的情感分析系统设计	48
4.1 可行性分析和需求分析	48
4.1.1 可行性分析	48
4.1.2 需求分析	48
4.2 系统设计	49
4.2.1 系统开发环境与工具	49
4.2.2 系统架构	49
4.3 系统展示	50
4.4 本章小结	54
第 5 章 总结与展望.....	55
5.1 工作总结	55
5.2 未来工作展望	55

参考文献.....	57
致谢.....	59

第 1 章 引言

1.1 研究背景和意义

随着互联网技术的不断发展，特别是移动互联网的迅速普及，人们的生活方式在通讯、购物、出行等方面发生了巨大变化。根据中国互联网中心^[1]于 2023 年发布的报告，截至 2023 年 8 月 23 日，中国网民规模达到了 10.79 亿，比 2022 年增长了 1109 万，互联网普及率达到了 76.4%。同时，随着互联网的发展，各种应用也相继进入人们的生活，其中，即时通信的用户规模达到了 10.76 亿。与人们生活息息相关的软件 APP：美团外卖、抖音短视频等应用也保持了急速增长，其中网上短视频的用户数量已经达到了惊人的 10.26 亿。短视频 APP 作为主要载体之一，带动了一系列直播、购物等需求，用户与平台之间主要的沟通交流方式就是通过评论。文本作为分布最广、数据量最大的信息形式，在互联网中扮演着重要角色，各类互联网应用的发展催生了大量评论文本信息的产生。

在当今数字化时代，互联网已成为人们社交互动和信息交流的主要渠道。随着社交媒体、论坛、评论区等在线平台的兴起，用户之间的交流变得更加便捷和频繁。在这样的背景下，用户产生的数据量呈现出爆炸性增长，尤其是用户的评论数据，它们不仅仅是简单的文字表达，更是用户情感、态度和偏好的直接体现。这些评论数据涵盖了对产品的评价、对服务的反馈、对事件的看法以及对各种现象的评论。每一则评论都可能包含着用户的满意、失望、愤怒、喜悦等情感色彩，它们是用户内心情感的真实写照。对于企业或平台而言，这些数据的价值不可估量。通过分析这些评论，可以洞察用户的需求，优化产品和服务，提升用户体验，从而增强用户忠诚度和满意度。此外，用户评论中的情感倾向可以转化为对市场趋势的预测。正面的情感倾向可能预示着产品的热销或服务的成功，而负面的情感倾向则可能提示潜在的问题或风险。平台可以据此调整市场策略，改进营销手段，甚至在危机公关中发挥作用。

然而，面对如此庞大的数据量，单纯依靠人工分析显然是不现实的。若仅使用传统人工的方法来处理这批数据，不仅需要耗费巨大的人力成本和大量的时间，且最后得到的效益也极大可能远远不如预期。并且，由于评论数据的庞大和

复杂性，传统的手工分析方法已经无法满足对这些数据进行有效处理和分析的需求。因此，利用前沿技术自然语言处理技术^[2]（Natural Language Processing, NLP）对用户评论数据进行情感分析成为一种重要的研究方向。

在情感分析领域中，传统的机器学习算法，如支持向量机^[3]（Support Vector Machine, SVM）和朴素贝叶斯^[4]曾经被广泛应用。然而，这些算法需要大量手工构建的特征，且在高维空间或大规模数据中应用时存在局限性，难以推广到当前数据激增的情况。相比之下，深度学习算法不需要过多的特征工程，一旦选择了适当的模型，便具备了更强大的特征提取和表示能力。随着研究人员的进展，深度学习逐渐在计算机视觉和自然语言处理等领域取代了原有的算法技术。随着 Transformer^[5]等神经网络模型的发布，特别是 BERT 等预训练语言模型的出现，极大的推动了自然语言处理在文本分析等方面的发展。所以，研究将深度学习技术应用于情感分析具有重要的现实意义。

1.2 主要问题和研究现状

1.2.1 主要问题

随着计算机技术的快速发展，情感分析已经成为了一个备受关注的研究领域。但传统的情感分析仍然存在一些问题：

1) 精细化问题

在过去，情感分析主要致力于识别文本所表达的情绪是正面还是负面，进行一种较为粗略的分类。不过，随着时间推移，人们对于情感的识别与理解提出了更为精细的要求。情感分析的发展趋势正在从简单的情绪极性判断，转变为捕捉和解析更为复杂和微妙的情感细节，以满足不断进步的情感识别需求。人们希望情感分析能够更细致地划分情感类别，如喜悦、悲伤、愤怒、恐惧等。此外，实际文本中的情感表达往往是复杂多变的，一句话可能包含多种情感，例如既有喜悦又有悲伤，或者既有愤怒又有恐惧。这种情感的多样性给情感分析带来了挑战，需要更精细的分类和区分。

2) 情感强度的量化与区分问题

当前的情感分析方法通常只关注情感的类别，比如积极、消极等，而对于情

感强度的量化和区分往往被忽视。但在实际应用中，同一类别下的情感表达可能会有不同的强度，这种差异可能会导致不同的行为或结果。例如，对于产品评论，一个用户可能只是稍微提到了产品的优点，而另一个用户可能会非常详细地描述自己的使用体验，并表达出极高的满意度。

因此，本文旨在探讨如何对情感进行精细分类、对情感的强度进行量化和区分，以更准确地捕捉文本中的情感信息。通过这种细粒度的情感分析，我们可以更好地理解用户的情感态度，为实际应用提供更精准的情感分析结果。

1.2.2 研究现状

本节主要介绍一些情感分析的算法的研究现状，主要从如下三个方面进行介绍研究现状。

1) 基于规则的方法

基于规则的情感分析是一种简单直观的方法，其方法的流程图如图 1.1 所示，它利用事先定义好的规则或者规则集来判断文本中的情感倾向。这些规则可以基于词汇、短语、语法结构等方面，用于识别文本中表达的情感。




图 1.1 基于规则的情感分析流程

该类方法首先需要构建一个情感词典，此词典是基于规则的情感分析的关键步骤，这个词典包含了如大笑、哭泣等具有明显情感倾向的情感词汇。这些词汇可以通过人工构建或者利用已有的情感词汇库。然后需要定义一系列规则来进行情感评分，这些规则可以包括根据情感词汇的出现位置、词性、句法结构等方面的规则，还有需要考虑否定词、程度副词等对情感的影响。在根据定义的规则对文本进行评分后，就可以分析文本中的情感倾向。

基于规则的情感分析方法具有简单直观、易于理解和实现的优点。然而，它也存在一些局限性：首先，其分类效果容易受到词典质量的影响，需要构建者具备高水平的专业知识。其次，不同领域的情感词汇可能存在差异，因此在特定领域需要重新构建词典，这降低了方法的可扩展性。最后，由于互联网的快速发展，网络词汇的快速更新增加了维护词典的成本。除了上述原因外，基于规则的情感分析对语义和上下文的理解能力有限，往往无法处理复杂的情感表达。所以在处理复杂文本和实现高精度情感分析时，通常需要结合其他方法，如基于机器学习或者基于深度学习的方法。

2) 基于传统机器学习的方法

基于传统机器学习的情感分析是利用传统的机器学习算法来提取文本具有情感倾向的特征，然后根据这些特征来分析理解文本中的情感倾向。与上述的方法相比，基于机器学习的方法往往具有更好的效果。该方法的主要流程如图 1.2 所示，该方法首先需要从文本中提取具有情感倾向的特征，并将这些特征进行向量化处理，再选择与之匹配的机器学习算法进行模型训练用以预测出文本的情感倾向。




图 1.2 基于传统机器学习的情感分析流程

文本向量化是将人类可以理解的文本形式转换为计算机可以理解的数字形式。在自然语言处理领域，文本向量化是一项关键任务，它使得计算机可以像人类一样理解和处理文本信息。其目的是将文本信息转换为数值信息，以便于计算机进行进一步的分析和处理。在传统机器学习方法中常用的向量化方法有：词袋模型（Bag of Words, BOW）、TF-IDF（Term Frequency-Inverse Document Frequency）、词嵌入（Word Embedding）等。

在自然语言处理的领域中，传统机器学习技术常依赖于标记完整的数据集进行模型的训练。这些模型致力于探索输入实例与它们的标签之间的对应关系，以此作为依据，对新的未知数据进行标签预测。在此过程中，选择合适的算法以适应数据的特性是至关重要的。例如，支持向量机^[3]（SVM）在处理高维数据时表

现出色，随机森林^[11]（Random Forest）算法则在分类任务中因其易于使用和强大性能而受到青睐，而朴素贝叶斯（Naive Bayes）算法则以其计算效率和在概率分类问题上的适用性而闻名。根据不同的数据特性和分析目标，选择最合适的算法对于提升模型的预测能力至关重要。

基于传统机器学习的方法不需要像上述那样构建情感词典，只需要提取文本的情感语义特征，且通常情况下得到的分类效果还行。但这种方法也存在着一定的缺陷：首先，传统机器学习方法对特征工程的要求较高，需要人工设计和选择特征，设计和选取出合适的特征对研究人员的相关工作经验要求较高；其次，传统机器学习方法往往对新领域或复杂情感表达的泛化能力较差，常用的文本特征只是浅层特征，不能表示文本的深层次语义特征，所以在处理复杂文本和情感表达时，机器学习方法的性能往往不如深度学习方法；另外，机器学习模型的训练效果很容易受到训练数据标注质量的影响。目前随着数据量的极具扩大和人们对情感分析的需求提升，在处理复杂文本和情感表达时，通常使用基于深度学习的方法来解决。

3) 基于深度学习的方法

虽然传统的机器学习方法在情感分析中也能起到不错的效果，但和深度学习的方法相比，传统的机器学习方法需要进行特征提取，且往往泛化能力不如前者。近年来，随着计算机计算能力的不断提高和可供计算机学习的数据规模的增加，深度学习取得了显著的发展。深度学习通过多层特征转化可以将原始输入转化为深层次、抽象的表示，主要使用神经网络进行特征转化。

深度学习作为机器学习的一个分支，在情感分析中取得了更好的效果，主要原因有：其无需人工进行特征构造，就可自动的从数据中学习更多更有效的特征；其通过模拟人类的多层神经网络的特殊组合，可以学习挖掘出更复杂、更隐秘的特征，从而提高模型的情感分析的性能；其可以更好地理解文本上下文的信息，从而更准确的分析出文段的情感，例如，长短期记忆网络（Long Short Term Memory, LSTM^[9]）和门控循环单元（GRU）等模型可以有效地处理长文本序列，从而有效的分析出文本中的长程影响关系；其也可以通过融合多种模型或者多种输入信息来提高情感分析的性能。例如，可以将词嵌入和语法特征结合起来，构建更综合的特征表示。此外，深度学习方法也支持端到端的学习，即直接

从原始数据中分析出数据的情感倾向，无需进行人工干预和中间的糅杂处理步骤，这极大地简化了模型设计和训练等过程，提高了模型的效率和性能。

基于深度学习的情感分析方法的处理流程如图 1.3 所示。这种方法并不需要构建情感词典或人工提取选取特征，而是通过大量的训练数据学习语义知识，并能够自适应地挖掘文本的深层次语义特征。神经网络可以自动学习大量文本数据中的深层次情感语义特征。深度学习方法的主要优势在于其强大的特征提取能力，它能够从数据中学习到高级的特征表示，从而提高了情感分析的性能和效果。这种方法已经被广泛应用于情感分析任务中，并取得了显著的成效。




图 1.3 基于深度学习的情感分析流程

多层神经网络是人们研究的一种模拟人脑工作方式的模型，由多个相互连接的神经元构成。研究人员在前些年提出了一个多层前馈神经网络，并使用反向传播算法训练网络，这些策略解决了以往神经网络难以训练的问题。然后在随后几年，卷积神经网络（Convolutional Neural Networks, CNN^[5]）在图像分类任务上又取得了巨大成功，这一结果又吸引大量研究人员开始关注深度学习。从此深度学习也开始被广泛应用于多个自然科学研究领域，基于深度学习的方法也迅速成为解决情感分析问题的优先选择。2014 年，CNN 在情感分析中首次被应用于文本分类任务，通过卷积操作和池化操作捕捉文本中的局部特征，解决了传统方法中对文本进行手工特征提取的问题，提高了模型的性能。但 CNN 缺乏全局建模的能力，与之相比，循环神经网络（Recurrent Neural Network, RNN^[8]）是具有此能力，RNN 可以提取全局特征，但是在实际使用中，RNN 又经常出现梯度消失和梯度爆炸问题，最终研究者们发现 1997 年提出的长短期记忆神经网络（LSTM^[9]）可以通过门控机制解决长序列数据中存在的梯度消失和梯度爆炸的问题，且相比 CNN，LSTM 也能够更好地捕捉文本中存在的长期依赖关系，提高了情感分析的效果。

随着互联网的发展，为了进一步提高深度学习模型的性能以满足人们的需求，研究者们提出了一种注意力机制结构。该结构既可以帮助模型关注输入中的

关键特征，也给模型带来了一定程度的解释性。早期的注意力机制可以追溯到语音识别领域，在语音识别中，注意力机制用于对输入信号的不同部分进行加权，以便网络能够更好地关注对当前识别决策有帮助的信息。在前些年，研究者为了提高模型的效果，首次在机器翻译任务中提出了一种可学习的注意力机制，该机制允许模型在生成每个翻译单词时动态地对输入序列中的不同部分进行关注。在 2017 年，Vaswani 等人提出了 Transformer^[6]，并在该模型中引入了自注意力机制，使其能够并行计算输入序列中各个位置数据之间的依赖关系，该模型利用该机制在机器翻译等任务上取得的效果显著提升，同时也解决了 RNN 难以并行化的问题。然后由 Google 在 2018 年提出 BERT^[7]，这是一种以 Transformer 为基础的预训练语言模型。BERT 通过在大规模文本数据上进行预训练学习，丰富其语言表示能力，然后可以应用于各种下游任务，如机器翻译等。根据实验测试，BERT 在多项自然语言处理基准测试中取得了领先的性能。

这些神经网络模型^[10]的提出者们通过创新的设计和算法，不断推动着深度学习技术的发展，为自然语言处理等领域带来了许多重要的突破。目前深度学习方法在情感分析中具有很大的优势，可以更好地处理文本信息，提高情感分析的准确性和泛化能力，且具有不错的鲁棒性，深度学习方法是当前情感分析任务中的主流方法。

1.3 主要内容

本文主要设计了一种基于 BERT 预训练模型的情感分析解决方案，旨在应对人们对情感理解的深入和需求的提升。传统的机器学习方案在情感分析中，该方法对特征工程的要求较高，需要人工设计和选择特征，设计和选取合适的特征对研究人员的相关工作经验要求较高，并且受数据影响很大。而随着 Transformer^[6]、GPT^[17]、ELMO、BERT^[7]等模型的发展，“预训练+微调”的范式更加火热，为此，本文基于 BERT 预训练模型构建了一套“BERT 预训练+”来完成情感分析。

在具体实现中，本文采用的数据是剧本数据，需要实现的目的是识别剧本中角色的情感，角色的情感受上下文的影响较大，所以本文首先构建了一个上下文拼接的模型。然后考虑到情感的复杂性，一个角色可能同时具有多种情感，如：

爱 and 乐、恐和惊等，因此，本文采用了多任务学习的方式来解决此问题。最后通过实验分析构建了一个以 BERT 为基础，结合 MMOE^[18]、多头注意力机制模型、AT-LSTM 等模型进行下游任务，对六种情感进行交互预测，提高了情感分析的准确性和鲁棒性。为了进一步提高模型的泛化性和训练效果，本文还尝试了多种训练技巧，包括对抗训练 FGM 和随机权重平均 SWA 等技巧。此外，本文还采用了混合精度训练来降低显存的消耗并加快训练和推理速度。

1.4 本文的组织结构

本文的研究内容被有序地组织为五大部分，各部分内容概述如下：

第一章节，作为本研究的开端，详细讨论了情感分析的背景，突出情感分析中对情感细微差别的识别的重要性，并探讨了情感分析在当前研究领域的意义。

第二章节，为本研究提供技术背景，深入介绍了文本预处理的关键步骤、文本的数学向量化方法，以及深度学习技术的应用，这些技术为本研究中情感分析模型的建立奠定了坚实的基础。

第三章节，详细描述了情感分析模型的设计、构建和实现过程。本章节从数据集的采集开始，明确了研究的具体任务需求，然后按顺序介绍了数据的预处理、模型的搭建、训练和测试流程，最终形成了一个融合 BERT 预训练技术和其他先进技术的综合模型解决方案。

第四章节，专注于情感分析系统的开发。本章节首先评估了系统的可行性和预期功能，随后详细描述了系统开发所需的技术环境和系统架构，并展示了系统的主要可视化功能模块。

第五章节，为本研究的总结部分，回顾了本研究开发的算法和取得的成果，并对未来的研究方向进行了展望，同时诚实地指出了研究过程中遇到的挑战和潜在的改进方向。

第2章 相关理论与技术

2.1 情感分析概述

从前，情感分析的理论还比较零散，无法形成一个体系。随着时代的进步，人们的情感需求日益提高，从而引发了研究人员对情感分析的关注。情感分析作为自然语言处理领域的一个重要分支，目的是分析理解文本中所蕴含的情感倾向，这对于理解人类情感、社会舆情和用户需求等具有重要意义。在社交媒体、在线评论、客户服务等应用中，利用深度学习分析理解用户的情感后，可以帮助企业和机构更好地了解用户的态度，从而改善产品和服务，最终实现更好的盈利。

表 2.1 一个不同分析范围进行情感分析的例子

基于文档	基于句子	基于方面
iPhone 是非常值得信赖的品牌，质量也有保障，相当满意拍照效果，颜值也相当高，但电池续航一般，并且价格非常不亲民。	1、iPhone 是非常值得信赖的品牌，质量也有保障，相当满意拍照效果，颜值也相当高。 2、但电池续航一般，并且价格非常不亲民。	iPhone 是非常值得信赖的品牌，质量也有保障，相当满意拍照效果，颜值也相当高，但电池续航一般，并且价格非常不亲民。
中性	1: 积极 2: 消极	品牌: 积极 质量: 积极 颜值: 积极 续航: 中性 价格: 消极

随着时代的发展，更细粒化的方面级情感分析受到越来越多的关注。如表 2.1 所示，细粒度的情感分析^[12]能更加全面地了解顾客对产品不同方面的体验和感受，而基于文档和句子的情感分析方法只能得到一个笼统地评价。方面级情感分析可以为推荐系统、问答系统等应用提供更准确的参考，从而为用户提供更高质量的服务。这种情感分析的方法能够更好地理解用户对特定方面的情感倾向，从而为产品改进和服务优化提供指导。

2.2 文本预处理

在当今快速发展的网络时代，数据来源是多样化和非结构化，数据通常包含大量的噪声数据。在进行情感分析之前，文本预处理是非常重要的，这关系到后续情感分析的效果。其目的是清洗和规范原始文本数据，去掉影响模型效果的噪声数据。通常来说，文本预处理包含如下三部分：

文本分词：其目的是将文本按照词语或子词的边界进行划分，是文本预处理处理的基础。在英文中，通常可以利用英文的书写格式，用空格将句子分割成词语，但中文的书写格式并没有明显的分割词语边界，所以需要使用专门的技术来进行分词。其中，中文的分词好坏将直接影响到后续模型的表现，常用 `jieba` 进行中文分词。因为其具有高效和准确的特点，其采用基于前缀词典实现的分词算法，能够较好地处理各种中文文本。

文本清洗：其目的是去除文本中的噪声数据，以便后续的文本分析能够更准确地进行。由于数据来源的多样化和非结构化，通常获取到的数据包含大量的无用字符，例如网页中的 `html` 标签等特殊字符。此外，我们获取的文本还可能出现重复信息，如连续的重复词或者短语等。所以为了不影响后续情感分析的结果，这些噪声数据都要去除。

文本标准化：其目的是将文本格式进行统一化的，以便后续的文本分析能够更加高效和准确。在英文中，有的字母开头是大写，而有的是小写，然而他们表达的意思是一样的，所以需要将文本中的所有字母转换为统一的大小写形式，通常是转换为小写。这样可以减少词汇的重复性，减小计算机处理的数据量，提高后续处理的效率。对于中文而言，有时候会出现繁体与简体共存的文本，所以通常需要将繁体字转换为简体字，以便统一处理和分析。此外还有日期时间、数字单位等都需要进行统一标准化处理。

2.3 文本向量化

人类日常生活使用的语言，如中文、英文、日文、法文等各种语言被称为自然语言，人类和正常使用交流理解，但是对于计算机来说，原始的自然语言是非数值型数据，很难理解分析。所以需要使用文本向量化技术，将自然语言转化为

机器能够理解的数值向量形式。本节将介绍一些常用的文本向量化表示方法。

2.3.1 离散式表示

其中离散式表示主要包括：独热向量编码（One-Hot）、词袋模型（BOW）和词频-逆文档频率（TF-IDF）模型。

1) 独热向量编码

独热编码，也成为 One-Hot 编码，是文本向量化最简单、最基础的方法之一，当特征是离散无序时，就可以采用此方法进行处理表示。其主要思想是将每个词转化为一个唯一确定的向量，该方法是使用一个特殊的向量对文本进行表示，每个词向量中只有一项为 1，其他项均为 0，向量的长度为类别总数 N （即词典的词个数）。

以学校校训“修德、博学、求实、创新”为例，对其进行 One-Hot 编码的结果如下表 2.2 所示。

表 2.2 一个 One-Hot 编码的例子

修德博学求实创新	
修德	[1, 0, 0, 0]
博学	[0, 1, 0, 0]
求实	[0, 0, 1, 0]
创新	[0, 0, 0, 1]
修德博学求实创新	[1, 0, 0, 0, 0, 1, 0, 0, 0, 0, 1, 0, 0, 0, 0, 1]

从上面的例子可以看到 One-Hot 编码生成的向量非常稀疏，每个向量中只有一个数值是有效的，这导致存储空间的极大浪费。随着语料库的不断扩充，向量的维度也会随之增加，从而可能引发维度灾难的问题，极大的消耗计算机的资源。此外，该方法并未考虑词与词之间的顺序问题，将词作为了相互独立的个体，如“我喜欢”和“喜欢我”的编码向量化表示的结果是相同的。

2) 词袋模型

词袋模型（BOW）是文本向量化最常用的一种文本表示方法。其主要思想是：文档的含义可以通过它包含的词汇来捕捉，而不必关注词汇的顺序或语法结

构。词袋模型的中心观点是将文本中的每一个词视为一个独立元素，这些元素共同构成了一个“词袋”，文本的含义即由这些元素的集合来表达。在这种模型下，文档或文本可以被转换为一个向量，向量中的每个元素对应一个特定的词汇，其数值则代表该词汇在文本中的出现频率或其它衡量其重要性的度量。

以学校校训“修德、博学、求实、创新”为例，对其进行 BOW 编码的结果如下表 2.3 所示。

表 2.3 一个 BOW 编码的例子

修德博学求实创新	
修德	[0.25]
博学	[0.25]
求实	[0.25]
创新	[0.25]
修德博学求实创新	[0.25 , 0.25 , 0.25 , 0.25]

词袋模型以其简洁明了、易于操作和理解的特点而著称。它能够迅速地将文本信息转换为向量形式，非常适合处理大规模的文本数据集。不过，词袋模型在处理文本时，并不保留词汇的顺序和上下文信息，这可能导致一些重要信息的丢失。特别是在那些需要考虑词汇语境的任务中，词袋模型的效果可能不尽如人意。

为了改进上述模型的不足，研究者们提出了许多改进的方法，如考虑词汇的位置信息的 n-gram 模型、引入上下文信息的 word2vec 和 GloVe 模型等，这些模型在一定程度上弥补了词袋模型的局限性，提高了文本表示的效果。

3) 词频-逆文档频率

词频-逆文档频率（TF-IDF）框架，被广泛认可并应用于信息检索领域和文本挖掘任务中，用以确定特定词汇在整体文档集合中对单一文档的相关性及其重要性。该框架的中心思想在于，一个词汇如果在目标文档中的出现频次较高，而在其他文档中的分布较为稀疏，则表明该词对于目标文档具有显著的标识作用。

TF-IDF 的计算过程具体展现为：

在这一过程中，词汇的出现频次（TF）的确定方法如下：

$$TF(t, d) = \frac{\text{词}t\text{在文档}d\text{中出现的次数}}{\text{文档}d\text{中所有词的总数}} \quad (2.1)$$

其中逆文档频率（IDF）的计算方式如下：

$$IDF(t) = \log \left(\frac{\text{语料库中文档的总数}}{\text{包含词}t\text{的文档数}+1} \right) \quad (2.2)$$

最终的词频-逆文档频率（TF-IDF）为：

$$TF - IDF(t, d) = TF(t, d) \times IDF(t) \quad (2.3)$$

根据 TF-IDF 的计算公式，可以得出以下结论：一个词如果在特定文档中出现得较为频繁（即具有较高的词频 TF 值），并且在整个文档集中出现得较少（即具有较高的逆文档频率 IDF 值），那么该词的 TF-IDF 值也会相应较高，这表明该词对于该文档具有显著的标志性。相反，如果一个词在文档集中普遍存在，那么它的 IDF 值会较低，对 TF-IDF 值的贡献也就不大。TF-IDF 通过词频对文本进行编码，能够评估一个词在整个文档集中的重要性，但是 TF-IDF 方法仍然无法保留词在句子中的顺序信息。

2.3.2 分布式表示

由于传统的文本表示方法，如词袋模型等，存在数据稀疏性、高维度以及难以衡量词与词之间关系等问题，它们在深度学习应用中并不理想。深度学习领域更倾向于使用分布式表示来对文本进行编码。这种分布式的文本表示技术通过将词汇映射到一个高维空间的向量上，以此来捕捉和表达文本中词语的语义联系和上下文信息。常用的分布式表示方法包括基于神经网络的 Word2Vec^[14]和基于统计的 GloVe^[15]等。

1) Word2Vec

Word2Vec^[14]是由 Mikolov 等人提出的一种文本分布式表示的方法，其核心思想是通过神经网络模型将词语映射到一个低维空间中的向量表示，通常在 300 维以下，使得向量更易于处理和存储，同时也能更好地捕捉词语之间的含义。其主要有如下两种算法模型：CBOW 和 Skip-gram。

CBOW（Continuous Bag of Words）模型的主要思想是通过上下文中的多个词来预测当前词，从而学习词向量，其核心理念是利用一个词的上下文信息，即该

词周围的其他词汇来预测该词本身，以此方法来训练词的向量表示。




图 2.1 CBOW 的结构原理图

该模型架构由三个关键层构成：首先是输入层，该层负责将上下文词汇转换成独热码的形式；其次是隐藏层，它涉及对词汇进行向量化处理；最后是输出层，它通过独热码来表示预测出的当前词汇。在训练周期内，CBOW 模型的目标是优化模型以提高对目标词汇的预测准确性。这一过程包括对上下文词汇的向量表示执行数学运算，并通过 softmax 函数来确定目标词汇的预测概率。损失函数通常选择交叉熵损失，利用反向传播算法对模型参数进行细调，目的是通过迭代训练来提升模型的预测精度。

相对地，Skip-Gram 模型的设计理念是利用当前词汇来推断其上下文环境，以此来构建词汇的向量表示。该模型同样包含了三层结构：输入层、隐藏层以及输出层，每一层都扮演着特定的角色，并协同工作以实现模型的功能。

Skip-gram 模型一般采用一个包含单个隐藏层的神经网络结构来实现。在这个模型中，输入层接收一个词的 One-Hot 编码，该编码指明了该词在词汇库中的索引位置。隐藏层的维度对应于词向量的大小，而这些词向量是需要通过模型学习得到的参数。输出层则使用 softmax 函数，其目的是预测给定当前词的上下文中

的各个词的概率。在模型训练阶段，通过最大化预测上下文词出现的概率来优化词向量。具体操作是，模型首先计算输入词向量在隐藏层的变换结果，随后利用 softmax 层来确定词汇表中每个词成为上下文词的可能性。为了衡量模型的性能并进行优化，通常采用交叉熵作为损失函数，并通过反向传播算法来调整词向量的参数。再根据实验数据不断更新和优化相应的权重参数，以此获得最佳的模型权重参数。




图 2.2 Skip-gram 的结构原理图

Word2Vec 的关键优势在于它能够将文本处理简化为对向量的运算，从而使得文本中的语义相似度可以通过向量之间的关联程度来衡量。这使得词向量可以作为输入用于各种自然语言处理任务，如情感分析等。

2) GloVe 模型

虽然 Word2vec 模型有效地生成了语义信息的词向量，但它只考虑了训练窗口内的局部语义信息，没有考虑窗口外的语义信息。为了获得可以表示全局语义信息的词向量，学界提出了一种创新的词汇表示框架——GloVe 模型。此模型整合了广泛语料库内的统计数据与词汇周围的上下文信息，用以识别和表达词汇之间

的广泛语义联系。该模型的训练核心在于优化词向量的点积与它们共现频率之间的匹配度。研究者提出，词汇的共现频次与它们的向量点积在对数域内具有线性关联，这一发现为提取词汇的向量表示提供了一种有效的学习机制。通过这种方法，GloVe 模型能够生成反映词汇语义丰富性的高质量词向量。

GloVe 模型的开发分为两个关键时期：在首个阶段，实施对整个语言资料集的彻底分析，旨在得出每一词汇对在既定视窗规模内的共存状况，并据此生成共现矩阵。该矩阵直观地映射了词汇间的相互作用，其非零项揭示了特定词汇对的共存频度。在随后的第二阶段，模型依据共现矩阵中的这些非零数据点，对词汇的向量化形态进行塑造和调整。在训练过程中，通过最小化词向量点积与共现概率之间的差异来优化词向量，同时对共现矩阵进行降维操作，以减少参数数量和计算复杂度。

共现矩阵的统计过程如下式子 2.4 所示：

$$x_i = \sum_{k=1}^n x_{ik} \quad (2.4)$$

在固定范围内，统计词语矩阵中的各个元素 x_{ik} 共同出现的次数就可得到共现矩阵 X ，其中 i 表示当前统计的中心词， k 表示固定的范围大小。

其损失函数如下式子 2.5 所示：

$$J = \sum_{i=1}^N \sum_{k=1}^N f(X_{ik})(w_i^T w_k + b_i + b_k - \log(X_{ik}))^2 \quad (2.5)$$

其中， N 表示语料库词典的大小， $f(X_{ik})$ 是采用词对共现频率越高则所占权重越高的原则构建的权重函数， w_i 和 w_k 是第 i 个词和第 k 个词的词向量表示， b_i 和 b_k 表示偏置项， X_{ik} 表示词之间的共现频率。

相比于 Word2Vec^[14]，GloVe^[15]能够有效地捕捉词语之间的全局语义关系，学习到高质量的词向量。且在词语共现计数较多的情况下，模型表现出色，能够处理大规模语料库。然而，该方法的性能在很大程度上依赖于训练数据的量。当训练数据的量不足时，生成的词向量质量可能会显著降低，这使得该方法的稳健性相对较弱。

2.4 深度学习相关技术理论

研究者们借鉴了人类神经元的概念，发展出了深度学习的理论框架。本理论模型依托于多层神经网络的整合，以此仿真人类大脑的神经网络功能，目的是为了机器具备自我学习和分析的功能。在深度学习的研究范畴内，设计恰当的神经网络结构和进行精确的参数调整是实现目标的关键步骤。借助于反向传播算法和梯度下降等优化策略，神经网络得以逐步对自身的权重和偏置值进行优化，从而深入挖掘并理解数据中的模式与关联性。本节将简要介绍本文所采用的深度学习相关技术，包括但不限于激活函数、注意力机制以及 BERT 语言模型等技术。

2.4.1 激活函数

激活函数在深度学习框架内扮演关键角色，它们通过引入非线性性质，扩展了神经网络处理复杂数学模型的能力。这种特性对于模拟现实世界数据的多样性和复杂性至关重要。激活函数主要可以分为三大类：S 型（如 sigmoid 或 tanh）、ReLU 型（如 ReLU 或 Leaky ReLU）以及由多个函数组合而成的复合型激活函数。本节主要是介绍几种常见的激活函数：

1) Sigmoid 函数

Sigmoid 函数也被称为 Logistic 函数，它是 S 型函数的一种，其函数图像如图 2.3 所示，常用于隐层神经元的输出。




图 2.3 Sigmoid 的函数图像

Sigmoid 函数的输出范围在 0 到 1 之间，可以将神经元的输出限制在一定范围内，有助于模型的稳定性和收敛性，其函数表达式如式（2.6）所示，常用它将一

个实数映射到（0,1）的区间进行二分类。在特征相差比较复杂或是相差不是特别大时效果比较好。Sigmoid 函数在整个定义域上都是可导的，这在反向传播算法中很重要，可以方便地计算梯度，进行参数更新。

$$\text{Sigmoid}(x) = \frac{1}{1 + e^{-x}} \quad (2.6)$$

不过，Sigmoid 函数面临一个显著的挑战，即梯度消失的问题。当输入值的绝对值变得非常大或非常小的时候，Sigmoid 函数的梯度会接近于零。这种现象会在神经网络的反向传播过程中导致梯度更新变得非常微弱，进而影响整个模型的学习效率和训练质量。

2) Tanh 函数

Tanh 函数（双曲正切）的图像也呈现出一种 S 形曲线，类似于 Sigmoid 函数，但与之不同的是，Tanh 函数的输出范围在-1 到 1 之间，而不是 0 到 1，其函数图像如下图 2.4 所示。




图 2.4 Tanh 的函数图像

与 Sigmoid 函数相比，Tanh 函数的输出范围更广，包括了负数，有助于神经网络模型学习更复杂的数据分布和更广泛的特征表示，其函数表达式如式（2.7）所示。Tanh 函数的输出以 0 为中心，即当输入为 0 时，Tanh 函数的输出为 0，有助于减少数据的偏移，提高模型的训练效果。

$$\text{Tanh}(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2.7)$$

与 Sigmoid 函数类似，Tanh 函数同样也存在梯度消失的问题，特别是在输入比较极端时，梯度接近于零，导致反向传播时梯度传递减弱，影响模型的训练效果。因此，在使用 Tanh 函数时需要注意梯度消失的问题，并结合其他方法进行调整和优化。

3) ReLU 函数

ReLU 函数又被称为修正函数，在一定程度上解决了 S 型激活函数存在的梯度消失问题。其函数图像如图 2.5 所示。




图 2.5 ReLU 的函数图像

ReLU 函数将所有负值的输入映射为零，而对于正值输入则保持不变，其函数表达式如式 (2.8) 所示。

$$\text{ReLU}(x) = \max(x, 0) = \begin{cases} x, & x > 0 \\ 0, & x < 0 \end{cases} \quad (2.8)$$

相比于 Sigmoid 和 tanh 等激活函数，ReLU 在正区间上的导数恒为 1，这有助于缓解梯度消失问题，使得反向传播时梯度能够更好地传递。这种简单的非线性变换使得神经网络能够学习复杂的特征，并且在计算上比一些传统的激活函数更加高效。但 ReLU 也存在一些问题，由于 ReLU 函数负半轴数据为硬饱和置零，输出可能出现“死亡神经元”问题，即某些神经元永远不会被激活，导致相应的权重永远不会更新。

4) Leaky ReLU 函数

Leaky ReLU 是对标准 ReLU 激活函数的改进，目的是为了了解决 ReLU 可能出

现的“死亡神经元”问题，其函数图像如图 2.6 所示。




图 2.6 Leaky ReLU 的函数图像

Leaky ReLU 在负值区域引入了一个小的线性项，使得负数输入时也有一个小的梯度，从而可避免完全的“死亡”，其函数表达式如式（2.9）所示。

$$LeakyReLU(x) = \begin{cases} x, & x > 0 \\ \alpha x, & x < 0 \end{cases}, \alpha \text{ 为一个常数系数} \quad (2.9)$$

Leaky ReLU 引入了一个小的斜率，避免了 ReLU 中可能出现的神经元完全失活的问题。且相比于 ReLU，Leaky ReLU 在负数区域也有一定的激活，因此可以更好地利用所有的神经元，减少了网络的稀疏性。Leaky ReLU 在负数区域保留了线性属性，有助于学习一些特定类型的数据表示。

在实际应用中通常 Leaky ReLU 比 ReLU 效果更好，特别是在处理较大学习率的情况下，可以更好地避免神经元的“死亡”。但 Leaky ReLU 也存在一个缺点，就是引入了一个新的超参数 α ，需要进行调优。

2.4.2 注意力机制

注意力机制是一种模拟人类感知系统中注意力机制的技术，其目的是在提高神经网络处理序列数据的效率和性能。人类可以像在海量信息中进行选择性关注一样，注意力机制也能够从输入数据中选择性地聚焦于关键信息，忽略其他无关信息。传统的神经网络在处理序列数据时往往会面临长距离依赖和信息丢失的问

题，而注意力机制通过动态地选择性关注序列中不同位置的信息，能够更好地解决这些问题。这种机制在深度学习中被广泛使用，使得模型能够识别出输入中的重要部分，并有选择地将资源和注意力集中在这些部分上。注意力机制最初是在计算机视觉领域中应用于图像分类任务的，它使得模型能够自适应地选择图像中的区域来提取信息。在自然语言处理领域，注意力机制最早被应用于机器翻译任务中，它有助于模型学习语言之间的对应关系。注意力机制的加入让深度学习模型在处理复杂输入数据时更加高效，并且更贴近人类的识别和处理信息的方式。在实践应用中，注意力机制已被证实能够有效提升模型的表现和工作效率，因此它在多种不同的任务和研究领域中获得了广泛的采纳和深入的研究。

在实现细节上，注意力机制的运算大致分为两个关键步骤：首先是确定注意力权重的分配，其次是利用这些权重整合输入数据。在第一步中，目标是识别出输入信息中最为关键的部分。这个注意力权重集合反映了各个输入元素对于当前处理任务的重要性。注意力权重的确定过程通常包括一个查询向量的引入，这个查询向量是根据特定任务需求定制的，它有助于注意力机制从输入中筛选出与任务紧密相关的信息片段。

具体而言，注意力分布的计算过程涉及评估查询向量与输入数据之间的相关性，从而为输入数据的每个部分分配一个注意力权重。这些权重随后会经过归一化处理，以形成最终的注意力分布图。注意力分布实质上是对输入数据进行加权，它允许模型有针对性地集中处理那些对于当前任务更为关键的信息。

得到注意力分布后，接下来的步骤就是根据这个注意力分布来融合输入信息。这一步通常是涉及到将输入信息与注意力权重相乘，然后将结果进行加权求和，得到最终的注意力表示。这个注意力表示包含了输入信息中与任务相关的部分信息，能够帮助模型更好地完成当前任务。

其计算流程如下图 2.7 所示。对于输入的信息向量 ($X = [x_1, x_2, \dots, x_n]$)，注意力机制先使用打分函数 f 计算出向量 q 和每个输入的信息向量的相似度评分；然后使用 soft max 函数进行归一化，得到注意力分布 $(\alpha_1, \alpha_2, \dots, \alpha_n)$ ，最后再根据得到的注意力分布对输入的信息向量进行加权求和。




图 2.7 注意力机制计算流程

其中常见的函数如下：

1) 点积函数

$$f(x, q) = q^T x \quad (2.10)$$

2) 缩放点积

$$f(x, q) = \frac{q^T x}{\sqrt{D}} \quad (2.11)$$

3) 加性注意力

$$f(x, q) = v^T \tanh(W_1 x + W_2 q) \quad (2.12)$$

4) 双线性注意力

$$f(x, q) = x^T W q \quad (2.13)$$

其中 W 、 W_1 、 W_2 、 v 都是可学习的参数， D 表示输入的信息向量的维度。

2.4.3 Transformer 语言模型

Transformer 框架，一个以注意力机制为核心的深度学习模型，由 Vaswani 及其同事在 2017 年提出。这种模型在分析序列数据时，相较于传统的循环神经网络和长短期记忆网络，更加有效地处理长距离依赖，并且能够更高效地执行并行操作。

该模型的创新之处在于采用了自注意力机制，使得模型在计算序列中某一位置的表示时，能够同时考虑序列内所有其他位置的信息。这种机制极大地增强了模型对序列数据的理解和生成能力，因此在自然语言处理等多个领域实现了显著的进展。此外，Transformer 模型还融入了残差连接和层归一化等技术，进一步提升了模型的性能。

Transformer 架构的工作原理可以通过图 2.12 来具体展示，该模型主要由编码部分和解码部分组成，这两个部分均由多个重复的层结构堆叠而成。编码器由若干连续的编码层构成，解码器亦是按顺序由多个解码层组成。在每个层级中，存在两个基础的子层：一个执行自注意力机制的子层，另一个是基于前馈网络的子层。通过采用残差连接和层归一化的技术，这些子层有助于提升模型的训练效率和收敛性能。




图 2.8 Transformer 的模型结构

以 Transformer 模型的编码器为例，输入文本字符串首先会通过位置编码来标注每个词汇的顺序信息。接着，文本被传递到自注意力机制层，该层负责深入挖掘文本的语义内容，并分析文本内部各元素间的相互作用。通过应用多头自注意力技术，模型能够对序列中每一位置的元素进行评估，并同时顾及序列内其他所有元素的信息，实现对文本整体依赖性的全面捕捉。这种设计显著提升了模型捕

提序列中长距离依赖的能力，从而增强了模型处理序列数据的效果。在 Transformer 模型的编码器环节中，通过在每个子层融入残差连接和层归一化的做法，模型的训练稳健性得到了增强，同时也促进了模型更快地达到收敛状态。

2.4.4 BERT 预训练模型的介绍

BERT^[7]是由 Google 在 2018 年引入的高级预训练语言思维模型，并在最新的多项自然语言处理（NLP）任务中表现出卓越的性能。该模型采用了 Transformer 的 Encoder 部分，并运用了此种架构的自注意力（Attention）机制，实现更有效地识别并利用上下文信息。

作为一个自监督学习模型，BERT 模型受益于大规模无标记文本数据进行预训练，它基于如此大量的数据，成功学习到一种更通用的语言表示。而其双向设计使得每个单词都能充分融入其上下文，从而形成丰富的语义。再者，BERT^[7]模型不仅可以捕获单词的双向关系，还可以理解句子顺序和逻辑关系，这得益于其独特的预训练任务构造方式，包括被掩蔽的语言模型（Masked Language Model, MLM）和下一句预测（Next Sentence Prediction, NSP）。此外，BERT 模型提供了一种通用的预训练模型，具有广泛的适应性，只需要通过简单的微调，就可用于解决各种 NLP 任务，比如文本分类、实体识别、问答等，这大大提高了模型的实用性和灵活性。




图 2.9 BERT 预训练和微调模型图左图为预训练，右图为微调^[7]

上图 2.9 内容为 BERT 模型的预训练和微调操作。BERT 模型在预训练阶段确

实使用了多任务机制，并具有两个主要的预训练任务，即被掩码的字预测任务（Masked Language Model, MLM）和下一句预测任务（Next Sentence Prediction, NSP）。这两个预训练任务合作，让 BERT 模型有能力充分理解上下文信息，并且掌握句间的逻辑关系。

在这个过程中，BERT 模型采用了一种独特的掩码策略。首先，每个词有 0.15 的概率被选择进行掩码，但选择掩码后的处理路径会有三种：以 0.8 的概率真正使用[MASK]标记；以 0.1 的概率不进行任何更改，原句原词出现；以 0.1 的概率用句子中的另一个随机词语替代。此举不仅帮助模型更准确地预测被掩码的字，还为 BERT 模型增加了一定的健壮性，使其能够在微调应用中借助文本纠错能力处理复杂的现实场景。

至于 BERT 模型的另一个预训练任务，下一句预测任务，它能够判断给定的两段输入文本是否来自于同一文本中的相近段落。这个任务实质上可以看作是一个二分类任务，训练 BERT 模型理解句子在语篇中的连贯性和逻辑关系。

通过多任务预训练过程优化的 BERT 模型，能够充当一个高效的文本特征抽取器，进而为多种自然语言处理任务提供微调的可能性。这些任务包括情感分析、命名实体的识别、文本的分类等。在微调阶段，原始 BERT 模型的架构保持不变，只会根据特定任务加入必要的输出层，通过在新任务数据上训练，BERT 模型可以适应各种具体应用，实现端对端的预测。

根据不同的下游任务，BERT 模型会有特定的微调策略。以实体识别任务为例，通常利用 BERT 模型的最后一层输出作为每个单词的表示，然后通过一个分类器如 Softmax 或线性层将这些表示转化为预测的实体标签。比如，在某些情况下，这些预测标签会进一步输入到一个条件随机场（CRF）模型中，以便利用标签序列之间的依赖关系提高预测性能。在文本分类和阅读理解任务中也是如此，BERT 的微调策略会依据具体任务的要求有所不同。

如下图 2.10 所示，BERT 模型的输入是以特定格式准备的，一般为[CLS]+句子 1+[SEP]+句子 2+[SEP]。这种格式允许模型处理像文本对比这样需要两个独立输入的任务。至于输入的表达，BERT 采用了多种嵌入方法，包括词嵌入、片段嵌入和位置嵌入。词嵌入类似于词向量，代表了词的语义；片段嵌入则表示词所在的句子，使模型能区分同一输入中的两个句子，而位置嵌入则按照词在句子中

的位置进行编码。这些嵌入方式掺和在一起，形成了每个词的最终输入表示。这种多维度的嵌入表示，BERT 模型能够理解同一词在不同语境中的多重含义，进一步增强其在微调阶段处理下游任务的能力。




图 2.10 BERT 输入^[7]

2.5 本章小结

本章主要对情感分析的概述、文本预处理、文本向量化和深度学习相关技术进行了系统而全面的介绍，为后续章节的情感分析内容和实验研究奠定了基础。

本章集中阐述了情感分析的基本概念、相关技术和方法论。开篇首先对情感分析进行了定义，并探讨了其在洞察人类情绪、社会舆论和用户偏好等多个领域的重要作用。随后，本章对文本预处理的流程进行了阐释，这包括了去除文本中的干扰元素、进行分词处理、实现文本的规范化等操作，同时介绍了在预处理中常用的技术手段。

进一步地，本章深入讲解了文本向量化的策略，既包括了诸如词袋模型和 TF-IDF 这样的离散型表示方法，也涵盖了 Word2Vec 和 GloVe 等分布式表示技术，并讨论了这些方法在情感分析中的实践应用。在深度学习技术方面，本章首先描述了激活函数的重要性，并列举了 Sigmoid、ReLU 等常见激活函数及其在构建神经网络时的用途。最后，本章也探讨了注意力机制在文本分类中的作用，以及 Transformer、BERT 模型在情感分析领域的应用优势。

通过本章的系统性介绍，为之后章节中的情感分析讨论和实验研究提供了坚实的理论和技術基础。

第 3 章 基于 Bert+预训练模型的多情感分析方法

3.1 问题描述

3.1.1 数据集描述

本项研究所依据的数据集取自中国计算机学会（CCF）组织的一场专注于数据与智能计算的竞赛活动。该竞赛所依托的数据集构建于多部电影剧本的基础上，并且附有爱奇艺公司提供的人工情感标注信息。数据集被划分为训练集与测试集两个部分，其中训练集涵盖了 31 部剧本，包含 42790 条记录；测试集则包括了 18 部剧本，记录总数为 21376 条。

每条数据包括 4 列，分别为 id，content，character，emotion（测试集不包括该列），每列的含义如下表 3.1。在本研究使用的数据集中，情感标签涵盖了六种基本情感状态：爱情、乐情、惊情、怒情、恐情和哀情。研究的核心任务是为这些情感状态赋予一系列连续的强度评分，评分尺度设定为从 0 到 3。在这个尺度中，0 代表该情感状态的缺失，1 表示情感状态较弱，2 意味着情感状态较为明显，3 则指情感状态非常突出，各项评分通过逗号进行分隔。

表 3.1 数据集的描述字段说明

字段名称	类型	描述	说明
id	String	数据 ID	
content	String	文本内容	剧本对白或者动作描写
character	String	角色名	剧本中的角色
emotion	String	情感结果	爱值、乐值、惊值、怒值、恐值、哀值

3.2.2 任务描述

一部优秀的剧本不仅是赢得良好口碑和吸引大量观众的基石，同样也能为制作方带来可观的经济收益。剧本分析作为整个内容生产流程的起点，探索如何结合专家的专业知识、大数据技术以及自然语言处理技术，以帮助业务团队迅速进

行剧本的分析和评估，是一个具有实际价值的研究课题。在剧本评估体系中，对角色进行深入分析是核心环节之一，其中角色情感的分析尤为关键。本项赛事提供了部分电影剧本以及由爱奇艺标注团队所完成的情感标签，旨在利用这些已标注的剧本数据集，对剧本中每个场景的对话和动作描述进行多维度的情感分析和识别，以辨识出各个角色的情感状态。

在进行剧本情感分析时，与处理评论文本的情感分析相比，存在一些独特的挑战和考虑因素。主要难点可以归纳为：

- 1) 剧本的文本风格通常更为口语化，与新闻报道的文体存在明显的区别；
- 2) 角色的情感状态不仅受到当前文本的影响，还可能与之前文本的语义有着紧密的联系。

3.2.3 评价指标

常见的情感分类的评价指标一般为准确率、F1 值等，但本文涉及的是一个多分类的情感极性分析，不太适用常见的评价指标体系。本文使用的评价指标为均方根误差(RMSE)，按照“文本内容+角色名”识别出 6 种情感的极性值，其计算公式如下式 3.1 和式 3.2。

$$RMSE = \sqrt{\frac{\sum_{i=1}^n \sum_{j=1}^6 (y_{ij} - x_{ij})^2}{6n}} \quad (3.1)$$

$$Score = \frac{1}{1 + RMSE} \quad (3.2)$$

其中， y_{ij} 是预测的情感极性值， x_{ij} 是官方给出的极性情感值， n 为测试样本的数量，最终的 $Score$ 值越高就说明模型的效果越好，比赛的排名就越高。

3.2 数据预处理

3.2.1 数据分析

1) 文本长度分析

本课题对数据文本长度进行了统计分析，从图 3.1 中可以发现训练集与测试集文本长度分布大致相似，长度都聚集在小于 100 的位置，由于每一条剧本数据

之间都具有一定的联系，由此考虑到可以对文本长度进行填充，使后续构建的模型可以学习到更多的语义。




图 3.1 数据集的文本长度分布

2) 数据分布分析

本课题的数据集中训练集共 31 个剧本，4 万多条文本数据，从标签上的分布来看，数据标签分布不均匀，随着情感程度的加深，标签数量越少。由图 3.2 可以看出，每一类情感极性的分布都极不均衡，对此本课题尝试了使用标签分布平滑(LDS)等技术来削弱不平衡标签的影响。




图 3.2 训练集的情感标签分布

3.2.2 数据清洗




图 3.3 训练集的情感标签缺失情况图

通过对训练数据的分析，发现存在 14.04%的数据情感标签为缺失，如上图 3.3。由于整体上缺失情况为场景描述文本且对后续情感分析影响较小，因此，直接在本研究中直接对缺失标签进行了剔除处理。此外，训练集还存在 12.69%的数据角色标签缺失，如下图 3.4。但通过对该场景的文本片段进行分析，发现角色识别较为容易，所以对该情况进行了额外的文本识别填充。




图 3.4 训练集的角色标签缺失情况图

3.2.3 文本拼接

剧本中，每条对白或动作描述并不是相互独立的，他们之间存在着上下文关

系，为了让模型理解到前后文信息,我们采取拼接前后文的方式来实现。

在所给数据集中，如下表 3.2 展示的部分数据，由于剧本中的同一句对白或动作可能涉及多个角色，而每个角色及其对应的对白或动作描述都会作为独立的数据记录，这可能导致数据集中出现大量文本内容的重复。为了解决这一问题，我们对数据进行了去重处理，以确保文本内容与当前语境更加贴合。

在剧本的情感分析过程中，由于每一段对话或动作的叙述在原始长度上就不尽相同，即便在执行了上下文的融合处理之后，这种长度上的变化仍旧显著。为了充分挖掘和利用上下文信息，本研究通过设定拼接文本的最大长度阈值，以实现文本拼接后的最大化，从而增加了文本的信息量。

表 3.2 训练集的部分数据展示

id	content	character	emotion
1171_0001_A_12	o2 示范了一个动作，c1 照做。	o2	0,0, 0, 0,0,0
1171_0001_A_13	o2 示范了一个动作，c1 照做。	c1	0,0,0,0,0,0
1171_0001_A_3	o2 一手拿着一个行李，一路小跑着把 c1 带到 了文工团门口	o2	0,0,0,0,0,0
1171_0001_A_4	o2 一手拿着一个行李，一路小跑着把 c1 带到 了文工团门口	c1	0,0,0,0,0,0

3.3 模型搭建

3.3.1 上下文建模

在对数据进行情感分析的过程中，构建具有深度上下文关联的数据集是非常关键的步骤。毕竟对于该数据，角色的情绪反应并不仅仅是对单独言语或行为的反应，而往往需要对前文的语境和语义有深度的理解。更进一步地，后文的语境也可能对当前情绪的理解产生修正的影响。因此，为了更好的进行情感分析，进行上下文建模是非常有必要的。本文进行的上下文建模主要有以下步骤：

1) 去除重复内容

由于剧本内的单一对白或动作可能被多个角色所共有，这可能引起数据集中文本的重复现象。本研究通过消除这些重复的文本项，进行了数据的清洗工作，

目的是为了上下文信息更加贴合当前讨论的语境。

2) 进行文本拼接

在处理剧本对话和动作描述时，由于每个条目的长度不一致，即使在进行上下文拼接之后，这种长度差异依然存在。为了适应 BERT 模型对输入长度的要求，同时尽可能多地保留上下文信息，本研究设定了一个文本拼接的最大长度限制。当拼接后的文本长度超出这个限制时，首先考虑减少上文的拼接量，转而增加下文的拼接量。如果下文已经全部拼接完毕或已至剧本的末尾，那么将重新考虑上文，对超出长度限制的部分进行裁剪，并将剩余的文本内容拼接回原始文本中。通过这种策略，可以确保拼接后的上下文长度恰好符合设定的最大长度，同时避免因长度超出限制而导致角色位置信息被截断的情况。

3) 标记特殊角色

为了提升模型对特定角色情感的识别能力，本文对角色进行了特殊的标记以突出角色的身份。标记方法采用“S 角色”的形式，这样的设计使得模型能够更好地识别并理解角色的情感状态。同时，在已构建的文本中找到被标记角色的位置，这有助于在模型处理过程中更准确地定位到对应角色，从而进一步提升模型的情感分析性能。

3.3.2 BERT+MMOE

本文需要对角色进行六种情感分析，是一个多任务的学习分析任务。本文中，为了解决此任务，引入了多任务学习模型 MMOE^[18]（Multi-gate Mixture-of-Experts），它是一种解决多任务学习问题的深度学习架构。这个模型是由 Google 在 2018 年推出的，其主要目的是同时解决多个任务，而同时保证模型的资源分配有足够的灵活性，从而使每个任务都能获得适合其需求的处理能力。

MMOE 模型的核心思想是一种被称为“专家”的机制。在 MMOE 的架构中，每个专家都是一个特殊的神经网络层，这些专家可以在不同的任务中学习并提取不同的特征。每个专家都有一个相应的“门”用于决定其在特定任务中的重要性。这种设计最大化地利用了专家的专业领域，并确保所有的专家都可以向多个任务提供他们的专业知识。

MMOE 模型的结构主要包含三个部分（如下图 3.5）：Shared Bottom Layer, Mixture-of-Experts Layer, and Task-specific Towers. Shared Bottom Layer 用于处理

所有任务的输入数据并抽取共享特征。Mixture-of-Experts Layer 则由多个专家组成，每个专家负责基于共享特征抽取特定的特征。而 Task-specific Towers 则是一系列专门处理特定任务的神经网络层，他们利用各自对应的门和专家的输出来完成任务。通过这种设计，MMOE 模型可以同时处理多个任务，每个任务都能受益于所有专家的专业知识，并且各任务间不会相互干扰。这种模式适合处理一些具有多个密切相关任务的复杂问题，并有可能提高各个任务的性能。



图 3.5 MMOE 的模型结构^[18]

图 3.6 BERT+MMOE 的模型结构

在完成对角色上下文的建模之后，文本资料经过编码转换，被引入 BERT 模

型以提取语言特征。随后，从 BERT 模型获得的最终输出层的向量被用作 MMOE 模型的输入。MMOE 模型由六个专家网络构成，它们根据预先设定的损失函数进行参数优化。这一训练过程使得模型能够对文本进行情感倾向的预测，而详细的模型架构和操作流程在图 3.6 中有所描述。

3.3.3 BERT+AT-LSTM

本文是进行对象级的细粒度情感分析，不仅仅需要模型理解较长范围内的文本信息，同时还需要精确定位到“角色”。对此，本文设计采用 BERT+AT-LSTM 的方式来强调角色 token，使模型对角色 token 有更好的注意力。

AT-LSTM^[19]，全称为 Attention-based LSTM，是一种基于 LSTM（Long Short-Term Memory）模型进一步拓展的深度学习模型，将注意力机制嵌入 LSTM 模型中，从而增强了对输入序列中不同部分的区分处理能力。

LSTM 模型本身是一种递归神经网络（RNN）结构，创新性地引入了存储单元（cell state）和三种门控制器：输入门，遗忘门和输出门，借此解决了传统 RNN 在处理长序列时出现的梯度消失或爆炸问题。然而，纵使 LSTM 模型在处理长序列任务上有显著优势，但在一些需要重视特定信息的场景下（如情感分析）仍存在局限性。这是因为，LSTM 本身并不能有效地区分序列中每个元素的重要性，即给予序列中较为关键的部分更多的关注。所以 AT-LSTM 模型应运而生。AT-LSTM 模型引入了注意力机制，使得模型能够为输入序列中的每个元素分配一个权重，这个权重反映了该元素对于输出的重要性。这样，在计算序列的表征时，模型会倾向于关注那些高权重的元素，即关键性的信息。

在实现中，AT-LSTM 模型一般会在原有的 LSTM 架构上，增加一个注意力层。这个注意力层通常采用加性注意力或者乘性注意力的方式计算权重，再与 LSTM 层的输出（隐藏状态）相乘，得到最终的加权输出。这个加权输出位于序列上的各个位置，更多地集中了关键元素的信息。其中主要注意力层的数学公式如下所示：

$$M = \tanh \left(\begin{bmatrix} W_h H \\ W_v v_a \otimes e_N \end{bmatrix} \right) \quad (3.3)$$

$$\alpha = \text{soft max}(w^t M) \quad (3.4)$$

$$r = H\alpha^T \quad (3.5)$$

其中， $H = key$ ， $v = value$ ， $q = query$ ， α 为每个句子相应的 aspect 下的权重向量，其中 r 表示各 hidden state 带权重后的表示，然后最终句子的表示如下：

$$h^* = \tanh(W_p r + W_x h_N) \quad (3.6)$$

AT-LSTM 模型因此能够在众多 NLP 任务中实现性能的提升，例如文本分类、命名实体识别、情感分析等，本文就是在情感分析任务中使用 AT-LSTM。通过精细地权衡每个元素的贡献，AT-LSTM 模型能更准确地把握文本的主要语义，从而产生更高质量的模型预测。最终联合 AT-LSTM 和 BERT 建立的模型结构如图 3.7 所示：




图 3.7 BERT+AT-LSTM 的模型结构

3.3.4 BERT+多头注意力机制

上下文中目标角色的情感对当前角色情感的影响程度可能不同，同时，不同的情感受到上下文影响也可能不一样，因此在本文中设计利用多头注意力机制获取不同情感下的上下文角色特征。

多头注意力机制是在自然语言处理中广泛应用的一种注意力模型，首次由“Attention is All You Need”一文中的 Transformer^[7]模型引入。核心理念是对输入数据的不同部分进行注意力计算，以此捕获输入内的不同类型和层次的信息。

单头的注意力机制是一种分配不同权重的方式，使得模型能够关注输入中的某些特定部分。然而，在许多场合，单一注意力机制可能无法捕获到数据的所有有效信息，因为不同的信息可能在不同的表示空间和抽象级别上。这就是多头注意力机制的由来。

在多头注意力机制的实现中，模型内部构建了多个并行的注意力解析单元，每个单元独立负责计算其对应的注意力权重。这些单元，即“头部”，在它们各自的数据子空间上执行权重计算任务。使得模型得以在多个不同的表示子空间中同时提取相关信息，增强了对输入数据的多维分析能力。因此多头注意力机制可以更准确地捕获输入数据的多元性，并且提高模型在处理复杂任务时的性能。

对于一个具有 H 个头的多头注意力模型来说，在多注意力头模型中，每一头通过特定的线性变换将输入数据投影至其独有的特征空间。随后，每个头在该空间内独立地确定其注意力权重，从而派生出各自的上下文向量。这些向量在汇总后，通过一个统一的线性变换过程，转化为模型的最终预测输出。

通过这种设计，多头注意力机制可以抓住输入数据的不同方面，并通过在更高层次融合这些方面来理解原始输入。与单头注意力相比，这使得模型在处理各种自然语言处理任务时有更强的表现。

通过 BERT 模型分别提取当前文本以及不同上下文文本中目标角色位置的最后一层隐藏层表示，再为六个情感设置对应的神经注意力网络，分别提取上下文文本中目标角色的权重，计算公式为：

$$o(i, t)_k = h_k^T \text{ReLU}(P_i^t c_i^t + P_t^t r_t + b)_k \quad (3.7)$$

$$\alpha(i, t)_k = \text{softmax}(o(i, t)_k) = \frac{e^{o(i, t)_k}}{\sum_{j \in C_t} e^{o(i, t)_j}} \quad (3.8)$$

其中， $k=1, 2, \dots, 6$ ， r_t 为当前文本角色最后一层隐藏层表示，对于一个对白或者动作描述文本中多次出现的角色我们采用对隐藏层状态求平均进行聚合； c_i^t 表示当前文本的上下文隐藏状态， b 偏差项， P_i 、 P_t 为权重矩阵， h_k^T 为权重向量； $o(i, t)_k$ 经过 softmax 规范化得到权重系数， $\alpha(i, t)_k$ ， k 为 head 数量。最后，针对不同情感预测，我们将上下文文本中目标角色隐藏层表示加权聚合后附加到当前文本角色隐藏层表示作为最终的表示：

$$\tilde{r}_t = \sum \alpha(i, t)_k c_i^t + r_t \quad (3.9)$$

最终联合多头注意力机制和 BERT 建立的模型结构如图 3.9 所示：




图 3.9 BERT+多头注意力机制的模型结构

3.4 模型训练

3.4.1 损失函数的设置

本研究中，情感标签以整数值表示，而评估标准采用的则是均方根误差（RMSE）。这意味着，情感分析任务既可以按照分类问题来构建模型，也可以按照回归问题来构建。但是，如果将其建模为一个标准的分类问题，则可能会忽视标签数值递增所蕴含的信息；而如果将其视为一个标准的回归问题，则可能会忽略标签作为整数的特性。因此，本文设计了一个融合了分类和回归特点的损失函数，旨在更全面地利用标签信息。

$$loss = loss_{cls} + loss_{reg} \quad (3.10)$$

$$loss_{cls} = \sum_i^n \sum_j^6 \sum_k^4 y_{ijk} \cdot \log(p_{ijk}) \quad (3.11)$$

$$loss_{reg} = \frac{\sum_i^n \sum_j^6 (y_{ij} - y'_{ij})^2}{6n} \quad (3.12)$$

其中， n 是样本总数， y_{ijk} 表示在第 i 个样本中第 j 个情绪的强度标签为 k 的值， p_{ijk} 表示在第 i 个样本中第 j 个情绪的强度标签为 k 的概率， y'_{ij} 是第 i 个样本中第 j 个情绪的最终预测强度，在模型中会作为输出预测值。 y'_{ij} 的计算公式如下：

$$y'_{ij} = \sum_k^4 y_{ijk} \cdot p_{ijk} \quad (3.13)$$

根据所设计的损失函数，模型的输出层结构如图 3.10 所示。




图 3.10 模型输出层

3.4.2 训练策略

1) 对抗训练 FGM

Fast Gradient Method (FGM) 是对抗训练策略中的一种，主要被应用于深度学习模型的训练过程，以提高模型的鲁棒性。FGM 主要针对的是对抗样本问题，即通过专门的方法来增加输入数据的扰动，使得模型的输出产生变化，而这种变化又是人眼几乎无法察觉的。这类攻击对深度学习模型的安全性、鲁棒性提出了巨大的挑战。

在快速梯度法（FGM）框架下，生成具有对抗性的数据样本的主导思想是借助模型对输入数据的梯度信息，来形成一个小幅度的扰动。这个扰动虽然在大小上不显著，但其目的是对模型的输出造成不利影响。通过将该扰动应用到原始数据上，我们得到了对抗性样本，它们在视觉上与原始样本极为接近，但在模型的预测输出上可能产生根本性的变化。之后在训练过程中，将这些对抗样本纳入到训练数据中，使得模型在训练过程中能够尽可能地学习到一种对这类扰动的抵抗能力。

对于理解 FGM 的过程，最重要的计算就是对损失函数进行梯度的计算。其计算公式如下：

$$x' = x + \epsilon \cdot \frac{g_t}{\|g_t\|_2} \quad (3.14)$$

其中， x' 为扰动后的参数， x 为原始参数， ϵ 为扰动系数， g_t 为梯度， $\|\cdot\|_2$ 为二范式。

计算的过程如下：首先，使用实际输入的样本和我们模型预测的类别进行损失函数的计算，然后计算该损失函数关于模型输入的梯度，接下来，我们使用这个梯度乘以一个事先设定的微小量（通常称为对抗性扰动的强度），然后，便得到了我们需要的扰动值。

2) 随机权重平均 SWA

随机权重平均 SWA（Stochastic Weight Averaging）是一种用于优化神经网络训练的技术。SWA 通过在训练过程中对模型参数进行加权平均来减少模型的波动性，从而提高模型在测试集上的性能。SWA 的核心思想是在训练过程中定期保存模型的参数，并对这些参数进行加权平均。主要是给定训练轮数 T 和每隔一定步数进行参数保存的间隔 τ ，SWA 在第 t 个间隔保存的模型参数集合 $\{w_1, w_2, \dots, w_{\lfloor T/\tau \rfloor}\}$ 上进行加权平均，得到最终的模型参数 $\bar{w}$ ：

$$\bar{w} = \frac{1}{\lfloor T/\tau \rfloor} \sum_{i=1}^{\lfloor T/\tau \rfloor} w_i \quad (3.14)$$

其中， w_i 是第 i 个间隔保存的模型参数， $\lfloor T/\tau \rfloor$ 是保存参数的总次数。

SWA 是深度学习中一种强大的技术，用于提高神经网络的泛化性能。通过对训练过程中获得的权重进行平均处理，SWA 可以有助于减轻过拟合问题，并提高

模型的稳健性。

3) K 折交叉训练

K 折交叉验证方法是一种既简单又强大的模型评估方法，能够很好地评估模型的泛化性能，避免因数据分割的随机性导致的评估结果不稳定，这在机器学习和深度学习模型的训练中具有非常重要的意义。




图 3.11 K 折交叉训练的示意图（5 折）

如图表 3.11 所示：该过程从将整体数据集依据预定的 K 值平均划分为 K 个子集开始。在随后的 K 轮迭代训练中，每一轮选定一个子集充作测试集，而其他 $K-1$ 个子集则共同构成训练集。每完成一轮迭代，便生成一个模型，并获得一个基于该模型在测试集上的表现所计算出的评分。经过 K 轮迭代后，我们得到了 K 个完成训练的模型，每个模型都附有其对应的评分。然后，我们可以将这 K 个评估得分求平均，以此来作为最终的模型性能，从而极大地提高了模型评估的准确性，由于每个数据样本都在某次迭代过程中被用作过一次测试集，因此这种方法也更公平地考虑了所有数据样本的信息。

至于模型的选择，我们通常选择在验证集上平均性能最高的模型作为最终模型。这种评估方法旨在找到一个模型，既能在训练集上达到较好的拟合效果，又能在独立的测试集上表现良好，即有较好的泛化能力。

4) 学习率预热

学习率预热是深度学习中的一种训练策略，其主要目标是为了提高模型在训练初始阶段的稳定性和收敛速度。在训练神经网络时，如何设置学习率是一个重

要的问题。一般来说，在训练开始时，我们希望使用比较小的学习率，以避免模型由于学习率过大在初期迅速震荡或偏离有效解。然后，随着训练的进行，我们会逐渐增大学习率，这样能够充分利用梯度下降法找到更好的解。

常见的学习率预热为线性预热，学习率的变化是线性的。假设一共训练 n 个 step，初始学习率为 lr_s ，最大学习率为 $lr_{\max}$ ，预热比率为 $ratio$ ，则第 i 个 step 的学习率为：

$$lr = lr_s + (lr_{\max} - lr_s) \cdot \frac{i}{n \cdot ratio} \quad (3.15)$$

该方法的核心思想在于，训练初期模型尚未捕捉到有用的特征信息，如果此时采用过高的学习率，可能会导致模型训练不稳定，甚至发散。因此，通过逐步提升学习率的策略，可以让模型在训练过程中逐渐学习并掌握有效特征，同时这种渐进的方式也有助于减少训练过程中出现过拟合的风险。

通过学习率预热，模型在训练开始阶段能够有一个“缓冲期”，从而避免因学习率过大而导致的震荡，同时也能保持随着训练步数的增加，模型能够对数据和任务有更深入的理解和更好的性能。

5) 混合精度训练

混合精度训练，顾名思义是在训练过程中使用多种不同精度（如 32 位浮点数和 16 位浮点数）进行运算和存储，其目的是在不牺牲模型性能的前提下尽可能减少计算资源的消耗，提高训练速度。近年来，混合精度训练已经成为深度学习训练中的重要工具，尤其是在图形处理单元（GPU）具有硬件对 16 位浮点数计算的支持的场景下。

混合精度训练的主要流程如下：

- 1.在模型训练的开始，所有的权重参数（通常存储为 32 位浮点数）被复制并转换为 16 位浮点数格式，用来进行前向计算和反向传播。

- 2.在前向传播过程中，所有的计算（如卷积、矩阵乘法等）都使用 16 位浮点数进行，对于激活函数等可能引起数值无穷或溢出的运算，一般还需要处理一下数值范围。

- 3.在反向传播和权重更新过程中，梯度值和权重更新依然使用 16 位浮点数进行，但权重的更新和存储需要转换回 32 位浮点数，以保证精度。权重更新公式

如下：

$$w_t = \text{float32}(\text{float16}(t_{t-1}) - \eta \cdot \text{float16}(\Delta L)) \quad (3.16)$$

其中， w_{t-1} 为上一步的权重， ΔL 为损失函数关于权重的梯度， η 为学习率， t 表示训练步数。

3.5 实验结果与分析

本文实验的环境配置如下表 3.3 所示：

表 3.3 实验环境配置

实验环境	配置数据
处理器	AMD EPYC 9654
运行内存	60GB
显卡	RTX 4090 24GB
Python 版本	Python 3.9
PyTorch 版本	PyTorch 2.1
CUDA 版本	CUDA 11.7

在深度学习模型的优化训练中，参数的精细调节对于提升模型的表现至关重要。一个合理的参数配置方案可以有效提高模型的效能。此调参过程主要围绕输入文本长度的设定、学习速率的确定以及训练迭代轮数的规划等关键参数进行。在本项研究的模型训练实践中，我们采用了 AdamW 优化算法，并配合了线性预热学习率调度机制 `linear_schedule_with_warmup`。这种策略初阶段使用较低的学习率进行模型预热，以保持训练过程的稳定性，随后逐步提高学习率，以加快模型的收敛速度。同时，为了最大限度地利用 GPU 的计算能力以加快训练速度，本文在模型训练中采用了混合精度训练技术。

本节所采用的 BERT 模型是 RoBERTa 模型的一个变种，即中文优化版的 RoBERTa-wwm-ext 预训练模型。该模型基于 RoBERTa-large 架构，与基础版的 RoBERTa-base 相比，具有更大的模型参数量，这主要表现在其拥有更高维度的隐藏层和更多层的编码器，从而能够捕获更为丰富的语言特征。

3.5.1 模型基本参数调节

其中调节的模型超参数的名称、含义、范围值如表 3.4 所示。

表 3.4 模型可调节参数表

参数名称	参数含义	调节范围
lr	学习率	1e-5,2e-5,5e-5,1e-4
warmup_rate	学习率预热比率	0.05,0.1,0.2
batch_size	训练批次大小	16,32,64
epoch	模型训练轮数	2,3,4,5,6
max_len	文本输入长度	128,256,350,512

表 3.5 BERT+MMOE 模型调优后的参数值

参数名称	参数含义	参数值
lr	学习率	2e-5
warmup_rate	学习率预热比率	0.05
batch_size	训练批次大小	32
epoch	模型训练轮数	3
max_len	文本输入长度	256

表 3.6 BERT+AT-LSTM 模型调优后的参数值

参数名称	参数含义	参数值
lr	学习率	1e-5
warmup_rate	学习率预热比率	0.1
batch_size	训练批次大小	16
epoch	模型训练轮数	3
max_len	文本输入长度	350

表 3.7 BERT+多头注意力机制模型调优后的参数值

参数名称	参数含义	参数值
lr	学习率	1e-4
warmup_rate	学习率预热比率	0.1
batch_size	训练批次大小	32
epoch	模型训练轮数	3
max_len	文本输入长度	350

在模型的训练过程中，通过对比分析，使用 BERT-base 模型时，训练至第 5 个 epoch 时模型的离线性能表现最佳。而在使用 BERT-large 模型时，第 3 个 epoch 的离线性能最高。基于这些观察结果，我们决定将训练轮数 epoch 设定为 3。同时，在调整批次大小 batch_size 和文本最大长度 max_len 这两个参数时，我们必须谨慎考虑 GPU 显存的容量限制。例如，当训练批次设置为 64 且文本最大长度设置为 512 时，可能会超出 GPU 的显存容量，这将导致训练过程无法继续。因此，这两个参数需要进行联合调整。经过调整和优化，我们得到的三个模型的最优超参数分别记录在表 3.5、表 3.6 和表 3.7 中。

3.5.2 基础模型调优结果

模型 Baseline 为 3.5 节构建的三种模型，都是基于 BERT-large 模型进行训练实验，表 3.8 中的分数为上述三种模型通过参数调优后得到的。

表 3.8 baseline 分数

模型	分数
BERT+MMOE	0.7057
BERT+AT-LSTM	0.7052
BERT+多头注意力机制	0.7049

3.5.3 模型训练技巧提升

SWA 可以视为 EMA 的一种特定实现方式。在模型的每次参数更新之后，SWA 会将新参数与前一时刻的 EMA 值进行加权平均，并保留这个平均值。这个

平均后的参数集合在模型验证阶段被使用，并最终作为模型参数被保存下来。SWA 通过指数加权平均的方式对模型参数进行平滑处理，减少了参数更新过程中的随机噪声，从而增强了模型的泛化能力。

FGM 策略，本质上是一种模型训练中的扰动增强技术，它作用于 BERT 模型的词嵌入层，通过引入扰动来模拟对模型的干扰。该方法通过找出在特定参数下能够引发最显著干扰的扰动向量，训练模型以提高其鲁棒性，确保即便在受到外部扰动的影响下，模型仍能准确区分原始的标签。在实际操作中，扰动后的输入样本被用来执行模型的训练，通过反向传播算法计算出的梯度更新，与原始梯度合并，共同指导模型参数的调整，从而起到了增强模型泛化能力的作用。在本节的模型训练中，所使用的扰动系数 α 为 0.99。

表 3.9 不同模型训练技巧实验对比分数

模型	分数
BERT+MMOE+FGM	0.7066
BERT+MMOE+SWA	0.7054
BERT+MMOE+FGM+SWA	0.7068
BERT+AT-LSTM+FGM	0.7057
BERT+AT-LSTM+SWA	0.7059
BERT+AT-LSTM+FGM+SWA	0.7066
BERT+多头注意力机制+FGM	0.7059
BERT+多头注意力机制+SWA	0.7052
BERT+多头注意力机制+FGM+SWA	0.7056

K 折交叉验证是一种高效的数据利用方法，它能够更充分地利用可用数据，减少仅使用部分数据集进行训练时可能造成的信息损失，并且有助于降低模型评估结果的方差，提高评估的稳定性和可靠性。在本节的实验中，我们采用了 5 折交叉验证的方法，这意味着数据集被均匀分成 5 份，每次用 4 份作为训练集，剩下的 1 份作为验证集，这个过程将重复 5 次并计算模型的平均性能。此外，本节的实验基于前文所确定的最优模型参数进行，以确保实验结果的对比性和有效性。最终的实验结果如表 3.10 所示。

表 3.10 5 折交叉验证后的分数

模型	分数
BERT+MMOE+FGM+SWA+5 折	0.7097
BERT+AT-LSTM+FGM+SWA+5 折	0.7114
BERT+多头注意力机制+FGM+SWA+5 折	0.7123

3.5.4 模型融合

模型融合背后的基本思想是，不同的模型可能会在不同的方面表现出优势，通过组合它们，可以减少单个模型的弱点，并利用各自的优势。所以为了提高本文模型的效果，本文尝试了多种模型融合策略，最终选定为加权平均融合，其融合效果达到了 0.7126。加权公式如下：

$$\text{模型融合} = 0.3 \times \text{MMOE} + 0.2 \times \text{AT-LSTM} + 0.5 \times \text{多头注意力机制} \quad (3.17)$$

3.5.5 实验总结

从实验结果可以观察到，相较于基础版 base 的模型，更高级复杂的版本 large 在性能上表现更佳。所以在后续的研究和应用中，本文选择 BERT 模型都是倾向于选择 RoBERTa-large 版本。但性能更优的 large 模型因其拥有更多的参数，导致其对显存的需求也更大，这对模型训练中的批次大小、文本长度等超参数的调整产生了影响。在模型训练技巧方面，本文基于 BERT 模型构建的三种模型在应用了 FGM 和 SWA 后，性能均有所提升。BERT 模型的微调过程中，EMA 和 FGM 的运用被证明是提升模型性能的有效手段。此外，采用 5 折交叉验证不仅能充分利用数据，还能通过模型融合进一步提升模型的性能指标。通过平均融合各个模型的情感分析结果，得到的分数为 0.7126。最终模型的性能对比详见下图 3.11。




图 3.12 各种模型的效果对比图

3.6 本章小结

本章集中讨论了利用 BERT 预训练模型实现情感分析的算法方案。首先，对所面临的问题进行了概述，包括对数据集的介绍和赛题任务的明确定义。随后，执行了数据预处理的相关工作，涉及数据清洗、文本拼接等操作。紧接着，本文提出了一种特殊的损失函数，旨在更好地适应情感分析任务的特点。

继而深入探讨了 BERT 预训练模型的架构组成、文本编码方法以及该模型所经历的预训练过程。此外，本章还阐述了 BERT 模型对上下文信息进行编码的策略，并呈现了基于 BERT 模型构建的三种创新的模型方案。在模型构建完成后，进行了细致的模型训练，并引入了多种训练技巧，目的在于提高模型的泛化能力和鲁棒性。

本章的实验分析部分，对不同的模型构建方案和相应的训练技巧进行了全面评估，以判断其在情感分析任务中的应用效果和可行性。这些实验结果为 BERT 模型在情感分析领域的应用提供了深入的理解，并对实施过程中需考虑的关键点提供了指导。

第4章 基于 NLP 的情感分析系统设计

4.1 可行性分析和需求分析

4.1.1 可行性分析

随着互联网技术的不断发展，尤其是移动互联网的迅猛发展，使得人们在通讯交流、购物出行等生活方式发生了巨大的改变。人们在网络上产生了大量的文本数据，其中包括了用户对不同事物的评论。这些评论蕴含着丰富的情感信息，对于了解用户对产品、服务或事件的态度和情感倾向具有重要意义。但由于评论数据的庞大和复杂性，传统的手工分析方法已经无法满足对这些数据进行有效处理和分析的需求。本文结合自然语言处理的前沿技术，对文本进行了细粒度的情感分析，保证了分析的准确性和可信度。本系统在技术层面的可行性主要体现在以下两个关键点：

算法开发层面，系统依托的数据集源自中国计算机学会（CCF）主办的“大数据与计算智能大赛”，并在该赛事的评估体系中进行了性能测试。测试结果显示，本系统的方案在评比中优于其他参赛作品。研究中还实施了多模型集成策略，以此增强模型的综合预测效能。

技术应用层面，本文融合了当前自然语言处理领域的先进技术，特别是采用了 BERT 预训练模型，并与其他模型结合，构建了三种创新的模型方案：结合多模态门控机制的 BERT 模型、融合多头注意力机制的 BERT 模型，以及整合了注意力增强长短期记忆网络的 BERT 模型。为了提升模型性能，本研究采用了 FGM 等先进的训练技术来增强模型的泛化和鲁棒性。此外，通过实施混合精度和半精度训练策略，有效降低了显存消耗，并提高了模型训练与推理的效率。

4.1.2 需求分析

依据数据集完成的本系统主要是为了人们更好的了解角色的情感，以便更好的理解角色，帮助演员更快的融入角色的情感中，同时也方便编导和导演更好的挑选适合角色的演员。更具所需，基于 NLP 的情感分析系统主要具备以下功能：

- 1) 整体分析：

本系统包含数据的总体预览，可以清晰的看出剧本的数量、文本的数量、文本的缺失情况等。根据情感的分布情况也可以分析剧本的基础类型，对角色的主要出现次数等进行分析可确定主角等。

2) 情感展示

根据情感分析示例，可以展示出本系统情感分析的过程与结果，根据情感的占比情况等可以展示数据的偏好等。

4.2 系统设计

4.2.1 系统开发环境与工具

1) 硬件环境

硬盘：1T

内存容量(GB)：64

缓存容量(MB)：16

显存容量(GB)：24

GPU 显卡：1 块 RTX 4090 24GB

CPU：AMD Ryzen 7 5800H with Radeon Graphics

CPU 基本频率(GHz)：3.20

2) 软件环境

开发工具：VebStorm、IDEA

数据库：MySQL

操作系统：Windows10、CentOS7

开发框架：Python 3.9、Pytorch 2.1、CUDA 11.7、Transformers、Sklearn、Numpy、Pandas、Jieba、Word2Vec 等集成库。

4.2.2 系统架构

基于自然语言处理（NLP）的情感分析系统的设计通常分为三个主要层次：数据采集层、数据分析层和应用层。具体来说：

1) 数据采集层

在这一层中，系统使用的是 CCF（中国计算机学会）比赛中提供的真实剧本

数据集。这些数据构成了情感分析系统的基础输入。

2) 数据分析层：

该层的功能是对采集到的剧本数据进行存储和管理。随后，这些数据会经过文本预处理，以准备进行情感分析。文本预处理可能包括清洗、分词、去除噪声等步骤。预处理完成后，数据再次被存储，以供下一步分析使用。

3) 应用层：

在这一层，处理后的数据通过可视化的方式展示出来，使得用户能够直观地理解情感分析的结果。

整个情感分析系统的架构设计旨在确保数据的有效处理和分析，并通过用户友好的界面展示分析结果。系统架构的具体展示可以参考图 4.1。




图 4.1 系统框架图

4.3 系统展示

本节主要介绍基于 NLP 的情感分析系统的可视化展示，包括数据分析、角色情感识别等功能。系统可视化的各模块如下所示：




图 4.2 情感极性占比

上图 4.2 是数据集的六种情感极性统计可视化，根据数据集提供的数据，统计分析六种情感（爱、乐、惊、怒、恐、哀）的极性数量，然后使用 Echarts 画出柱状统计图。




图 4.3 标签缺失情况

上图 4.3 是数据集的标签缺失情况统计可视化，根据数据集提供的数据，统计分析了训练集的情感标签确实情况和测试集的角色标签缺失情况，然后使用 Echarts 画出环形饼状图。



图 4.4 数据统计

上图 4.4 为数据集的统计情况可视化。统计分析了数据集的文本总句子、环境描写句子、剧本数量和角色数量。



图 4.5 情感分析示例

上图 4.5 为情感分析示例可视化。展示了根据句子进行情感分析的示例及其结果。




图 4.6 角色重要性

上图 4.6 为选取的两个剧本的角色重要性可视化。主要是更具本文制定的规则计算角色的重要性，然后选取展示了几个重要角色的重要性。




图 4.7 剧本情感主题

上图 4.7 为选取的两个剧本的情感主题可视化。主要是更具本文制定的规则计算角色的情感，然后根据角色的情感分析计算剧本的情感，最后根据剧本的情感画出雷达图进行展示。

最后基于 NLP 的情感分析系统可视化整体界面如图 4.8 所示。



图 4.8 基于 NLP 的情感分析系统可视化

4.4 本章小结

本章全面介绍了基于 NLP 技术构建的情感分析系统的设计与实现。首先，对项目的可行性进行了分析，并明确了系统所需的功能。接着，介绍了系统开发所需的环境和工具，为开发工作提供了技术基础。系统架构被划分为采集层、分析层和应用层，每个层级都承担着不同的职责，确保了情感分析任务的高效执行。在系统展示部分，通过数据的统计分析、角色重要性排序、剧本主题类型判断和情感分析示例等，展示了系统的关键功能。

第5章 总结与展望

5.1 工作总结

本文的主要任务是进行细粒度的情感分析。随着互联网的发展和人们生活水平的日益提高，传统的情感分析已经满足不了人们的需求，本文就这一需求基于前言的算法进行了细粒度的情感分析。传统的机器学习方案还需进行特征工程，并且手工提取的难度相对较大，局限性也很明显。近年来随着深度学习的爆火，基于深度学习的情感分析也随之受到人们的关注与研究，Transformer、GPT、ELMO、BERT 模型也相继推出，“预训练+微调”的范式也广泛应用于自然语言处理任务中，本文也是提出了一种基于 BERT 预训练模型的情感分析方案，并将其与其他模型相结合，以实现模型融合，从而提升整体的分析效果。

在设计具体的解决方案时，考虑到剧本数据的上下文联系非常紧密，本文通过文本拼接来对文本进行上下文建模，以此来增强模型的性能。此外，由于剧本中每个角色的情感表达并非孤立，一个角色可能同时展现出多种情感，本文从多任务学习的角度出发，对这一现象进行了建模。通过这种多维度的分析方法，可以更准确地捕捉和分析角色的情感状态。主要构建了 BERT 作为文本编码器，选择了 MMOE、多头注意力机制模型、AT-LSTM 等模型进行下游任务，对六种情感进行交互预测。并且为了提高模型的泛化性和鲁棒性，在训练过程中尝试探讨了不同的训练技巧，主要包括对抗训练 FGM、随机权重平均 SWA 和学习率预热等技巧。为了降低显存的消耗，本文还采用了混合精度训练，这也加快了训练和推理的速度。

最终进行三种模型构建方案的模型融合，从效果来看，融合后的模型能够将三种模型进行优势互补，相比于 MMOE、多头注意力机制模型、AT-LSTM 这三个模型计算精度能够显著提高。

5.2 未来工作展望

虽然当前研究所融合的模型已经取得了一定的成效，但仍有进一步提升的空间。例如，图神经网络（GNN）作为一种新兴的网络架构，它通过图形模型来表

示文本中词汇的相互联系，这一技术尚未在本研究中得到应用。在未来的研究工作中，将 GNN^[21]技术整合入当前的研究框架，可能会成为提升模型性能的一个有效途径。

同时，考虑到 NLP 领域中预训练模型的重要性日益凸显，特别是 prompt^[22]范式，它通过将特定的下游任务重新设计，使之与预训练任务相吻合，从而更有效地利用预训练模型所获得的知识。未来的研究可以着重探索如何将 prompt 范式有效地融入情感分析任务中，这可能会为情感分析领域带来新的突破。

参考文献

- [1] 中国互联网络信息中心. 第 52 次《中国互联网络发展状况统计报告》发布及专家解读[J]. 互联网天地, 2023, 6(9): 11-15.
- [2] 王颖洁, 朱久祺, 汪祖民, 等. 自然语言处理在文本情感分析领域应用综述[J]. 计算机应用, 2022, 42(4): 1011-1020.
- [3] SUTHAHARAN S, SUTHAHARAN S. Support vector machine[J]. Machine Learning Models and Algorithms for Big Data Classification, 2016, 18(7): 207-235.
- [4] MURPHY K. Naive bayes classifiers[J]. University of British Columbia, 2006, 18(60): 1-8.
- [5] ZHAO Z, WU Y. Attention-Based Convolutional Neural Networks for Sentence Classification[C]. Interspeech, San Francisco, USA, 2016: 705-709.
- [6] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[J]. Advances in Neural Information Processing Systems, 2017, 5(30): 5-16.
- [7] DEVLIN J, CHANG M, LEE K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[EB/OL]. 2018: arXiv preprint arXiv: 1810. 04805.
- [8] MEDSKER L R, JAIN L. Recurrent neural networks[J]. Design and Applications, 2001, 5(64-67): 2-12.
- [9] TANG D, QIN B, FENG X, et al. Effective LSTMs for target-dependent sentiment classification[EB/OL]. 2015: arXiv preprint arXiv: 1512. 01100.
- [10] PORIA S, MAJUMDER N, MIHALCEA R, et al. Emotion recognition in conversation: Research challenges, datasets, and recent advances[J]. IEEE Access, 2019, 7(5): 100943-100953.
- [11] GHARSALLI S, EMILE B, LAURENT H, et al. Random forest-based feature selection for emotion recognition[C]. 2015 International Conference on Image Processing Theory, Boston, USA, 2015: 268-272.
- [12] THET T, NA J, KHOO C. Aspect-based sentiment analysis of movie reviews on discussion boards[J]. Journal of Information Science, 2010, 36(6): 823-848.

- [13]CUI Y, CHE W, LIU T, et al. Pre-training with whole word masking for Chinese BERT[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2021, 29(4): 3504-3514.
- [14]GOLDBERG Y, LEVY O. word2vec Explained: deriving Mikolov et al.'s negative-sampling word-embedding method[EB/OL]. 2014: arXiv preprint arXiv: 1402.3722.
- [15]PENNINGTON J, SOCHER R, MANNING C D. Glove: Global vectors for word representation[C]. Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP), Doha, Qatar: 2014: 1532-1543.
- [16]TANG D, WEI F, YANG N, et al. Learning sentiment-specific word embedding for Twitter sentiment classification[C]. Proceedings of the 52nd Annual Meeting of the Association for Computational Linguistics, Vancouver, Canada, 2014: 1555-1565.
- [17]LIU X, ZHENG Y, DU Z, et al. GPT understands, too[J]. AI Open, 2023, 6(8): 23-48.
- [18]MA J, ZHAO Z, YI X, et al. Modeling task relationships in multi-task learning with multi-gate mixture-of-experts[C]. Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, Sydney, Australia, 2018: 1930-1939.
- [19]WANG Y, HUANG M, ZHU X, et al. Attention-based LSTM for aspect-level sentiment classification[C]. Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing, Paris, France, 2016: 606-615.
- [20]SONG Y, WANG J, JIANG T, et al. Attentional encoder network for targeted sentiment classification[EB/OL]. 2019: arXiv preprint arXiv: 1902.09314.
- [21]LIANG X, TU G, DU J, et al. Multi-Modal Attentive Prompt Learning for Few-shot Emotion Recognition in Conversations[J]. Journal of Artificial Intelligence Research, 2024, 79(14): 825-863.
- [22]SHAHBAZ M, SURESH L, REXFORD J, et al. Elmo: Source routed multicast for public clouds[M]. Vancouver, Canada, Proceedings of the ACM Special Interest Group on Data Communication, 2019: 458-471.

致谢

是结束，也是开始。我的大学始于 2020 年初秋，终于 2024 年盛夏。当初高考延期的那一批学生，现在大学也即将毕业。这一年是我的 21 岁，是青肆意的黄金时刻，在这四年里，有喜悦、迷茫、遗憾，但更多的是感和成长。

首先，我想感谢四年来传道授业解惑的老师们的、我的论文指导老师和各位答辩组专家老师们，于前路为我指明方向。我要特别感谢我的指导老师杨燕，您不仅在学术上给予了我精心的指导和无私的帮助，而且在研究方法和思路给予了我极大的启发。您严谨的学术态度、深邃的学术见解和耐心的教导，对我未来的学术发展和职业生涯都将产生深远的影响。

其次，我想感谢我的家人，感谢我平凡而又伟大的父母，让我生活在个温暖幸福的家庭里。他们给予我足够多的自由，他们说天高任鸟飞，从不干涉我的选择，让我选择自己的人生道路，培养了一个独立坚强的自我。

最后，我想感谢我的朋友们，苦闷时常解忧虑，喜悦时一块欢宜。感谢你们参与了我的青春年华，感谢你们给予我的陪伴、感谢你们给予我的关心。

行文至此，落笔为终。我与崇文路 2 号的故事也即将结束，希望母校发展的越来越好。希望我能永远忠于自己，选择自己想要的人生。落幕的是我的大学生活，而不是依然有千万种可能的我。